

Predicción de demanda energética mediante Machine Learning y datos abiertos

00 Mes 2026



Universidad
Internacional
de Valencia

Titulación:

Máster Universitario en Big
Data y Ciencia de Datos

Curso académico
2025 – 2026

Alumno/a:

García Peña, Roberto

D.N.I.: 17458202Y

Director/a de TFT:

Gonzalo Surribas Sayago

Convocatoria:

Primera

De:

 Planeta Formación y Universidades

Índice general

Resumen	1
Abstract	2
1 Introducción	3
1.1 Contexto y motivación	3
1.2 Justificación del trabajo	3
1.3 Estructura del documento	4
2 Objetivos	6
2.1 Objetivo general	6
2.2 Objetivos específicos	6
2.3 Alcance y limitaciones	7
3 Estado del arte o Marco Teórico	8
3.1 Predicción de demanda energética: panorama general	8
3.2 Modelos clásicos de series temporales	9
3.2.1 Modelos ARIMA y SARIMA	9
3.2.2 Prophet	10
3.2.3 Análisis espectral y series de Fourier	10
3.3 Aprendizaje automático aplicado a series temporales	11
3.3.1 Modelos basados en árboles	11
3.3.2 Ingeniería de características temporales	12
3.4 El mercado eléctrico español y la tarifa PVPC	12
3.5 Trabajos previos relacionados	13
4 Metodología	15
4.1 Arquitectura del sistema	15
4.2 Adquisición y descripción de los datos	16
4.2.1 Demanda eléctrica	17
4.2.2 Variables meteorológicas	17
4.2.3 Calendario laboral	18
4.2.4 Delimitación temporal	18

4.3	Tratamiento y preprocesado de los datos	18
4.3.1	Análisis exploratorio inicial	18
4.3.2	Integridad de la serie y tratamiento de valores ausentes	19
4.3.3	Análisis de patrones cíclicos mediante series de Fourier	21
4.3.4	Descomposición estacional múltiple	22
4.3.5	Análisis de autocorrelación	24
4.3.6	Identificación de anomalías	24
4.3.7	Relación entre demanda y temperatura	26
4.3.8	Perfiles de consumo	27
4.4	Ingeniería de características	28
4.4.1	Codificación cíclica de las variables temporales	29
4.4.2	Términos de temperatura	29
4.4.3	Prevención de fuga de información	30
4.5	Estrategia de validación	31
4.6	Modelos desarrollados	32
4.6.1	Línea base	32
4.6.2	Modelos de aprendizaje automático	33
4.6.3	Sobre la optimización de hiperparámetros	34
4.7	Métricas de evaluación	34
4.8	Desarrollo de la aplicación web	35
5	Discusión	38
5.1	Resultados del análisis exploratorio	38
5.1.1	Calidad de la fuente de datos	38
5.1.2	Estructura temporal	38
5.1.3	Efecto del calendario	38
5.1.4	Relación con la temperatura	39
5.2	Comparativa de rendimiento de los modelos	39
5.3	Análisis de la importancia de variables	42
5.4	Análisis de errores	43
5.5	Evaluación en días festivos	45
5.6	Aplicación desarrollada	47
6	Conclusiones	49
6.1	Cumplimiento de los objetivos	49
6.2	Principales aportaciones	50
6.3	Limitaciones del trabajo	51
6.4	Líneas de trabajo futuro	52
7	Referencias	53

Índice de figuras

4.1	Arquitectura general del sistema	15
4.2	Demanda eléctrica horaria en tres escalas temporales: serie completa 2022–2024 (superior), detalle mensual (centro) y detalle semanal (inferior)	19
4.3	Inspección del hueco de mayor longitud (18 horas, 6 de marzo de 2022). La franja sombreada corresponde al tramo imputado	20
4.4	Comparativa de la distribución de la demanda antes y después del proceso de imputación	21
4.5	Periodograma de la serie de demanda. Escala logarítmica (superior) y detalle de los ciclos de corto plazo (inferior)	21
4.6	Descomposición MSTL de la serie con estacionalidad diaria (24 h) y semanal (168 h). El tramo ascendente inicial del panel de tendencia constituye un artefacto de borde del procedimiento, no un fenómeno real	23
4.7	Comparación del residuo obtenido mediante STL (periodo 24 h) y MSTL (periodos 24 h y 168 h)	23
4.8	Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie de demanda	24
4.9	Anomalías clasificadas según su origen (superior) y distribución del residuo asociado a cada categoría (inferior)	25
4.10	Relación entre demanda diaria media y temperatura media, con ajuste cuadrático superpuesto (izquierda) y matriz de correlaciones lineales (derecha)	27
4.11	Perfiles de consumo: perfil horario por día de la semana, distribución mensual, comparación entre días laborables y no laborables, y mapa de calor hora $\times$ mes	28
5.1	Importancia de las variables en el modelo seleccionado	42
5.2	Valores SHAP del modelo seleccionado	43
5.3	Interfaz de la aplicación web desarrollada parte 1	47
5.4	Interfaz de la aplicación web desarrollada parte 2	47

Índice de tablas

2.1	Delimitación del alcance del trabajo	7
4.1	Fuentes de datos empleadas	17
4.2	Periodos dominantes identificados mediante análisis espectral	22
4.3	Distribución de las anomalías detectadas según su origen	26
4.4	Variables predictoras construidas y su justificación	29
4.5	Disponibilidad de las variables en el instante de predicción	30
5.1	Comparativa de rendimiento de los modelos evaluados	39
5.2	Error de entrenamiento frente a error de producción	41
5.3	Error según el tipo de día (modelos de aprendizaje automático)	43
5.4	Error en los orígenes problemáticos de la línea base	44
5.5	Rendimiento en los ocho días festivos evaluados	45
5.6	Intensidad de festivo según el alcance territorial	46
6.1	Grado de consecución de las métricas establecidas	50

Resumen

La demanda eléctrica presenta patrones complejos influenciados por variables meteorológicas, hábitos de consumo, estacionalidad y calendario laboral, cuya correcta anticipación resulta clave tanto para la planificación de la red eléctrica como para la toma de decisiones del consumidor final. El presente Trabajo Fin de Máster desarrolla un sistema integral de predicción de la demanda energética en España a partir de fuentes de datos abiertos, aplicando una progresión metodológica que parte de modelos estadísticos clásicos de series temporales y escala hacia técnicas de aprendizaje automático.

El trabajo comprende un análisis exploratorio exhaustivo de los datos históricos de consumo eléctrico publicados por Red Eléctrica de España, complementados con variables meteorológicas procedentes de AEMET y con el calendario laboral correspondiente. Se emplean series de Fourier para la identificación de los patrones cíclicos dominantes previa a la fase de modelado. Posteriormente se construyen y comparan modelos ARIMA, SARIMA y Prophet como línea base, frente a algoritmos de aprendizaje automático como Random Forest, XGBoost y LightGBM, evaluando su rendimiento mediante métricas de entrenamiento y producción para garantizar la capacidad de generalización.

Finalmente, el modelo de mejor desempeño se integra en una aplicación web interactiva que permite consultar las previsiones de demanda para las próximas 24–48 horas, identificar las franjas horarias de menor consumo y obtener recomendaciones accionables orientadas a la optimización del consumo doméstico en el contexto de la tarifa PVPC.

Palabras clave: predicción de demanda energética, series temporales, machine learning, datos abiertos, aprendizaje automático, tarifa PVPC, eficiencia energética.

Abstract

Electricity demand exhibits complex patterns driven by meteorological variables, consumption habits, seasonality and the working calendar. Accurately anticipating these patterns is critical both for power grid planning and for end-consumer decision making. This Master's Thesis develops a comprehensive energy demand forecasting system for Spain based on open data sources, following a methodological progression that starts from classical statistical time series models and scales towards machine learning techniques.

The work includes a thorough exploratory analysis of historical electricity consumption data published by Red Eléctrica de España, complemented with meteorological variables from AEMET and the corresponding working calendar. Fourier series are applied to identify the dominant cyclical patterns prior to the modelling stage. ARIMA, SARIMA and Prophet models are then built as a baseline and compared against machine learning algorithms such as Random Forest, XGBoost and LightGBM, assessing their performance through both training and production metrics to ensure generalisation capability.

Finally, the best performing model is integrated into an interactive web application that allows users to consult demand forecasts for the next 24–48 hours, identify the lowest consumption time slots and obtain actionable recommendations aimed at optimising domestic energy usage within the Spanish PVPC tariff framework.

Keywords: energy demand forecasting, time series, machine learning, open data, PVPC tariff, energy efficiency.

1. Introducción

1.1. Contexto y motivación

El sistema eléctrico español ha atravesado en los últimos años un periodo de transformación acelerada. La progresiva integración de generación renovable, la electrificación del transporte y la volatilidad de los mercados energéticos han situado la gestión de la demanda en el centro del debate público y técnico.

La predicción de la demanda eléctrica constituye una función crítica para el operador del sistema. La red carece de capacidad de almacenamiento significativa, por lo que generación y consumo deben equilibrarse de forma continua: una previsión deficiente obliga a recurrir a mecanismos de ajuste más costosos y menos eficientes desde el punto de vista ambiental. Este problema ha sido ampliamente estudiado en la literatura, con un cuerpo de trabajo consolidado en torno a la predicción de carga a corto plazo (Hong y Fan 2016).

Existe, sin embargo, una segunda dimensión del problema que ha recibido mucha menos atención: la del **consumidor doméstico**. En España, la tarifa regulada —el Precio Voluntario para el Pequeño Consumidor, PVPC— establece un precio que varía cada hora del día en función del resultado del mercado mayorista. El consumidor acogido a esta modalidad puede, en principio, reducir su factura desplazando el consumo hacia las horas más económicas.

En la práctica, aprovechar esa posibilidad exige una información que no está al alcance del usuario medio. Los precios del día siguiente se publican a las 20:15 horas, una vez cerrada la subasta diaria, y su interpretación requiere una familiaridad con el funcionamiento del mercado eléctrico que difícilmente cabe presuponer. El resultado es una asimetría notable: la información existe, es pública y es gratuita, pero permanece inaccesible para quien más podría beneficiarse de ella.

Este trabajo parte de esa observación. Su motivación no es únicamente construir un modelo predictivo preciso —objetivo ampliamente cubierto por la literatura— sino **cerrar la distancia entre el dato abierto y la decisión del ciudadano**, mediante un sistema que traduzca la previsión técnica en una recomendación comprensible y accionable.

1.2. Justificación del trabajo

La justificación del presente trabajo se articula en torno a tres argumentos.

Disponibilidad de datos abiertos infrautilizados

Red Eléctrica de España publica la demanda peninsular con resolución de diez minutos y sin restricciones de acceso, y la Agencia Estatal de Meteorología ofrece tanto series climatológicas históricas como previsiones a cuarenta y ocho horas. Ambas fuentes son gratuitas y de acceso programático. Pese a ello, su explotación conjunta con fines de asesoramiento al consumidor final resulta escasa.

Distancia entre la literatura académica y la herramienta utilizable

La investigación sobre predicción de demanda eléctrica es abundante, pero sus resultados rara vez trascienden el entorno experimental. Un modelo evaluado en un cuaderno de análisis y un sistema desplegado al que un usuario puede acceder son artefactos de naturaleza distinta: el segundo exige resolver la obtención de datos en tiempo real, el tratamiento de fallos de las fuentes externas, la coherencia entre el código de entrenamiento y el de producción, y la traducción del resultado numérico a lenguaje natural.

Aportación diferencial: un sistema completo

El trabajo no se limita a comparar algoritmos. Abarca el ciclo completo —ingesta, tratamiento, modelado, evaluación y despliegue— y produce como resultado una aplicación accesible públicamente. Esta orientación condiciona decisiones metodológicas que un estudio puramente comparativo podría obviar: la disponibilidad efectiva de cada variable en el instante de predicción, el coste computacional del reentrenamiento o el comportamiento del sistema ante la caída de una fuente externa.

1.3. Estructura del documento

El documento se organiza en seis capítulos.

El **capítulo 2** formula el objetivo general y los siete objetivos específicos, y delimita el alcance del trabajo.

El **capítulo 3** revisa el estado del arte: el panorama general de la predicción de demanda eléctrica, los modelos clásicos de series temporales, las técnicas de aprendizaje automático aplicadas a este dominio y el funcionamiento del mercado eléctrico español.

El **capítulo 4** expone la metodología. Describe la arquitectura del sistema, las fuentes de datos, el tratamiento aplicado —que constituye una de las aportaciones centrales—, la ingeniería de características derivada del análisis exploratorio, la estrategia de validación y los modelos evaluados.

El **capítulo 5** presenta y discute los resultados: la caracterización de la serie, la comparativa de rendimiento entre las diez formulaciones evaluadas, el análisis de importancia de variables, el estudio de errores y la aplicación desarrollada.

El **capítulo 6** revisa el grado de cumplimiento de los objetivos, sintetiza las aportaciones, reconoce las limitaciones y propone líneas de continuación.

Se incluyen finalmente las referencias bibliográficas y tres anexos con el repositorio de código, la aplicación desplegada y el cronograma del proyecto.

2. Objetivos

2.1. Objetivo general

Desarrollar un sistema integral de predicción de la demanda energética en España mediante técnicas de aprendizaje automático aplicadas sobre fuentes de datos abiertos, abarcando desde la ingesta y el tratamiento riguroso de los datos hasta el despliegue de una aplicación web funcional que traduzca las predicciones en recomendaciones comprensibles para el usuario final.

2.2. Objetivos específicos

- OE1.** Analizar el comportamiento histórico de la demanda energética mediante técnicas de análisis exploratorio de datos, identificando tendencias, estacionalidad y ciclos característicos.
- OE2.** Incorporar variables exógenas relevantes al conjunto de datos: condiciones meteorológicas procedentes de AEMET, calendario laboral y variables de calendario derivadas.
- OE3.** Aplicar series de Fourier para la identificación de los patrones cíclicos dominantes con carácter previo a la fase de modelado.
- OE4.** Desarrollar y comparar modelos predictivos siguiendo una progresión de complejidad creciente: modelos estadísticos clásicos (ARIMA, SARIMA, Prophet) como línea base, y modelos de aprendizaje automático (Random Forest, XGBoost, LightGBM) como propuesta principal.
- OE5.** Evaluar el rendimiento de los modelos mediante métricas de entrenamiento y de producción (MAE, RMSE, MAPE), controlando explícitamente el sobreajuste.
- OE6.** Interpretar los resultados obtenidos e identificar los factores con mayor influencia sobre la demanda mediante análisis de importancia de variables.
- OE7.** Desplegar el modelo de mejor desempeño en una aplicación web interactiva accesible públicamente, con predicciones a 24–48 horas y recomendaciones orientadas a la tarifa PVPC.

2.3. Alcance y limitaciones

Tabla 2.1: Delimitación del alcance del trabajo

Dentro del alcance	Fuera del alcance
Demanda eléctrica peninsular española (REE)	Consumo individual del usuario en tiempo real
Histórico 2022–2024 (datos horarios)	Predicción de generación renovable
Variables meteorológicas de AEMET	Integración con API de distribuidoras
Calendario laboral	Aplicación móvil nativa
Horizonte de predicción de 24–48 horas	Predicción por comunidad autónoma
Aplicación web desplegada	Modelos de precio del mercado mayorista

3. Estado del arte o Marco Teórico

3.1. Predicción de demanda energética: panorama general

La predicción de la demanda eléctrica constituye una de las aplicaciones más antiguas y mejor documentadas del análisis de series temporales. Su relevancia deriva de una restricción física del sistema: la electricidad no puede almacenarse en cantidades significativas a escala de red, de modo que generación y consumo han de equilibrarse de forma instantánea y permanente.

Clasificación por horizonte temporal

La literatura distingue habitualmente cuatro horizontes, cada uno asociado a una finalidad operativa y a metodologías distintas (Hong y Fan 2016):

- **Muy corto plazo** (de minutos a una hora). Orientado al control en tiempo real y a la regulación de frecuencia. Predomina la inercia de la serie: los métodos autorregresivos simples resultan difíciles de superar.
- **Corto plazo** (de una hora a una semana). Es el horizonte de la programación diaria y de la casación del mercado, y el que concentra el mayor volumen de investigación. **El presente trabajo se sitúa en este intervalo**, con un horizonte de veinticuatro a cuarenta y ocho horas.
- **Medio plazo** (de una semana a un año). Empleado en la planificación del mantenimiento y en la contratación de combustible.
- **Largo plazo** (más de un año). Orientado a la planificación de infraestructuras. Depende de variables macroeconómicas y demográficas más que de la propia serie histórica.

Factores determinantes

Existe consenso en la literatura sobre los tres grupos de factores que gobiernan la demanda a corto plazo:

1. **Calendario.** Hora del día, día de la semana y festividades. Su efecto es sistemático y predecible, y constituye la fuente principal de estructura de la serie.
2. **Meteorología.** Fundamentalmente la temperatura, cuya relación con la demanda no es lineal sino aproximadamente cuadrática, por la superposición de las demandas de calefacción y refrigeración.

3. **Actividad económica.** Relevante en horizontes medios y largos, con efecto reducido a escala de días.

Evolución metodológica

El campo ha atravesado tres etapas sucesivas. Hasta los años noventa predominaron los modelos estadísticos de la familia Box-Jenkins (Box et al. 2015) y la regresión con variables meteorológicas. La década siguiente vio la incorporación de las redes neuronales, con resultados desiguales. Desde mediados de la década de 2010 se han impuesto los métodos de conjunto basados en árboles de decisión.

Las competencias M han proporcionado la evidencia comparativa más sólida al respecto. La cuarta edición (Makridakis, Spiliotis y Assimakopoulos 2020) estableció que las combinaciones de métodos superan sistemáticamente a los modelos individuales, y que el aprendizaje transversal entre series mejora los resultados frente al ajuste individualizado. La quinta (Makridakis, Spiliotis y Assimakopoulos 2022) arrojó un hallazgo aún más rotundo: los métodos basados en árboles con potenciación del gradiente dominaron las primeras posiciones, por delante de las arquitecturas de aprendizaje profundo.

Esta evidencia justifica la progresión metodológica adoptada en el presente trabajo, que parte de modelos estadísticos clásicos y escala hacia técnicas de potenciación del gradiente, en lugar de recurrir directamente a formulaciones de mayor complejidad.

3.2. Modelos clásicos de series temporales

Los modelos estadísticos de series temporales constituyen la referencia frente a la que debe medirse cualquier propuesta alternativa. Su valor en este trabajo es doble: proporcionan una línea base rigurosa y aportan herramientas de diagnóstico —autocorrelación, descomposición estacional— que orientan la construcción de variables en los modelos posteriores.

3.2.1. Modelos ARIMA y SARIMA

La formulación $\text{ARIMA}(p, d, q)$ (Box et al. 2015) modela una serie mediante tres componentes. El término **autorregresivo** de orden p expresa el valor actual como combinación lineal de p valores anteriores; la **integración** de orden d aplica diferenciaciones sucesivas hasta alcanzar la estacionariedad; y el término de **media móvil** de orden q incorpora los q errores de predicción precedentes.

Formalmente, empleando el operador de retardo B :

$$\phi_p(B) (1 - B)^d y_t = \theta_q(B) \varepsilon_t \quad (3.1)$$

donde ϕ_p y θ_q son los polinomios autorregresivo y de media móvil, y ε_t un proceso de ruido blanco.

La extensión estacional SARIMA(p, d, q)(P, D, Q) $_s$ añade componentes análogos sobre el periodo estacional s :

$$\Phi_P(B^s) \phi_p(B) (1 - B^s)^D (1 - B)^d y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t \quad (3.2)$$

Esta formulación presenta una limitación determinante para el problema que nos ocupa: **admite un único periodo estacional**. Una serie horaria de demanda eléctrica exhibe al menos dos —el ciclo diario de veinticuatro horas y el semanal de ciento sesenta y ocho—, y el coste computacional del ajuste crece con el valor de s , lo que hace inviable el tratamiento directo de la estacionalidad semanal.

La solución habitual consiste en representar la estacionalidad mediante términos de Fourier introducidos como regresores externos, reservando la parte ARIMA para la autocorrelación de corto plazo (Hyndman y Athanasopoulos 2021). Este enfoque admite varios periodos simultáneos y reduce drásticamente el coste de estimación.

3.2.2. Prophet

Prophet (Taylor y Letham 2018) adopta una aproximación distinta: descompone la serie de forma aditiva en tres componentes interpretables,

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (3.3)$$

donde $g(t)$ representa la tendencia —lineal por tramos con puntos de cambio detectados automáticamente—, $s(t)$ la estacionalidad modelada mediante series de Fourier, $h(t)$ el efecto de las festividades y ε_t el término de error.

Sus ventajas para este dominio son la admisión nativa de estacionalidades múltiples y la incorporación explícita de un calendario de festivos, con ventanas configurables para recoger el efecto de arrastre sobre vísperas y días posteriores. Como contrapartida, al no modelar la autocorrelación de los residuos, tiende a desaprovechar la fuerte inercia de corto plazo característica de las series de demanda.

3.2.3. Análisis espectral y series de Fourier

El análisis espectral permite identificar los periodos dominantes de una serie de manera objetiva, sin presuponerlos a partir del conocimiento del dominio. La transformada discreta de Fourier descompone la señal en componentes sinusoidales,

$$X_k = \sum_{n=0}^{N-1} x_n e^{-i2\pi kn/N} \quad (3.4)$$

y el periodograma $|X_k|^2$ revela la potencia asociada a cada frecuencia. Los máximos locales identifican los ciclos presentes en los datos.

Su utilidad en este trabajo es doble. Por una parte, fundamenta empíricamente la selección de los desfases temporales empleados como variables predictoras. Por otra, permite representar la estacionalidad mediante pares seno-coseno en los modelos que no la admiten de forma nativa.

3.3. Aprendizaje automático aplicado a series temporales

La aplicación de algoritmos de aprendizaje automático a series temporales exige una reformulación previa del problema. Mientras los modelos estadísticos operan directamente sobre la secuencia, los algoritmos de regresión requieren una matriz de observaciones independientes. La transformación consiste en construir, para cada instante, un vector de características que recoja la información disponible hasta ese momento.

Esta reformulación introduce dos ventajas y un riesgo. Permite incorporar variables exógenas sin restricciones y capturar relaciones no lineales e interacciones entre predictores. Pero expone el procedimiento a la **fuga de información**: si alguna variable incorpora datos posteriores al instante de predicción, las métricas obtenidas serán excelentes e irreproducibles en explotación. La sección 4.4.3 aborda esta cuestión de forma específica.

3.3.1. Modelos basados en árboles

Los métodos de conjunto basados en árboles de decisión dominan actualmente las aplicaciones sobre datos tabulares, y las competiciones M han confirmado su superioridad también en predicción de series temporales (Makridakis, Spiliotis y Assimakopoulos 2022).

Random Forest (Breiman 2001) construye múltiples árboles sobre remuestras del conjunto de entrenamiento, aleatorizando además las variables consideradas en cada división, y promedia sus predicciones. La reducción de varianza resultante lo hace robusto frente al sobreajuste, a costa de un sesgo algo mayor.

La **potenciación del gradiente** adopta una estrategia secuencial: cada árbol se ajusta sobre los residuos del conjunto acumulado hasta el momento. Las dos implementaciones de referencia son **XGBoost** (Chen y Guestrin 2016), que incorpora regularización explícita sobre la complejidad del árbol y tratamiento nativo de valores ausentes, y **LightGBM** (Ke et al. 2017), que introduce el crecimiento por hojas y el agrupamiento de características mutuamente excluyentes, con una reducción sustancial del tiempo de entrenamiento.

La principal limitación de estos métodos en el contexto de series temporales es su incapacidad para extrapolar fuera del rango observado, consecuencia directa de que sus

predicciones son promedios de valores del conjunto de entrenamiento. Esta restricción resulta poco problemática en demanda eléctrica, cuya magnitud se mantiene dentro de márgenes estables.

3.3.2. Ingeniería de características temporales

La calidad de las variables construidas determina el rendimiento de estos modelos en mayor medida que la elección del algoritmo. Se distinguen cuatro bloques:

- **Desfases** (lag_k). El valor de la serie k instantes antes. Su selección debe fundamentarse en la estructura de autocorrelación y, sobre todo, respetar la restricción de disponibilidad: para un horizonte de h periodos únicamente son admisibles los desfases de orden $k \geq h$.
- **Estadísticos móviles**. Media y desviación típica sobre ventanas precedentes. Recogen el nivel y la volatilidad recientes. La ventana debe cerrarse antes del instante de predicción.
- **Codificación cíclica**. Las variables de calendario son circulares: la hora 23 es contigua a la hora 0. Su representación como enteros introduce una discontinuidad artificial que se evita mediante pares de funciones trigonométricas.
- **Variables de calendario**. Indicadores de festividad, día laborable y sus entornos. Su relevancia en demanda eléctrica es considerable, como se cuantifica en el capítulo de resultados.

3.4. El mercado eléctrico español y la tarifa PVPC

El mercado diario

La electricidad se negocia en España a través del Operador del Mercado Ibérico de Energía (Operador del Mercado Ibérico de Energía 2025). El mercado diario casa oferta y demanda para cada una de las veinticuatro horas del día siguiente mediante un mecanismo marginalista: todas las ofertas aceptadas perciben el precio de la última unidad necesaria para cubrir la demanda prevista.

De este mecanismo se deriva una consecuencia directa para el presente trabajo: **el precio horario guarda una relación estrecha con la demanda prevista**. Las horas de mayor consumo exigen recurrir a tecnologías de coste marginal superior, lo que eleva el precio de casación. Predecir la demanda equivale, por tanto, a anticipar de forma aproximada el perfil de precios.

La tarifa PVPC

El Precio Voluntario para el Pequeño Consumidor es la tarifa regulada aplicable a suministros de baja tensión con potencia contratada inferior a diez kilovatios. Su característica distintiva es que el término de energía **varía cada hora** en función del resultado del mercado mayorista.

Los precios correspondientes a cada día se publican la víspera, en torno a las 20:15 horas, una vez cerrada la casación del mercado diario. El consumidor acogido a esta modalidad dispone así de información con la que planificar su consumo, si bien limitada al día siguiente.

Implicaciones para el sistema propuesto

De lo anterior se derivan las dos aportaciones que la aplicación desarrollada puede ofrecer sobre la información ya disponible:

1. **Anticipación.** La previsión de demanda está disponible en cualquier momento, mientras que el precio oficial solo se publica a las 20:15 horas de la víspera.
2. **Horizonte extendido.** El mercado publica únicamente el día siguiente; el sistema propuesto alcanza las cuarenta y ocho horas.

Debe precisarse que la aplicación no predice el precio, sino la demanda, y emplea esta última como indicador aproximado de aquel. La relación entre ambas magnitudes es estrecha pero no determinista: la composición del parque generador disponible —singularmente la aportación renovable— introduce una variabilidad que el modelo no contempla. Esta limitación se recoge de forma explícita en la aplicación.

3.5. Trabajos previos relacionados

La revisión de Hong y Fan (2016) constituye la referencia de síntesis más completa sobre predicción de carga eléctrica. Los autores clasifican las aproximaciones existentes, discuten las métricas de evaluación habituales y subrayan una carencia recurrente en la literatura: la ausencia de comparación frente a líneas base ingenuas, lo que dificulta valorar la aportación real de las propuestas. El presente trabajo atiende expresamente esa observación, evaluando tres modelos ingenuos antes de cualquier formulación estadística.

En cuanto a la evidencia comparativa, las competiciones M constituyen el experimento controlado de mayor alcance en el campo. La cuarta edición (Makridakis, Spiliotis y Assimakopoulos 2020) estableció la superioridad de las combinaciones de métodos y del aprendizaje transversal entre series. La quinta (Makridakis, Spiliotis y Assimakopoulos 2022) confirmó el predominio de los métodos de potenciación del gradiente

sobre las arquitecturas de aprendizaje profundo, resultado especialmente relevante para la orientación metodológica adoptada aquí.

Sobre los aspectos de descomposición estacional, el procedimiento STL (Cleveland et al. 1990) constituye la referencia clásica, y su extensión MSTL (Bandara, Hyndman y Bergmeir 2021) permite el tratamiento de estacionalidades múltiples, circunstancia que concurre en las series horarias de demanda.

Finalmente, en el terreno de la interpretabilidad, los valores SHAP (Lundberg y Lee 2017) han desplazado a las medidas de importancia nativas de los modelos de árboles, al proporcionar una descomposición aditiva de cada predicción individual con fundamento en la teoría de juegos cooperativos.

4. Metodología

4.1. Arquitectura del sistema

El sistema se organiza en tres capas desacopladas, según se recoge en la Figura 4.1. Esta separación permite desarrollar y validar cada una de forma independiente, y resulta especialmente conveniente en un trabajo con componente de despliegue: la capa de aplicación puede evolucionar sin afectar al procedimiento de entrenamiento, y viceversa.




Figura 4.1: Arquitectura general del sistema propuesto. El módulo `prediccion.py`, destacado en naranja, es compartido por el procedimiento de entrenamiento y por la aplicación, lo que garantiza que las variables se construyan de forma idéntica en ambos contextos

Capa de datos

Responsable de la obtención, el tratamiento y el almacenamiento de la información. Integra las tres fuentes descritas en la sección anterior mediante llamadas a sus respectivas interfaces de programación, aplica el procedimiento de limpieza e imputación.

tación y persiste el resultado en formato Parquet. Este almacenamiento intermedio evita la dependencia de la red en ejecuciones sucesivas y garantiza la reproducibilidad del análisis.

Capa de modelos

Comprende la construcción de variables, el entrenamiento y la evaluación. Su componente central es el módulo `prediccion.py`, que implementa la generación de características y la función de predicción.

Conviene destacar una decisión de diseño con implicaciones prácticas considerables: **este módulo es compartido por el procedimiento de entrenamiento y por la aplicación**. La alternativa—implementar la construcción de variables por duplicado—expone el sistema al fenómeno conocido como *training/serving skew*: si ambas implementaciones divergen, aunque sea en un detalle menor, el modelo recibe en explotación entradas distintas de aquellas sobre las que fue entrenado, y su rendimiento se degrada sin que ningún procedimiento falle de manera visible. Compartir el código elimina esa posibilidad por construcción.

Capa de aplicación

Comprende la interfaz web, la obtención de datos en tiempo real y la generación de recomendaciones. Se apoya en el modelo serializado que produce la capa anterior y opera de forma autónoma respecto a ella.

Un principio rector de esta capa es la **degradación controlada**: el fallo de una fuente externa no debe interrumpir el servicio. Si la previsión meteorológica no está disponible, se recurre a una estimación climatológica y se advierte de ello al usuario; si falla la consulta de precios, la aplicación continúa operando sin esa información. Únicamente la serie de demanda resulta imprescindible, y su ausencia se comunica mediante un mensaje explícito.

4.2. Adquisición y descripción de los datos

El trabajo se apoya exclusivamente en fuentes de datos abiertas y de acceso gratuito, lo que garantiza la reproducibilidad del estudio. Se han integrado tres orígenes distintos, resumidos en la Tabla 4.1.

Tabla 4.1: Fuentes de datos empleadas

Fuente	Datos	Uso en el proyecto
REE (API REDa-ta)	Demanda eléctrica peninsular horaria	Variable objetivo. Serie principal 2022–2024
AEMET Open-Data	Temperatura media, máxima y mínima diarias	Variables exógenas explicativas
Calendario laboral	Festivos nacionales y de la Comunidad de Madrid	Variables binarias de calendario

4.2.1. Demanda eléctrica

La variable objetivo procede del sistema de información público de Red Eléctrica de España (Red Eléctrica de España 2025). El acceso se realiza mediante la API REDData (`apidatos.ree.es`), que no requiere credenciales de autenticación.

Conviene señalar una particularidad relevante para la reproducibilidad. El *widget* `evolucion` de dicha API no admite agregación horaria y devuelve un error `400 Bad Request` cuando se solicita el parámetro `time_trunc=hour`. La serie horaria debe obtenerse a través del *widget* `demanda-tiempo-real`, cuya resolución nativa es de diez minutos; los valores se reagregan posteriormente a frecuencia horaria mediante la media aritmética de los seis registros de cada hora.

La descarga se ejecuta de forma fraccionada en bloques de pocos días, con reintentos automáticos y un intervalo de espera entre peticiones. El fraccionamiento no obedece únicamente a la cortesía con el servicio: las peticiones que abarcan periodos extensos provocan errores `502 Bad Gateway`, dado que el widget devuelve del orden de ciento cuarenta registros diarios. Los resultados se almacenan localmente en formato Parquet para evitar dependencias de red en ejecuciones posteriores.

4.2.2. Variables meteorológicas

Los datos climatológicos proceden del portal de datos abiertos de la Agencia Estatal de Meteorología (Agencia Estatal de Meteorología 2025), para el que se solicitó una clave de acceso gratuita. La estación de referencia seleccionada es **Madrid-Retiro** (indicativo 3195), por su representatividad respecto al principal núcleo de consumo peninsular y por la continuidad de su serie histórica.

La API de AEMET presenta dos particularidades operativas. En primer lugar, responde mediante un mecanismo de dos peticiones encadenadas: la primera devuelve una URL temporal y la segunda recupera los datos propiamente dichos. En segundo lugar, impone un límite de peticiones por unidad de tiempo, por lo que la descarga se fracciona en tramos e incorpora esperas entre llamadas.

Debe destacarse una limitación de la fuente con implicaciones metodológicas: los valores climatológicos históricos de AEMET tienen **resolución diaria**, mientras que la variable objetivo es horaria. Se ha optado por propagar el valor diario a las veinticuatro horas del día correspondiente. Esta decisión implica renunciar al ciclo térmico intradiario, pero preserva la señal estacional, que es la componente con mayor efecto sobre la demanda agregada. La alternativa —emplear reanálisis ERA5 del programa Copernicus, con temperatura horaria— se descartó por su mayor complejidad de tratamiento y se recoge como línea de trabajo futuro.

4.2.3. Calendario laboral

Los días festivos se obtienen mediante la librería `holidays` de Python, configurada para España con la subdivisión correspondiente a la Comunidad de Madrid. Esta fuente cubre tanto festivos nacionales como autonómicos y no requiere acceso a red.

4.2.4. Delimitación temporal

El periodo de estudio abarca del 1 de enero de 2022 al 31 de diciembre de 2024, lo que supone tres años completos y **26.304 registros horarios** esperados. Esta ventana temporal se considera suficiente para capturar al menos tres ciclos estacionales completos, manteniendo un volumen de datos manejable para el entrenamiento iterativo de los modelos.

4.3. Tratamiento y preprocesado de los datos

El tratamiento de los datos constituye una fase central de este trabajo. Cada decisión adoptada se documenta gráficamente y, cuando procede, se verifica mediante contraste estadístico.

4.3.1. Análisis exploratorio inicial

La Figura 4.2 presenta la serie de demanda en tres escalas temporales. La visualización conjunta permite identificar de forma inmediata la superposición de tres patrones: un ciclo anual con máximos en invierno y verano, un ciclo semanal que diferencia días laborables de fines de semana, y un ciclo diario con doble pico.




Figura 4.2: Demanda eléctrica horaria en tres escalas temporales: serie completa 2022–2024 (superior), detalle mensual (centro) y detalle semanal (inferior)

En el detalle semanal se aprecia con nitidez la estructura del perfil diario: un mínimo en la madrugada, un ascenso pronunciado a partir de las seis de la mañana, un máximo de mediodía y un segundo máximo vespertino, con una reducción apreciable del nivel general durante el fin de semana.

4.3.2. Integridad de la serie y tratamiento de valores ausentes

La comprobación de integridad reveló una circunstancia que condiciona toda la estrategia de imputación. De los 26.304 registros horarios esperados se obtuvieron 26.214, resultando 90 ausencias (un 0,34 % del total). Ahora bien, el recuento de valores nulos sobre la serie descargada era **cero**: las ausencias no figuraban como valores perdidos, sino como **filas inexistentes en el índice temporal**.

Esta distinción no es menor. Los procedimientos habituales de interpolación operan sobre valores nulos dentro de registros existentes, de modo que aplicados directamente sobre esta serie no habrían producido efecto alguno: la verificación posterior habría comparado la serie consigo misma, arrojando un resultado trivialmente favorable y carente de valor. El procedimiento correcto exige **reindexar previamente** la serie sobre una malla horaria completa, materializando así los huecos como valores nulos explícitos, y solo entonces proceder a su imputación.

El inventario de huecos resultante muestra que las 90 ausencias se distribuyen en varios tramos, siendo el mayor de **18 horas consecutivas** correspondiente al 6 de marzo de 2022.

Estrategia de imputación

Se adopta un procedimiento escalonado en función de la longitud del hueco:

1. **Huecos de hasta tres horas** — interpolación temporal lineal. En tramos tan breves la curva de demanda es aproximadamente lineal y el error introducido resulta despreciable.
2. **Huecos superiores a tres horas** — sustitución por el valor registrado en la misma hora de la semana anterior (desplazamiento de 168 horas). Esta elección es deliberada: una interpolación lineal a lo largo de dieciocho horas trazaría una recta a través de un ciclo diario completo, destruyendo precisamente la estructura que el modelo debe aprender a reproducir. El desplazamiento semanal preserva tanto el perfil horario como el efecto del día de la semana.
3. **Casos residuales** — mediana del perfil correspondiente a la combinación mes $\times$ día de la semana $\times$ hora.

La Figura 4.3 muestra la inspección visual del hueco de mayor longitud. El tramo imputado conserva la forma característica del ciclo diario y se integra con continuidad en los valores adyacentes, lo que confirma la idoneidad del procedimiento frente a la alternativa lineal.




Figura 4.3: Inspección del hueco de mayor longitud (18 horas, 6 de marzo de 2022). La franja sombreada corresponde al tramo imputado

Verificación de la distribución

Para comprobar que la imputación no altera la estructura estadística de la serie se comparan las distribuciones antes y después del tratamiento mediante histograma, función de densidad y diagrama de caja (Figura 4.4).




Figura 4.4: Comparativa de la distribución de la demanda antes y después del proceso de imputación

La comparación se complementa con un contraste de Kolmogorov-Smirnov de dos muestras. Dado que el volumen imputado representa un 0,34 % del total, no se rechaza la hipótesis nula de igualdad de distribuciones, lo que permite afirmar que el tratamiento preserva las propiedades estadísticas de la serie original.

4.3.3. Análisis de patrones cíclicos mediante series de Fourier

Con carácter previo al modelado se aplica la transformada rápida de Fourier sobre la serie centrada, con objeto de identificar los periodos dominantes de manera objetiva, sin presuponerlos a partir del conocimiento del dominio.




Figura 4.5: Periodograma de la serie de demanda. Escala logarítmica (superior) y detalle de los ciclos de corto plazo (inferior)

El periodograma (Figura 4.5) presenta picos nítidos y aislados en los periodos recogidos en la Tabla 4.2.

Tabla 4.2: Periodos dominantes identificados mediante análisis espectral

Periodo	Interpretación	Origen del patrón
24 h	Ciclo diario	Alternancia entre actividad diurna y descanso nocturno
12 h	Armónico del diario	Estructura de doble pico (mediodía y tarde)
168 h	Ciclo semanal	Diferencia entre días laborables y fin de semana
≈ 84 h	Semi-semanal	Armónico del ciclo semanal

Este resultado tiene consecuencias directas sobre la sección 4.4: los desfases temporales de 24 y 168 horas incorporados como variables predictoras no responden a una elección arbitraria ni a la costumbre, sino que se derivan de la estructura espectral observada en los propios datos.

4.3.4. Descomposición estacional múltiple

La presencia simultánea de estacionalidad diaria y semanal impide emplear una descomposición STL convencional, que admite un único periodo. Aplicando STL con periodo 24 la componente semanal no puede ser capturada y se acumula íntegramente en el residuo, generando caídas sistemáticas coincidentes con los fines de semana.

Se recurre por tanto a la descomposición MSTL, que admite periodos múltiples y permite separar ambas componentes (Figura 4.6).




Figura 4.6: Descomposición MSTL de la serie con estacionalidad diaria (24 h) y semanal (168 h). El tramo ascendente inicial del panel de tendencia constituye un artefacto de borde del procedimiento, no un fenómeno real

La Figura 4.7 contrasta ambos residuos y evidencia la mejora: la estructura periódica visible en el residuo de STL desaparece al incorporar el periodo semanal.




Figura 4.7: Comparación del residuo obtenido mediante STL (periodo 24 h) y MSTL (periodos 24 h y 168 h)

La intensidad de cada componente se cuantifica mediante la métrica propuesta por Hyndman y Athanasopoulos (2021), definida como $1 - \text{Var}(R_t)/\text{Var}(S_t + R_t)$, donde S_t y R_t denotan respectivamente la componente estacional y el residuo.

4.3.5. Análisis de autocorrelación

Las funciones de autocorrelación simple y parcial (Figura 4.8) confirman por vía complementaria los hallazgos del análisis espectral, y proporcionan además los órdenes candidatos para la especificación de los modelos ARIMA estacionales (Box et al. 2015).




Figura 4.8: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie de demanda

La ACF muestra máximos locales pronunciados en los retardos múltiplos de 24 horas, con un valor próximo a 0,78 en el retardo 24 y una recurrencia de igual magnitud en el retardo 168, lo que refleja la persistencia conjunta de ambos ciclos.

4.3.6. Identificación de anomalías

La aplicación de la regla del rango intercuartílico sobre la serie completa resultó infructuosa: no identificó ningún valor atípico, con límites situados aproximadamente en 14.000 y 42.000 MW que la serie no alcanza en ningún momento. El motivo es que la propia variación estacional ensancha el rango intercuartílico hasta privarlo de capacidad discriminante. Un consumo de 22.000 MW resulta perfectamente ordinario en la madrugada de un domingo de agosto y marcadamente anómalo un martes de enero a las veinte horas, distinción que una regla global no puede establecer.

Se adopta en consecuencia un procedimiento condicionado al contexto temporal:

1. Se estima el **valor esperado** de cada hora como la mediana del conjunto de observaciones que comparten mes, día de la semana y hora. La mediana se prefiere a la media por su robustez frente a los propios valores extremos que se pretende detectar.
2. Se calcula el **residuo** como diferencia entre el valor observado y el esperado.
3. Se aplica un **z-score robusto** sobre dicho residuo, empleando la mediana y la desviación absoluta mediana (MAD) en lugar de la media y la desviación típica. Se consideran anómalas las observaciones cuyo valor absoluto supera un umbral de 4.

Este procedimiento identifica 555 horas anómalas, equivalentes al 2,11 % de la serie, frente a las cero detectadas por la regla del rango intercuartílico.

Clasificación de las anomalías

Dado que el perfil esperado se construye sobre la agrupación mes $\times$ día de la semana $\times$ hora, los días festivos no quedan recogidos en la línea base y se manifiestan como desviaciones de gran magnitud. Lejos de constituir una deficiencia del procedimiento, esta circunstancia proporciona una medida directa del efecto del calendario sobre la demanda.




Figura 4.9: Anomalías clasificadas según su origen (superior) y distribución del residuo asociado a cada categoría (inferior)

Tabla 4.3: Distribución de las anomalías detectadas según su origen

Origen	Horas	% del total
Festivo	347	62,5
Víspera de festivo	23	4,1
Día posterior a festivo	18	3,2
Fin de semana	31	5,6
Sin explicación de calendario	136	24,5

Los resultados de la Tabla 4.3 son concluyentes: un 69,8 % de las anomalías se concentra en días festivos o en su entorno inmediato. El residuo mediano de la categoría *Festivo* se sitúa en torno a $-7,000$ MW, con casos que alcanzan los $-15,500$ MW. Sobre un nivel esperado próximo a 28.000 MW, ello representa una reducción cercana al 25 %.

Esta evidencia cuantitativa justifica la incorporación de variables de calendario al conjunto de predictores: ningún modelo que las omita puede reproducir desviaciones de tal magnitud.

Las 136 anomalías no atribuibles al calendario presentan, por el contrario, un residuo mediano *positivo* y se concentran en los meses estivales, lo que sugiere su asociación con episodios de temperatura extrema. Su análisis individualizado se aborda en el capítulo de resultados.

Criterio de conservación

Ninguna de las observaciones identificadas ha sido eliminada del conjunto de datos. Se trata de comportamiento real del sistema eléctrico —festivos, olas de calor, episodios meteorológicos adversos— y constituye precisamente el tipo de situación que el modelo debe aprender a anticipar. La detección se emplea con finalidad analítica y explicativa, no depurativa.

4.3.7. Relación entre demanda y temperatura

El análisis de la relación entre demanda diaria media y temperatura (Figura 4.10) arroja un resultado de especial relevancia para la especificación del modelo.




Figura 4.10: Relación entre demanda diaria media y temperatura media, con ajuste cuadrático superpuesto (izquierda) y matriz de correlaciones lineales (derecha)

El coeficiente de correlación lineal entre demanda y temperatura media es de **0,089**, valor prácticamente nulo que podría inducir erróneamente a descartar la temperatura como variable explicativa. La representación gráfica revela sin embargo una dependencia clara, de naturaleza **cuadrática**: la demanda aumenta tanto con temperaturas bajas, por efecto de la calefacción, como con temperaturas elevadas, por efecto de la refrigeración, alcanzando su mínimo en el entorno de los 16–17 °C.

Se trata de un caso paradigmático de relación no lineal para la que el coeficiente de correlación de Pearson carece de capacidad descriptiva. Este hallazgo motiva directamente la construcción de los términos cuadráticos y de grados-día descritos en la sección siguiente.

4.3.8. Perfiles de consumo

Los perfiles agregados (Figura 4.11) sintetizan la estructura temporal de la demanda y resultan coherentes con el comportamiento documentado para el sistema peninsular español.




Figura 4.11: Perfiles de consumo: perfil horario por día de la semana, distribución mensual, comparación entre días laborables y no laborables, y mapa de calor hora $\times$ mes

El mapa de calor resulta particularmente ilustrativo, al mostrar el carácter dual del consumo español: máximo vespertino en los meses invernales, asociado a iluminación y calefacción, y máximo de mediodía en julio y agosto, atribuible a la refrigeración.

4.4. Ingeniería de características

Las variables predictoras no se han seleccionado por convención, sino que se derivan de los hallazgos del análisis exploratorio expuestos en la sección anterior. La Tabla 4.4 recoge el conjunto construido junto con la justificación empírica de cada bloque.

Tabla 4.4: Variables predictoras construidas y su justificación

Bloque	Variables	Justificación
Desfases temporales	lag_1h, lag_2h, lag_3h, lag_24h, lag_25h, lag_48h, lag_168h	Periodos dominantes identificados mediante análisis de Fourier (Tabla 4.2) y confirmados por la ACF
Estadísticos móviles	media_24h, std_24h, media_168h, std_168h	Recogen el nivel y la variabilidad reciente sobre las mismas ventanas temporales
Codificación cíclica	hora_sin, hora_cos, dia_sem_sin, dia_sem_cos, mes_sin, mes_cos	Preservan la continuidad circular del tiempo, evitando la discontinuidad artificial entre las 23 y las 0 horas
Calendario	festivo, vispera_festivo, post_festivo, finde, laborable	El 69,8 % de las anomalías detectadas se concentra en festivos y su entorno (Tabla 4.3)
Temperatura	tmed, tmax, tmin, tmed_sq, grados_frio, grados_calor	La relación con la demanda es cuadrática, no lineal (Figura 4.10)

4.4.1. Codificación cíclica de las variables temporales

Las variables de calendario presentan naturaleza circular: la hora 23 es adyacente a la hora 0, y el mes de diciembre al de enero. Su codificación como enteros introduciría una discontinuidad artificial en dicha transición. Se recurre por ello a una representación mediante pares de funciones trigonométricas:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right) \quad (4.1)$$

donde t denota el valor de la variable y T su periodo (24 para la hora, 7 para el día de la semana y 12 para el mes). De este modo, valores temporalmente próximos resultan también próximos en el espacio de características.

4.4.2. Términos de temperatura

Dado el carácter cuadrático de la relación entre demanda y temperatura, se incorporan tres transformaciones adicionales. La primera es el término cuadrático t_{med}^2 . Las dos restantes corresponden a los conceptos de grados-día de calefacción y refrigeración, de uso habitual en el análisis energético (Hong y Fan 2016):

$$\text{GD}_{\text{frío}} = \text{máx}(0, 18 - t_{\text{med}}), \quad \text{GD}_{\text{calor}} = \text{máx}(0, t_{\text{med}} - 22) \quad (4.2)$$

Estas variables permiten a los modelos lineales capturar la forma en U de la relación,

que de otro modo quedaría fuera de su alcance.

4.4.3. Prevención de fuga de información

La construcción de variables a partir de la propia serie objetivo expone el procedimiento a la fuga de información, que constituye el riesgo metodológico principal en la aplicación de aprendizaje automático a series temporales.

Formulación del problema

Para un horizonte de veinticuatro horas, la predicción del instante $t + 24$ debe elaborarse desde el instante t . En ese momento, la disponibilidad efectiva de cada variable es la que recoge la Tabla 4.5.

Tabla 4.5: Disponibilidad de las variables en el instante de predicción

Variable en $t + 24$	Equivale a	¿Conocida en t ?
lag_1h	y_{t+23}	No
lag_2h	y_{t+22}	No
lag_3h	y_{t+21}	No
lag_24h	y_t	Sí
lag_168h	y_{t-144}	Sí
media_24h	media de $t \dots t + 23$	No
media_168h	ventana que alcanza $t + 23$	No
Calendario y meteorología	conocidos de antemano	Sí

Merece atención el caso de los estadísticos móviles. Su construcción en el análisis exploratorio empleó un desplazamiento de una posición, adecuado para predicción a un paso. Para un horizonte de veinticuatro horas, sin embargo, la ventana de `media_24h` en el instante $t + 24$ abarca de t a $t + 23$, tramo en su mayor parte desconocido. **La contaminación no se limita por tanto a los desfases de orden reducido**, extremo que no resulta evidente a simple vista.

Criterio adoptado

Se establece la regla siguiente: para un horizonte de h periodos únicamente son admisibles los desfases de orden $k \geq h$ y los estadísticos móviles cuya ventana se cierre antes del instante de predicción. En consecuencia:

- Se descartan `lag_1h`, `lag_2h` y `lag_3h`.
- Se descartan los estadísticos móviles del análisis exploratorio y se recalculan desplazando la serie el horizonte completo.
- Se conservan los desfases de 24, 25, 48 y 168 horas, así como las variables de calendario y meteorológicas.

Cuantificación del efecto

El efecto de la fuga no se ha asumido, sino medido. Entrenando el mismo modelo con ambos conjuntos de variables sobre idénticos orígenes de validación se obtiene que **la inclusión de las variables contaminadas reduce el error aparente en un 59 %**.

Dicho de otro modo: un modelo que incorporase los desfases de orden reducido aparentaría un rendimiento sustancialmente superior al que alcanzaría en explotación, donde esas variables sencillamente no están disponibles. La magnitud del efecto justifica el tratamiento explícito que recibe esta cuestión.

4.5. Estrategia de validación

Improcedencia de la validación cruzada aleatoria

La validación cruzada por particiones aleatorias, procedimiento estándar en aprendizaje supervisado, resulta **metodológicamente inadmisibile** en series temporales. Al asignar observaciones a los conjuntos de entrenamiento y prueba sin atender a su orden, el modelo se entrena con datos posteriores a aquellos que debe predecir. Las métricas resultantes son optimistas y carecen de correspondencia con el comportamiento en explotación.

Validación de origen rodante

Se adopta en su lugar la validación de origen rodante (*rolling origin* o *walk-forward*). El procedimiento fija un instante de corte, entrena con la totalidad de las observaciones anteriores, predice las veinticuatro horas siguientes y repite la operación desplazando el corte:

```
Origen 1:  [----- entrenamiento -----] [test]
Origen 2:  [----- entrenamiento -----] [test]
Origen 3:  [----- entrenamiento -----] [test]
```

Este esquema reproduce las condiciones de explotación: en cada origen el modelo dispone exclusivamente de información anterior al instante de predicción.

Elección del paso entre orígenes

La separación entre orígenes exige una precaución que no siempre se explicita en la literatura. Una primera configuración empleó un paso de ciento sesenta y ocho horas —exactamente una semana— con el propósito de cubrir un periodo amplio. El resultado

fue que **los catorce orígenes recayeron sobre el mismo día de la semana**, de modo que la evaluación excluía por completo sábados y domingos.

El sesgo introducido no era neutral. Beneficiaba específicamente a los modelos que predicen a partir del día anterior, pues todos los días evaluados eran laborables precedidos de laborables. Detectada la anomalía, se sustituyó el paso por ciento veinte horas —cinco días—, valor que no es múltiplo de la semana y que con catorce orígenes proporciona exactamente dos observaciones de cada día. Al repetir la evaluación, el error del modelo ingenuo diario se elevó de forma apreciable, lo que confirmó el diagnóstico.

La configuración definitiva es por tanto:

- Horizonte de predicción: 24 horas
- Número de orígenes: 14
- Separación entre orígenes: 120 horas (5 días)
- Periodo cubierto: aproximadamente 70 días

Evaluación complementaria en días festivos

El esquema anterior distribuye los orígenes de forma regular, por lo que la coincidencia con un día festivo queda librada al azar. En la evaluación realizada ningún origen recayó sobre una festividad, circunstancia que habría dejado sin contrastar el hallazgo principal del análisis exploratorio.

Se construyó en consecuencia un conjunto de evaluación **dirigido**, seleccionando ocho orígenes de modo que el día completo a predecir fuese festivo. Este conjunto está deliberadamente sesgado hacia casos difíciles y no representa el rendimiento medio del sistema; se reporta como análisis complementario en la sección 5.5.

4.6. Modelos desarrollados

Se han evaluado diez formulaciones, organizadas en tres niveles de complejidad creciente. Todas comparten el mismo esquema de validación, los mismos orígenes y las mismas métricas, de modo que la comparación resulta homogénea.

4.6.1. Línea base

Modelos ingenuos

Antes de cualquier formulación estadística se establece el error que se obtiene sin modelo alguno. Se consideran tres alternativas:

1. **Ingenuo diario**: la demanda de cada hora del día siguiente coincide con la observada a esa misma hora del día actual.

2. **Ingenuo semanal:** coincide con la del mismo día de la semana anterior. A diferencia del anterior, recoge el efecto laborable/festivo.
3. **Perfil semanal:** media por hora del día sobre las cuatro últimas semanas.

La inclusión de estas referencias responde a una observación recurrente en la literatura (Hong y Fan 2016): un número considerable de trabajos publicados presenta mejoras que en realidad no superan la predicción ingenua estacional.

Modelos estadísticos clásicos

SARIMA. Se ajusta un modelo SARIMA(2, 0, 1)(1, 1, 1)₂₄, con órdenes orientados por las funciones de autocorrelación. El elevado coste computacional del ajuste con periodo estacional 24 obliga a restringir el entrenamiento a una ventana de sesenta días.

SARIMAX con términos de Fourier. Alternativa que representa las estacionalidades diaria, semanal y anual mediante pares seno-coseno introducidos como regresores externos, reservando la parte ARIMA para la autocorrelación de corto plazo. La comparación de tiempos de ajuste justifica empíricamente esta elección: mientras el SARIMA clásico requiere del orden de minutos sobre una ventana reducida, la formulación con Fourier procesa la serie completa en segundos.

Una primera especificación de este modelo empleó $d = 0$ sin término constante. La inspección de los resultados reveló un sesgo sistemático —subestimación en los periodos de demanda elevada y sobrestimación en los de demanda reducida— característico de la reversión a la media del conjunto de entrenamiento. La corrección consistió en aplicar una diferenciación de primer orden, con lo que el modelo opera sobre incrementos y se adapta al nivel local.

Prophet. Se configura con estacionalidad diaria, semanal y anual, e incorpora el calendario de festivos con ventanas de un día a cada lado para recoger el efecto de arrastre.

4.6.2. Modelos de aprendizaje automático

Se evalúan cuatro formulaciones sobre el conjunto de variables descrito en la sección 4.4:

- **Ridge.** Regresión lineal con regularización L_2 , precedida de estandarización. Actúa como referencia lineal y permite aislar la aportación de la no linealidad.
- **Random Forest** (Breiman 2001). Cien árboles, profundidad máxima doce y diez observaciones mínimas por hoja. La configuración es deliberadamente contenida: el procedimiento de validación exige catorce reentrenamientos sobre más de veinte mil observaciones, y una parametrización más ambiciosa resultaba impracticable.

- **XGBoost** (Chen y Guestrin 2016). Cuatrocientos árboles, tasa de aprendizaje 0,05, profundidad máxima siete, submuestreo de observaciones y variables al 80 %.
- **LightGBM** (Ke et al. 2017). Parámetros equivalentes, con cuarenta y ocho hojas por árbol.

4.6.3. Sobre la optimización de hiperparámetros

No se ha realizado una búsqueda sistemática de hiperparámetros. La decisión es deliberada y se fundamenta en dos consideraciones.

En primer lugar, los resultados obtenidos con configuraciones convencionales superan holgadamente los umbrales fijados en los objetivos del trabajo, por lo que el margen de mejora esperable no justifica el coste computacional de una búsqueda exhaustiva.

En segundo lugar, y con mayor peso, la evidencia acumulada en las competiciones M (Makridakis, Spiliotis y Assimakopoulos 2022) indica que la calidad de las variables construidas determina el rendimiento en mayor medida que el ajuste fino de los hiperparámetros. El esfuerzo se ha concentrado en consecuencia sobre la ingeniería de características, guiada por el análisis exploratorio.

La optimización mediante Optuna se recoge como línea de trabajo futuro.

4.7. Métricas de evaluación

Se emplean cuatro métricas complementarias, ninguna de las cuales resulta suficiente por sí sola.

El **error absoluto medio** expresa la desviación en megavatios y resulta directamente interpretable, si bien depende de la escala:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.3)$$

La **raíz del error cuadrático medio** penaliza en mayor medida las desviaciones grandes, lo que la hace sensible a los valores extremos:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.4)$$

El **error porcentual absoluto medio** es adimensional y constituye la referencia habitual en la literatura sobre predicción de carga, lo que permite contrastar los resultados con los trabajos publicados:

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (4.5)$$

El **error porcentual absoluto medio simétrico** corrige la asimetría del anterior frente a sobrestimaciones e infraestimaciones:

$$\text{sMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{2 |y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \quad (4.6)$$

Media y mediana

Las métricas se calculan sobre cada uno de los catorce orígenes y se resumen mediante media y mediana. La distinción no es accesorio: un único día atípico —una festividad, un episodio meteorológico extremo— puede duplicar la media sin que ello refleje el comportamiento habitual del modelo.

Se reportan por tanto ambos estadísticos, junto con la desviación típica entre orígenes y el peor caso observado. La mediana constituye el criterio principal de ordenación, por su robustez frente a valores extremos.

Métricas de entrenamiento y de producción

Siguiendo la indicación expresa de la dirección del trabajo, se registran conjuntamente el error dentro de muestra —sobre las observaciones de entrenamiento— y fuera de muestra —sobre las predicciones efectivas—. Una diferencia sustancial entre ambos indica que el modelo memoriza en lugar de generalizar.

Debe precisarse un matiz relativo a los modelos estadísticos: en ellos el ajuste dentro de muestra corresponde a una predicción de un paso adelante, mientras que la evaluación se realiza a veinticuatro pasos. La comparación resulta en consecuencia poco informativa. En los modelos de aprendizaje automático, en cambio, ambos errores se calculan sobre el mismo horizonte y la diferencia sí es interpretable.

4.8. Desarrollo de la aplicación web

Diseño funcional

La aplicación se dirige a un usuario sin formación técnica en el ámbito energético. Su función es traducir la predicción numérica en una recomendación comprensible. Se estructura en cinco bloques:

1. **Indicadores de situación:** demanda actual, máximo y mínimo previstos, y franja horaria más favorable.

2. **Recomendación en lenguaje natural**, generada automáticamente a partir de la predicción.
3. **Representación gráfica** de la serie histórica y la previsión, con las franjas recomendadas destacadas.
4. **Tabla de horas** ordenada por demanda prevista, con el precio de mercado cuando está disponible.
5. **Contexto meteorológico** y nota metodológica sobre el modelo y sus limitaciones.

Tecnologías empleadas

La interfaz se ha desarrollado con Streamlit (Streamlit Inc. 2025), entorno que permite construir aplicaciones de datos en Python sin requerir desarrollo específico de interfaz. Las representaciones gráficas emplean Plotly, y el modelo se serializa mediante joblib.

Obtención de datos en tiempo real

La aplicación consulta tres fuentes en cada ejecución. La demanda reciente se obtiene de la interfaz REData, en bloques de cinco días: las peticiones de mayor amplitud provocan errores de servidor, dado que el servicio publica con resolución de diez minutos. La previsión meteorológica procede del servicio de predicción horaria municipal de AEMET, con horizonte de cuarenta y ocho horas. El precio de mercado se recupera igualmente de REData, con carácter complementario.

Predicción más allá del horizonte nativo

El modelo se ha entrenado para un horizonte de veinticuatro horas, límite impuesto por la disponibilidad de los desfases: predecir el instante $t + 25$ requeriría conocer $t + 1$, aún no observado.

Para alcanzar las cuarenta y ocho horas se aplica un **esquema recursivo**: las predicciones del primer tramo se incorporan a la serie y se emplean para calcular los desfases del segundo. El procedimiento acumula error, circunstancia que se cuantifica en el capítulo de resultados y de la que se advierte al usuario en la propia interfaz.

Estrategia de despliegue

La aplicación se despliega en Streamlit Community Cloud, servicio gratuito integrado con el repositorio de código. El modelo serializado se versiona junto con el resto

del proyecto, mientras que las credenciales de AEMET se gestionan mediante variables de entorno y quedan excluidas del control de versiones.

5. Discusión

5.1. Resultados del análisis exploratorio

El análisis exploratorio ha permitido caracterizar la serie de demanda y, sobre todo, fundamentar empíricamente las decisiones de modelado. Se sintetizan a continuación los hallazgos de mayor relevancia.

5.1.1. Calidad de la fuente de datos

La serie descargada presenta una completitud del 99,66 %, con 90 registros ausentes sobre 26.304 esperados. Dichas ausencias se concentran en unos pocos tramos, el mayor de dieciocho horas, lo que apunta a incidencias puntuales del sistema de publicación y no a un problema sistemático de la fuente. No se ha detectado ningún valor físicamente inconsistente.

5.1.2. Estructura temporal

El análisis espectral confirma la existencia de tres escalas de periodicidad —diaria, semanal y anual— y de un armónico de doce horas correspondiente a la estructura de doble pico. La descomposición MSTL cuantifica la intensidad de cada componente y muestra que la estacionalidad diaria es la dominante.

Este resultado tiene implicaciones prácticas: cualquier modelo que aspire a un rendimiento competitivo deberá incorporar explícitamente ambas periodicidades, bien mediante términos estacionales en el caso de las formulaciones ARIMA, bien mediante desfases temporales en los modelos de aprendizaje automático.

5.1.3. Efecto del calendario

El resultado de mayor valor para la fase de modelado procede de la clasificación de anomalías. Casi el 70 % de las desviaciones significativas respecto al perfil esperado se explica por el calendario, con un efecto mediano en los días festivos próximo a los $-7,000$ MW.

La magnitud del efecto convierte la inclusión de variables de calendario en un requisito y no en una opción: se trata de la mayor fuente identificada de variación no capturada por la estructura cíclica ordinaria.

5.1.4. Relación con la temperatura

El coeficiente de correlación lineal entre demanda y temperatura, de 0,089, resulta engañoso si se interpreta aisladamente. La inspección gráfica revela una dependencia cuadrática nítida con mínimo en torno a los 16–17 °C, coherente con la superposición de las demandas de calefacción y refrigeración.

Este hallazgo condiciona la selección de modelos. Las formulaciones lineales requieren la incorporación explícita de términos cuadráticos o de grados-día para aprovechar la información térmica, mientras que los modelos basados en árboles de decisión pueden capturar la no linealidad de forma automática, lo que anticipa una ventaja de estos últimos en el presente problema.

5.2. Comparativa de rendimiento de los modelos

La Tabla 5.1 recoge el rendimiento de las diez formulaciones evaluadas, ordenadas por error mediano. Todas comparten los mismos catorce orígenes de validación, el mismo horizonte y las mismas métricas.

Tabla 5.1: Comparativa de rendimiento de los modelos evaluados

Modelo	MAPE medio	MAPE mediana	Desv. típica	Peor caso	MAE (MW)	Frente al ingenuo
<i>Aprendizaje automático</i>						
XGBoost	1,65	1,34	0,70	3,10	470	+56,2 %
Random Forest	1,86	1,47	0,98	3,98	520	+51,9 %
LightGBM	1,67	1,53	0,75	3,71	473	+50,0 %
Ridge	2,55	1,94	1,56	6,22	717	+36,6 %
<i>Línea base estadística</i>						
SARIMA clásico	3,95	2,42	2,98	10,29	1.120	+20,9 %
Prophet	4,86	4,78	1,28	7,34	1.370	−56,4 %
SARIMAX + Fourier	5,66	4,90	3,18	13,02	1.565	−60,3 %
<i>Modelos ingenuos</i>						
Ingenuo semanal	3,92	3,06	2,64	10,35	1.108	referencia
Ingenuo diario	4,98	3,21	4,57	15,36	1.387	−4,9 %
Perfil semanal	8,54	8,30	3,33	13,60	2.434	−171,2 %

Resultado principal

El modelo XGBoost alcanza un error mediano del **1,34 %**, lo que supone una mejora del **56,2 %** sobre la mejor línea base ingenua. En términos absolutos, el error absoluto medio de 470 MW representa un 1,7 % sobre una demanda media de 28.263 MW.

Ambas cifras superan holgadamente los umbrales establecidos en los objetivos del trabajo —MAPE inferior al 8 % y MAE por debajo del 5 % del consumo medio— y se sitúan en el orden de magnitud que maneja el propio operador del sistema en sus

previsiones a día vista.

Los modelos estadísticos no superan la línea base

Un resultado que merece reportarse con la misma claridad es que **Prophet y SARIMAX con términos de Fourier obtienen peores resultados que la predicción ingenua semanal**. Únicamente el SARIMA clásico logra superarla, con una mejora del 20,9 %.

Este hallazgo no constituye una anomalía. La predicción ingenua estacional es una referencia exigente en demanda eléctrica, precisamente porque la serie presenta una estructura semanal muy marcada. La observación de Hong y Fan (2016) sobre la ausencia habitual de comparación con líneas base cobra aquí pleno sentido: un trabajo que hubiese omitido estos modelos ingenuos habría presentado a Prophet como una aportación valiosa cuando en realidad no mejora la alternativa trivial.

En el caso de SARIMAX, el análisis por origen revela que sus dos peores resultados corresponden a domingos. La causa es identificable: con dos armónicos para el periodo de ciento sesenta y ocho horas, la forma semanal representable es una senoide suave, incapaz de reproducir la transición abrupta entre días laborables y fin de semana.

Estabilidad frente a precisión

La columna de desviación típica introduce un matiz relevante. El modelo ingenuo diario presenta una mediana aceptable (3,21 %) pero la mayor dispersión de todo el conjunto (4,57), con un peor caso del 15,36 %. El análisis por origen muestra que sus fallos se concentran en los lunes, con errores del 15,36 % y el 13,94 %, frente a valores próximos al 2 % en el resto. La explicación es inmediata: predice el lunes a partir del domingo.

Se trata de un modelo que funciona razonablemente bien la mayor parte del tiempo y falla de forma severa en circunstancias identificables. En un contexto de explotación, esa característica resulta más problemática que un error medio ligeramente superior pero estable.

El contraste con Prophet ilustra el compromiso. Prophet obtiene el peor error mediano de las formulaciones estadísticas (4,78 %), pero la menor desviación típica con diferencia (1,28): nunca destaca y nunca falla estrepitosamente.

Control del sobreajuste

La Tabla 5.2 recoge la comparación entre el error de entrenamiento y el de producción para los modelos de aprendizaje automático, donde ambos se calculan sobre el mismo horizonte y la comparación resulta por tanto interpretable.

Tabla 5.2: Error de entrenamiento frente a error de producción

Modelo	Entrenamiento	Producción	Diferencia
XGBoost	0,67 %	1,65 %	+146 %
LightGBM	0,83 %	1,67 %	+101 %
Random Forest	1,38 %	1,86 %	+35 %
Ridge	2,99 %	2,55 %	−15 %

XGBoost presenta la mayor diferencia relativa, consecuencia esperable de su configuración con cuatrocientos árboles de profundidad siete. Random Forest exhibe la menor, coherente con su parametrización más restrictiva —profundidad doce y diez observaciones mínimas por hoja—, que penaliza la precisión a cambio de una mayor capacidad de generalización.

El dato de Ridge requiere interpretación específica: su error de producción es **inferior** al de entrenamiento. Ello no responde a ninguna singularidad del modelo, sino a que **el periodo de evaluación resulta más benigno que la media del histórico de entrenamiento**. Las catorce ventanas se sitúan entre octubre y diciembre de 2024, tramo relativamente estable, mientras que el entrenamiento abarca tres años que incluyen la volatilidad de 2022.

La implicación afecta a la lectura del resto de la tabla: si el conjunto de evaluación es más favorable que la media, las diferencias de los modelos de árboles están **infravaloradas**. En un periodo de mayor variabilidad cabría esperar una separación superior. Esta circunstancia se recoge entre las limitaciones del trabajo.

Selección del modelo

XGBoost obtiene el mejor resultado en error mediano, en error absoluto medio y en la evaluación sobre días festivos, por lo que se selecciona como modelo definitivo.

Conviene no obstante dejar constancia de que LightGBM constituye una alternativa defendible: su rendimiento en producción es prácticamente equivalente (1,67 % frente a 1,65 % de error medio), presenta la mitad de diferencia entre entrenamiento y producción, y su tiempo de ajuste es sensiblemente menor. En un escenario que exigiese reentrenamiento frecuente, esas propiedades podrían inclinar la elección.

5.3. Análisis de la importancia de variables




Figura 5.1: Importancia de las variables en el modelo seleccionado

El análisis de importancia responde al objetivo específico OE6, relativo a la identificación de los factores con mayor influencia sobre la demanda.

Valores SHAP

La importancia nativa de los modelos de árboles indica con qué frecuencia se emplea cada variable, pero no en qué dirección ni bajo qué condiciones. Los valores SHAP (Lundberg y Lee 2017) descomponen cada predicción individual en la contribución aditiva de cada predictor, lo que permite un análisis más matizado.




Figura 5.2: Valores SHAP del modelo seleccionado

5.4. Análisis de errores

Las métricas agregadas ocultan la distribución del error. Esta sección examina dónde falla el modelo, con especial atención a si corrige las deficiencias detectadas en la línea base.

Error según el tipo de día

La Tabla 5.3 recoge el error desagregado entre días laborables y fines de semana.

Tabla 5.3: Error según el tipo de día (modelos de aprendizaje automático)

Modelo	Laborable	Fin de semana	Diferencia
XGBoost	1,53 %	1,87 %	0,34
LightGBM	1,47 %	1,99 %	0,52
Random Forest	1,67 %	2,55 %	0,88
Ridge	2,47 %	2,76 %	0,29

La diferencia entre ambos tipos de día resulta reducida en los modelos de potencia-

ción del gradiente, lo que indica que las variables de calendario cumplen su función.

Corrección de las deficiencias de la línea base

El análisis por origen de la fase anterior había identificado dos patrones de fallo: el modelo ingenuo diario se degradaba los lunes y SARIMAX los domingos. La Tabla 5.4 compara el comportamiento en esos mismos orígenes.

Tabla 5.4: Error en los orígenes problemáticos de la línea base

Origen	Modelo deficiente	Línea base	XGBoost
Lunes 28-oct	Ingenuo diario	15,36 %	2,75 %
Lunes 2-dic	Ingenuo diario	13,94 %	1,48 %
Domingo 17-nov	SARIMAX	11,18 %	1,08 %
Domingo 22-dic	SARIMAX	13,02 %	1,24 %
Viernes 27-dic	Ingenuo semanal	10,35 %	2,01 %

La corrección es sistemática y de magnitud considerable. Confirma la hipótesis formulada al analizar la línea base: los fallos identificados obedecían a la ausencia de información de calendario, y los modelos que la incorporan los resuelven.

Comportamiento lineal frente a no lineal

Un resultado con valor explicativo se obtiene al comparar Ridge con los modelos de árboles en esos mismos orígenes. Ridge mantiene errores del 6,30 % y el 5,10 % en los lunes problemáticos, y del 4,06 % en uno de los domingos, mientras las tres formulaciones basadas en árboles se sitúan por debajo del 3 %.

La circunstancia resulta ilustrativa porque **Ridge dispone exactamente de las mismas variables**, incluida la indicadora de día laborable. Su limitación es estructural: al ser lineal, únicamente puede sumar un efecto constante asociado al tipo de día, sin capturar que **dicho efecto depende de la hora**. Un lunes a las cuatro de la madrugada se asemeja considerablemente a un domingo, mientras que a las nueve de la mañana la diferencia es máxima. Esa interacción entre hora y día de la semana solo la reproducen los modelos capaces de representar relaciones no lineales.

Distribución del error a lo largo del día

El error presenta un mínimo en torno a las cinco de la madrugada (0,96 %) y un máximo a las diecisiete horas (2,63 %). El patrón es coherente con la estructura del problema: las horas de rampa —el ascenso matinal y el pico vespertino— concentran la mayor incertidumbre, mientras que el valle nocturno resulta altamente predecible.

Calidad global del ajuste

El coeficiente de correlación entre valores observados y predichos alcanza 0,9931, con un error máximo de 1.948 MW sobre una demanda media de 28.263 MW. El sesgo medio es de -204 MW, lo que indica una ligera tendencia a la infraestimación sin relevancia práctica.

5.5. Evaluación en días festivos

El análisis exploratorio estableció que cerca del 70 % de las anomalías se concentraba en días festivos, y sobre esa base se incorporaron las variables de calendario. Procede verificar de forma explícita que dichas variables cumplen su cometido, para lo cual se emplea el conjunto de evaluación dirigido descrito en la sección 4.5.

Tabla 5.5: Rendimiento en los ocho días festivos evaluados

Modelo	MAPE en festivos	Peor festivo	MAPE ordinario	Penalización
XGBoost	3,32 %	7,02 %	1,65 %	2,01
Random Forest	4,10 %	8,31 %	1,86 %	2,21
Ingenio diario	14,12 %	19,52 %	4,98 %	2,84
Ingenio semanal	16,63 %	40,68 %	3,92 %	4,24

La columna de penalización expresa el cociente entre el error en festivo y el error en día ordinario. Un valor próximo a la unidad indicaría que el modelo aprovecha íntegramente la información de calendario.

El caso más ilustrativo corresponde al 25 de diciembre: el modelo ingenuo semanal alcanza un error del **40,68 %**, frente al **4,74 %** de XGBoost. La diferencia es de casi un orden de magnitud y responde a una causa evidente: el modelo ingenuo compara la Navidad con el miércoles precedente, mientras que el modelo de aprendizaje automático dispone de la indicación de festividad.

Festivos nacionales y autonómicos

Una primera versión de este análisis reveló un patrón inesperado. Los modelos de aprendizaje automático superaban ampliamente a la línea base en los festivos nacionales, pero no en los autonómicos, donde el error resultaba comparable e incluso superior.

La causa admite una explicación precisa. La serie de demanda es **peninsular**, mientras que el calendario empleado correspondía a la **Comunidad de Madrid**. El 2 de mayo, festividad exclusivamente madrileña, el modelo recibía la indicación de festivo y anticipaba una caída pronunciada del consumo; sin embargo, el resto del país mantenía su actividad ordinaria y la demanda apenas descendía.

La solución adoptada sustituye la variable binaria por una **intensidad ponderada por población**: la fracción de habitantes del territorio nacional para los que cada fecha constituye día festivo. Se consulta a tal efecto el calendario de las diecinueve subdivisiones y se pondera por población.

Tabla 5.6: Intensidad de festivo según el alcance territorial

Fecha	Festividad	Comunidades	Intensidad
25 de diciembre	Natividad del Señor	19	1,000
28 de marzo	Jueves Santo	17	0,725
25 de julio	Santiago Apóstol	5	0,271
2 de mayo	Fiesta de la Comunidad de Madrid	1	0,143

Resulta pertinente señalar que una simple distinción binaria entre festivos nacionales y autonómicos tampoco habría resuelto el problema. El Jueves Santo figura como autonómico en las fuentes de calendario, pero afecta en realidad al 72,5 % de la población. La representación mediante una magnitud continua es la única que recoge adecuadamente este matiz.

Efecto de la corrección

El resultado sobre los dos casos problemáticos fue sustancial. El error del 2 de mayo descendió del **10,62 % al 2,14 %**, y el de Santiago Apóstol del 4,28 % al 2,89 %. En términos agregados, el error medio en festivos pasó del 4,81 % al 3,32 %, con una reducción de la penalización de 2,95 a 2,01.

El rendimiento global permaneció prácticamente inalterado, como cabía esperar: las festividades representan alrededor de veinte días al año y su peso sobre la métrica media es reducido. Una corrección que mejora los casos difíciles sin degradar el caso general constituye el resultado deseable.

5.6. Aplicación desarrollada



Figura 5.3: Interfaz de la aplicación web desarrollada parte 1




Figura 5.4: Interfaz de la aplicación web desarrollada parte 2

La aplicación materializa el objetivo específico OE7. Su elemento central es la traducción de la predicción numérica a una recomendación en lenguaje natural, generada automáticamente a partir de las franjas horarias de menor demanda prevista.

Degradación del esquema recursivo

El modelo opera con un horizonte nativo de veinticuatro horas. La extensión a cuarenta y ocho mediante realimentación de las predicciones introduce una acumulación de error que conviene cuantificar.

MAPE horas 1–24: 0.45 MAPE horas 25–48: 0.74

La aplicación advierte de esta circunstancia cuando el usuario selecciona el horizonte extendido.

Comportamiento ante fallos de las fuentes

Durante el desarrollo se constató que la interfaz REData devuelve errores de servidor ante peticiones que abarcan periodos extensos, dado que publica con resolución de diez minutos. La descarga se fragmentó en consecuencia en bloques de cinco días, con tolerancia a fallos parciales: si un bloque concreto no responde, los restantes se procesan y la aplicación advierte de la posible existencia de huecos.

Esta consideración excede el ámbito estrictamente académico, pero resulta determinante para un sistema destinado a funcionar de forma continuada.

6. Conclusiones

6.1. Cumplimiento de los objetivos

Se revisa a continuación el grado de consecución de cada objetivo específico.

OE1 — Análisis del comportamiento histórico. Alcanzado. El análisis exploratorio caracterizó la serie e identificó las tres escalas de periodicidad presentes. El tratamiento de valores ausentes reveló además una circunstancia metodológicamente relevante: las ausencias no figuraban como valores nulos sino como registros inexistentes en el índice temporal, de modo que los procedimientos habituales de interpolación no habrían producido efecto alguno.

OE2 — Incorporación de variables exógenas. Alcanzado. Se integraron las variables meteorológicas de AEMET y el calendario laboral. Este último evolucionó durante el trabajo desde una variable binaria hasta una intensidad ponderada por población, tras detectarse la discordancia entre el ámbito territorial de la demanda y el del calendario.

OE3 — Aplicación de series de Fourier. Alcanzado. El análisis espectral identificó los periodos de 24, 12 y 168 horas, resultado que fundamenta empíricamente la selección de los desfases temporales empleados como predictores.

OE4 — Desarrollo y comparación de modelos. Alcanzado y superado. Se evaluaron diez formulaciones frente a las seis inicialmente previstas, incorporando tres modelos ingenuos como línea base adicional.

OE5 — Evaluación con control del sobreajuste. Alcanzado. Se registraron las métricas dentro y fuera de muestra para todos los modelos, con la precisión relativa a su distinta interpretabilidad en formulaciones estadísticas y de aprendizaje automático.

OE6 — Identificación de los factores determinantes. Alcanzado. Mediante importancia nativa y valores SHAP. El resultado converge con el del análisis exploratorio, lo que refuerza ambas vías.

OE7 — Despliegue de la aplicación. Alcanzado. La aplicación se encuentra desplegada y accesible públicamente, con predicción a 24 y 48 horas, identificación de franjas favorables y recomendaciones en lenguaje natural.

Cumplimiento de las métricas objetivo

Tabla 6.1: Grado de consecución de las métricas establecidas

Métrica	Objetivo	Obtenido	Estado
MAPE	< 8 %	1,34 %	Superado
MAE sobre consumo medio	< 5 %	1,7 %	Superado
Mejora sobre línea base	Superarla	+56,2 %	Superado
Aplicación desplegada	1 URL pública	Sí	Cumplido

6.2. Principales aportaciones

Un sistema completo, no un experimento

La aportación principal no reside en el valor concreto del error alcanzado, sino en haber recorrido el ciclo íntegro desde el dato abierto hasta la aplicación accesible. Ese recorrido obligó a resolver cuestiones que un estudio puramente comparativo no llega a plantearse: la disponibilidad efectiva de cada variable en el instante de predicción, la coherencia entre el código de entrenamiento y el de explotación, o el comportamiento del sistema ante el fallo de una fuente externa.

Tratamiento riguroso y documentado de los datos

Tres decisiones metodológicas merecen destacarse por su carácter no evidente:

1. **El reindexado previo a la imputación.** Las ausencias se manifestaban como registros inexistentes, no como valores nulos. Sin reindexar, la interpolación no habría producido efecto y la verificación posterior habría comparado la serie consigo misma.
2. **La estrategia escalonada de imputación.** El desplazamiento semanal para huecos extensos preserva el perfil diario, que una interpolación lineal destruiría.
3. **La detección de anomalías condicionada al contexto.** La regla del rango intercuartílico no identificaba ningún valor atípico; el procedimiento sobre el residuo respecto al perfil temporal detectó 555.

Cuantificación de la fuga de información

El trabajo no se limita a evitar la fuga de información, sino que mide su efecto: la inclusión de variables no disponibles en el instante de predicción reduce el error aparente en un 59 %. Esta cuantificación documenta una decisión metodológica que la mayoría de los trabajos publicados no llega a explicitar.

Validación de la hipótesis sobre el efecto del calendario

La cadena argumental del trabajo se cierra de forma completa. El análisis exploratorio identificó que cerca del 70 % de las anomalías se concentraba en festivos; ese hallazgo motivó la incorporación de las variables de calendario; y la evaluación dirigida verificó que dichas variables cumplen su cometido, con diferencias de hasta un orden de magnitud frente a los modelos que carecen de ellas.

Detección y corrección de una limitación propia

La discordancia entre el ámbito territorial de la demanda —peninsular— y el del calendario —autonómico— se detectó al analizar los resultados, no se conocía de antemano. La solución adoptada, una intensidad ponderada por población, corrigió el error del 2 de mayo del 10,62 % al 2,14 % sin degradar el rendimiento general.

6.3. Limitaciones del trabajo

Resolución de las variables meteorológicas. Los valores climatológicos de AEMET tienen periodicidad diaria, mientras que la variable objetivo es horaria. La propagación del valor diario a las veinticuatro horas del día renuncia al ciclo térmico intradiario.

Representatividad de la estación meteorológica. Se emplea una única estación —Madrid-Retiro— como aproximación de las condiciones peninsulares. La heterogeneidad climática del territorio nacional no queda recogida.

Periodo de evaluación acotado. Los catorce orígenes cubren aproximadamente setenta días, entre octubre y diciembre de 2024. El signo negativo de la diferencia entre entrenamiento y producción en el modelo Ridge sugiere que dicho periodo resulta más estable que la media del histórico, por lo que las cifras de sobreajuste podrían estar infravaloradas.

Ausencia de información sobre generación. El sistema no incorpora datos de generación renovable, factor que influye sensiblemente sobre el precio y que podría mejorar la calidad de las recomendaciones económicas.

Extensión recursiva del horizonte. La predicción más allá de veinticuatro horas se obtiene realimentando las predicciones anteriores, procedimiento que acumula error. Un modelo entrenado específicamente para cuarenta y ocho horas obtendría mejores resultados.

Relación entre demanda y precio. La aplicación emplea la demanda prevista como indicador aproximado del precio. La relación entre ambas magnitudes es estrecha pero no determinista: la composición del parque generador disponible introduce una variabilidad no contemplada.

6.4. Líneas de trabajo futuro

Predicción directa del precio. Incorporar el precio del mercado diario como variable objetivo adicional permitiría ofrecer recomendaciones económicas directas en lugar de aproximadas.

Meteorología de resolución horaria. El reanálisis ERA5 del programa Copernicus proporciona temperatura horaria histórica, lo que eliminaría la limitación principal de las variables meteorológicas actuales.

Modelos fundacionales para series temporales. Han surgido recientemente modelos preentrenados de propósito general para predicción de series temporales, capaces de operar sin entrenamiento específico sobre el conjunto de destino. Su evaluación comparativa frente al enfoque adoptado constituye una línea de continuación natural.

Combinación de modelos. La evidencia de las competiciones M (Makridakis, Spiliotis y Assimakopoulos 2020) indica que la combinación de predicciones mejora sistemáticamente la robustez. Un promedio ponderado de XGBoost y LightGBM resultaría inmediato de implementar.

Desagregación territorial. La disponibilidad de demanda por comunidad autónoma permitiría emplear el calendario correspondiente a cada territorio, resolviendo de raíz la limitación que motivó la variable de intensidad ponderada.

Integración del consumo individual. La incorporación de los datos de consumo del propio usuario, accesibles a través de las distribuidoras, permitiría pasar de una recomendación general a una estimación personalizada del ahorro.

7. Referencias

- Agencia Estatal de Meteorología (2025). *AEMET OpenData*. URL: <https://opendata.aemet.es/> (visitado 22-07-2026).
- Bandara, K., R. J. Hyndman y C. Bergmeir (2021). «MSTL: A Seasonal-Trend Decomposition Algorithm for Time Series with Multiple Seasonal Patterns». En: *arXiv preprint arXiv:2107.13462*. DOI: [10.48550/arXiv.2107.13462](https://doi.org/10.48550/arXiv.2107.13462).
- Box, G. E. P., G. M. Jenkins, G. C. Reinsel y G. M. Ljung (2015). *Time Series Analysis: Forecasting and Control*. 5.^a ed. Hoboken, NJ: John Wiley & Sons.
- Breiman, L. (2001). «Random Forests». En: *Machine Learning* 45.1, págs. 5-32. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- Chen, T. y C. Guestrin (2016). «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, págs. 785-794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- Cleveland, R. B., W. S. Cleveland, J. E. McRae e I. Terpenning (1990). «STL: A Seasonal-Trend Decomposition Procedure Based on Loess». En: *Journal of Official Statistics* 6.1, págs. 3-73.
- Hong, T. y S. Fan (2016). «Probabilistic Electric Load Forecasting: A Tutorial Review». En: *International Journal of Forecasting* 32.3, págs. 914-938. DOI: [10.1016/j.ijforecast.2015.11.011](https://doi.org/10.1016/j.ijforecast.2015.11.011).
- Hyndman, R. J. y G. Athanasopoulos (2021). *Forecasting: Principles and Practice*. 3.^a ed. Melbourne: OTexts. URL: <https://otexts.com/fpp3/>.
- Ke, G., Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye y T.-Y. Liu (2017). «LightGBM: A Highly Efficient Gradient Boosting Decision Tree». En: *Advances in Neural Information Processing Systems*. Vol. 30.
- Lundberg, S. M. y S.-I. Lee (2017). «A Unified Approach to Interpreting Model Predictions». En: *Advances in Neural Information Processing Systems*. Vol. 30.
- Makridakis, S., E. Spiliotis y V. Assimakopoulos (2020). «The M4 Competition: 100,000 time series and 61 forecasting methods». En: *International Journal of Forecasting* 36.1, págs. 54-74. DOI: [10.1016/j.ijforecast.2019.04.014](https://doi.org/10.1016/j.ijforecast.2019.04.014).
- (2022). «The M5 competition: Background, organization, and implementation». En: *International Journal of Forecasting* 38.4, págs. 1325-1336. DOI: [10.1016/j.ijforecast.2021.07.007](https://doi.org/10.1016/j.ijforecast.2021.07.007).
- Operador del Mercado Ibérico de Energía (2025). *Resultados del mercado diario*. URL: <https://www.omie.es/> (visitado 22-07-2026).
- Red Eléctrica de España (2025). *Sistema de Información del Operador del Sistema (e-sios)*. URL: <https://www.esios.ree.es/> (visitado 22-07-2026).

- Streamlit Inc. (2025). *Streamlit: A Faster Way to Build and Share Data Apps*. URL: <https://streamlit.io/> (visitado 22-07-2026).
- Taylor, S. J. y B. Letham (2018). «Forecasting at Scale». En: *The American Statistician* 72.1, págs. 37-45. DOI: [10.1080/00031305.2017.1380080](https://doi.org/10.1080/00031305.2017.1380080).

Anexos

Anexo A. Repositorio de código

Enlace al repositorio público de GitHub con el código fuente del proyecto.

Anexo B. Aplicación web desplegada

Enlace a la aplicación web accesible públicamente.

Anexo C. Cronograma detallado del proyecto

[PENDIENTE]