

Predicción de la demanda eléctrica peninsular mediante Machine Learning y datos abiertos

Octubre-2026



Universidad
Internacional
de Valencia

Titulación:

Máster Universitario en Big
Data y Ciencia de Datos

Curso académico
2025 – 2026

Alumno/a:

García Peña, Roberto

D.N.I: 17458202Y

Director/a de TFT:

Gonzalo Surribas Sayago

Convocatoria:

Primera, segundo periodo

De:

 Planeta Formación y Universidades

Índice general

Resumen	1
Abstract	3
1 Introducción	4
1.1 Contexto y motivación	4
1.2 Justificación del trabajo	4
1.3 Vinculación con los Objetivos de Desarrollo Sostenible	5
1.4 Estructura del documento	7
2 Objetivos	9
2.1 Objetivo general	9
2.2 Objetivos específicos	9
2.3 Alcance y limitaciones	10
3 Estado del arte y Marco Teórico	11
3.1 Predicción de demanda eléctrica: panorama general	11
3.2 Modelos clásicos de series temporales	12
3.2.1 Modelos ARIMA y SARIMA	12
3.2.2 Prophet	13
3.2.3 Análisis espectral y series de Fourier	13
3.3 Aprendizaje automático aplicado a series temporales	14
3.3.1 Modelos basados en árboles	14
3.3.2 Ingeniería de características temporales	14
3.4 El mercado eléctrico español y la tarifa PVPC	15
3.5 Trabajos previos relacionados	16
3.5.1 Revisiones de referencia	16
3.5.2 Predicción de demanda eléctrica en el sistema español	16
3.5.3 Métodos de potenciación del gradiente	17
3.5.4 Posicionamiento del presente trabajo	17
3.6 Hipótesis de trabajo	18
4 Metodología	20
4.1 Arquitectura del sistema	20

4.2	Adquisición y descripción de los datos	21
4.2.1	Demanda eléctrica	22
4.2.2	Variables meteorológicas	22
4.2.3	Calendario laboral	23
4.2.4	Delimitación temporal	23
4.3	Tratamiento y preprocesado de los datos	23
4.3.1	Análisis exploratorio inicial	23
4.3.2	Integridad de la serie y tratamiento de valores ausentes	24
4.3.3	Análisis de patrones cíclicos mediante series de Fourier	26
4.3.4	Descomposición estacional múltiple	27
4.3.5	Análisis de autocorrelación	29
4.3.6	Identificación de anomalías	30
4.3.7	Relación entre demanda y temperatura	32
4.3.8	Perfiles de consumo	32
4.4	Ingeniería de características	33
4.4.1	Codificación cíclica de las variables temporales	34
4.4.2	Términos de temperatura	35
4.4.3	Prevención de fuga de información	35
4.5	Estrategia de validación	36
4.6	Modelos desarrollados	38
4.6.1	Línea base	38
4.6.2	Modelos de aprendizaje automático	39
4.6.3	Sobre la optimización de hiperparámetros	39
4.7	Métricas de evaluación	39
4.8	Desarrollo de la aplicación web	41
4.9	Uso de herramientas de inteligencia artificial generativa	42
5	Evaluación y resultados	43
5.1	Resultados del análisis exploratorio	43
5.1.1	Calidad de la fuente de datos	43
5.1.2	Estructura temporal	43
5.1.3	Efecto del calendario	43
5.1.4	Relación con la temperatura	43
5.2	Comparativa de rendimiento de los modelos	44
5.3	Análisis de la importancia de variables	47
5.4	Análisis de errores	49
5.5	Evaluación en días festivos	51
5.6	Aplicación desarrollada	53
6	Conclusiones	55
6.1	Cumplimiento de los objetivos	55
6.2	Contraste de las hipótesis	56

6.3	Principales aportaciones	57
6.4	Limitaciones del trabajo	58
6.5	Líneas de trabajo futuro	59
7	Referencias	61
	Anexos	63

Índice de figuras

4.1	Arquitectura general del sistema	20
4.2	Demanda eléctrica horaria en tres escalas temporales: serie completa 2022–2024 (superior), detalle mensual (centro) y detalle semanal (inferior)	24
4.3	Inspección del hueco de mayor longitud (18 horas, 6 de marzo de 2022). La franja sombreada corresponde al tramo imputado	26
4.4	Comparativa de la distribución de la demanda antes y después del proceso de imputación	26
4.5	Periodograma de la serie de demanda. Escala logarítmica (superior) y detalle de los ciclos de corto plazo (inferior)	27
4.6	Descomposición MSTL de la serie con estacionalidad diaria (24 h) y semanal (168 h). El tramo ascendente inicial del panel de tendencia constituye un artefacto de borde del procedimiento, no un fenómeno real	28
4.7	Comparación del residuo obtenido mediante STL (periodo 24 h) y MSTL (periodos 24 h y 168 h)	29
4.8	Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie de demanda	30
4.9	Anomalías clasificadas según su origen (superior) y distribución del residuo asociado a cada categoría (inferior)	31
4.10	Relación entre demanda diaria media y temperatura media, con ajuste cuadrático superpuesto (izquierda) y matriz de correlaciones lineales (derecha)	32
4.11	Perfiles de consumo: perfil horario por día de la semana, distribución mensual, comparación entre días laborables y no laborables, y mapa de calor hora $\times$ mes	33
5.1	Importancia de las variables en el modelo seleccionado	47
5.2	Valores SHAP del modelo seleccionado	48
5.3	Interfaz de la aplicación web desarrollada parte 1	53
5.4	Interfaz de la aplicación web desarrollada parte 2	53

Índice de tablas

1.1	Objetivos de Desarrollo Sostenible y metas vinculadas al trabajo	5
2.1	Delimitación del alcance del trabajo	10
3.1	Síntesis de los antecedentes revisados	18
4.1	Fuentes de datos empleadas	22
4.2	Periodos dominantes identificados mediante análisis espectral	27
4.3	Distribución de las anomalías detectadas según su origen	31
4.4	Variables predictoras construidas y su justificación	34
4.5	Disponibilidad de las variables en el instante de predicción	35
5.1	Comparativa de rendimiento de los modelos evaluados	44
5.2	Error de entrenamiento frente a error de validación temporal	45
5.3	Error según el tipo de día (modelos de aprendizaje automático)	50
5.4	Error en los orígenes problemáticos de la línea base	50
5.5	Rendimiento en los ocho días festivos evaluados	51
5.6	Intensidad de festivo según el alcance territorial	52
6.1	Grado de consecución de las métricas establecidas	56
6.2	Resolución de las hipótesis de trabajo	56

Resumen

La demanda eléctrica presenta patrones complejos, condicionados por la meteorología, el calendario laboral y los hábitos de consumo, cuya anticipación resulta clave tanto para la operación del sistema como para el consumidor doméstico acogido a la tarifa PVPC, cuyo precio varía cada hora. El presente Trabajo Fin de Máster desarrolla y evalúa un sistema completo de predicción de la demanda eléctrica peninsular española a veinticuatro horas, basado exclusivamente en datos abiertos, que abarca desde la adquisición de los datos hasta el despliegue de una aplicación web.

El estudio emplea la serie horaria de demanda publicada por Red Eléctrica de España entre 2022 y 2024 (26.304 registros), las temperaturas diarias de AEMET y el calendario de festivos de las diecinueve subdivisiones territoriales. El tratamiento de los datos incluye la reconstrucción de los huecos de la serie mediante una imputación escalonada, un análisis espectral de Fourier y una descomposición MSTL que identifican los ciclos diario y semanal como dominantes, y una detección de anomalías condicionada al contexto temporal que atribuye cerca del 70 % de las desviaciones significativas a los días festivos y su entorno. Estos hallazgos fundamentan la construcción de las variables predictoras, en la que se aplica una regla explícita para evitar la fuga de información temporal, cuyo efecto se ha cuantificado.

Se comparan diez formulaciones de complejidad creciente —tres modelos ingenuos, SARIMA, SARIMAX con términos de Fourier, Prophet, Ridge, Random Forest, XGBoost y LightGBM— mediante una validación temporal de origen rodante con catorce orígenes, complementada con una evaluación dirigida sobre días festivos. El modelo XGBoost obtiene el mejor resultado, con un error porcentual absoluto medio (MAPE) mediano del 1,34 % y un error absoluto medio de 470 MW, lo que supone una mejora del 56,3 % sobre la mejor línea base ingenua. Por el contrario, Prophet y SARIMAX con términos de Fourier no consiguen superar a la predicción ingenua semanal, lo que subraya la importancia de incluir estas referencias. En los días festivos, XGBoost obtiene un error del 3,32 %, frente al 16,63 % de la predicción ingenua semanal, y la sustitución del indicador binario de festivo por una intensidad ponderada por población reduce el error del 2 de mayo del 10,62 % al 2,14 %. El análisis mediante valores SHAP confirma que los desfases de 24 y 168 horas y las variables de calendario son los factores de mayor contribución, en coherencia con el análisis exploratorio.

El modelo seleccionado se integra en una aplicación web desarrollada con Streamlit, ejecutable en local a partir del repositorio público del trabajo, que ofrece previsiones a 24–48 horas, identifica las franjas de menor demanda y genera recomendaciones en lenguaje natural para optimizar el consumo doméstico. El trabajo es de elaboración propia y no se basa en desarrollos previos del director ni en proyectos anteriores, y contribuye a los Objetivos de Desarrollo Sostenible 7, 12 y 13.

Palabras clave: predicción de demanda eléctrica, series temporales, aprendizaje auto-

mático, XGBoost, datos abiertos, tarifa PVPC.

Abstract

Electricity demand follows complex patterns shaped by weather, the working calendar and consumption habits. Anticipating them is essential both for system operation and for household consumers on the Spanish PVPC tariff, whose price changes every hour. This Master's Thesis develops and evaluates a complete system for forecasting peninsular Spanish electricity demand 24 hours ahead, based exclusively on open data and covering the whole cycle from data acquisition to the deployment of a web application.

The study uses the hourly demand series published by Red Eléctrica de España for 2022–2024 (26,304 records), daily temperatures from AEMET and the holiday calendars of the nineteen Spanish regions. Data processing includes a tiered imputation of the gaps in the series, a Fourier spectral analysis and an MSTL decomposition that identify the daily and weekly cycles as dominant, and a context-dependent anomaly detection that attributes almost 70 % of significant deviations to public holidays and adjacent days. These findings guide feature engineering, where an explicit rule is applied to prevent temporal information leakage, whose effect has been quantified.

Ten models of increasing complexity are compared —three naive baselines, SARIMA, SARIMAX with Fourier terms, Prophet, Ridge, Random Forest, XGBoost and LightGBM— using rolling-origin temporal validation with fourteen origins, complemented by a targeted evaluation on public holidays. XGBoost achieves the best performance, with a median mean absolute percentage error (MAPE) of 1.34 % and a mean absolute error of 470 MW, a 56.2 % improvement over the best naive baseline. In contrast, Prophet and SARIMAX with Fourier terms fail to beat the seasonal naive forecast, which highlights the importance of including such baselines. On public holidays, XGBoost achieves an error of 3.32 %, compared with 16.63 % for the seasonal naive forecast, and replacing the binary holiday flag with a population-weighted holiday intensity reduces the error on 2 May from 10.62 % to 2.14 %. SHAP analysis confirms that the 24- and 168-hour lags and the calendar variables are the most influential factors, consistent with the exploratory analysis.

The selected model is integrated into a Streamlit web application that runs locally from the project's public repository, which provides 24–48 hour forecasts, identifies the lowest-demand time slots and generates natural-language recommendations to optimise household consumption. The work is original and is not based on previous work by the supervisor or on earlier projects, and it contributes to Sustainable Development Goals 7, 12 and 13.

Keywords: electricity demand forecasting, time series, machine learning, XGBoost, open data, PVPC tariff.

1. Introducción

1.1. Contexto y motivación

El sistema eléctrico español ha atravesado en los últimos años un periodo de transformación acelerada. La progresiva integración de generación renovable, la electrificación del transporte y la volatilidad de los mercados energéticos han situado la gestión de la demanda en el centro del debate público y técnico.

La predicción de la demanda eléctrica constituye una función crítica para el operador del sistema. La red carece de capacidad de almacenamiento significativa, por lo que generación y consumo deben equilibrarse de forma continua: una previsión deficiente obliga a recurrir a mecanismos de ajuste más costosos y menos eficientes desde el punto de vista ambiental. Este problema ha sido ampliamente estudiado en la literatura, con un cuerpo de trabajo consolidado en torno a la predicción de carga a corto plazo (Hong & Fan, 2016).

Existe, sin embargo, una segunda dimensión del problema que ha recibido mucha menos atención: la del **consumidor doméstico**. En España, la tarifa regulada —el Precio Voluntario para el Pequeño Consumidor, PVPC— establece un precio que varía cada hora del día en función del resultado del mercado mayorista. El consumidor acogido a esta modalidad puede, en principio, reducir su factura desplazando el consumo hacia las horas más económicas.

En la práctica, aprovechar esa posibilidad exige una información que no está al alcance del usuario medio. Los precios del día siguiente se publican a las 20:15 horas, una vez cerrada la subasta diaria, y su interpretación requiere una familiaridad con el funcionamiento del mercado eléctrico que difícilmente cabe presuponer. El resultado es una asimetría notable: la información existe, es pública y es gratuita, pero permanece inaccesible para quien más podría beneficiarse de ella.

Este trabajo parte de esa observación. Su motivación no es únicamente construir un modelo predictivo preciso —objetivo ampliamente cubierto por la literatura— sino **cerrar la distancia entre el dato abierto y la decisión del ciudadano**, mediante un sistema que traduzca la previsión técnica en una recomendación comprensible y accionable.

1.2. Justificación del trabajo

La justificación del presente trabajo se articula en torno a tres argumentos.

Disponibilidad de datos abiertos infrautilizados

Red Eléctrica de España publica la demanda peninsular con resolución de diez minutos y sin restricciones de acceso, y la Agencia Estatal de Meteorología ofrece tanto series climatológicas históricas como previsiones a cuarenta y ocho horas. Ambas fuen-

tes son gratuitas y de acceso programático. Pese a ello, su explotación conjunta con fines de asesoramiento al consumidor final resulta escasa.

Distancia entre la literatura académica y la herramienta utilizable

La investigación sobre predicción de demanda eléctrica es abundante, pero sus resultados rara vez trascienden el entorno experimental. Un modelo evaluado en un cuaderno de análisis y un sistema desplegado al que un usuario puede acceder son artefactos de naturaleza distinta: el segundo exige resolver la obtención de datos en tiempo real, el tratamiento de fallos de las fuentes externas, la coherencia entre el código de entrenamiento y el de validación, y la traducción del resultado numérico a lenguaje natural.

Aportación diferencial: un sistema completo

El trabajo no se limita a comparar algoritmos. Abarca el ciclo completo —ingesta, tratamiento, modelado, evaluación y despliegue— y produce como resultado una aplicación funcional, reproducible a partir del código publicado. Esta orientación condiciona decisiones metodológicas que un estudio puramente comparativo podría obviar: la disponibilidad efectiva de cada variable en el instante de predicción, el coste computacional del reentrenamiento o el comportamiento del sistema ante la caída de una fuente externa.

1.3. Vinculación con los Objetivos de Desarrollo Sostenible

La Agenda 2030 de las Naciones Unidas (Naciones Unidas, 2015) establece diecisiete Objetivos de Desarrollo Sostenible (ODS), desglosados en metas concretas. El presente trabajo guarda relación con varios de ellos. Conviene, sin embargo, distinguir entre una contribución directa —derivada de lo que el sistema desarrollado efectivamente hace— y una contribución indirecta, que depende de cómo se utilice. La Tabla 1.1 resume la vinculación y los apartados siguientes la justifican.

Tabla 1.1: Objetivos de Desarrollo Sostenible y metas vinculadas al trabajo

ODS	Metas	Elemento del trabajo que se relaciona
ODS 7. Energía asequible y no contaminante	7.1, 7.3 (principal)	Predicción de la demanda peninsular a 24–48 horas y aplicación que orienta el consumo doméstico hacia las franjas de menor demanda en el marco de la tarifa PVPC
ODS 12. Producción y consumo responsables	12.8	Traducción de datos abiertos del sistema eléctrico en información comprensible y en recomendaciones accionables para el ciudadano
ODS 13. Acción por el clima	13.3	Sensibilización sobre el perfil horario del sistema eléctrico y fomento de la flexibilidad de la demanda, con efecto indirecto sobre las emisiones

ODS 7: Energía asequible y no contaminante

Constituye el objetivo con el que el trabajo guarda una relación más estrecha, a través de dos de sus metas.

La **meta 7.1** persigue garantizar el acceso universal a servicios energéticos *asequibles, fiables y modernos*. En España, el consumidor acogido a la tarifa PVPC paga un precio que varía cada hora (sección 3.4), de modo que la asequibilidad de su suministro depende en parte del momento en que consume. La aplicación desarrollada pone a disposición, con código abierto, la información necesaria para desplazar el consumo flexible —lavadora, lavavajillas, carga del vehículo eléctrico— hacia las horas de menor demanda prevista, que suelen coincidir con las de menor precio. Se trata, por tanto, de una contribución a la dimensión de asequibilidad dirigida al pequeño consumidor, que es precisamente el colectivo con menos acceso a este tipo de información.

La **meta 7.3** persigue mejorar la eficiencia energética. La relación en este caso se sitúa en el plano del sistema y no en el del hogar: desplazar consumo no reduce necesariamente la energía total consumida, pero sí contribuye a aplanar la curva de carga. Una demanda más regular y mejor anticipada reduce la necesidad de recurrir a los mecanismos de ajuste y a las centrales de respuesta rápida con que se cubren las puntas, que resultan más costosos y menos eficientes. La propia predicción de la demanda a corto plazo, objeto técnico central del trabajo, es una de las herramientas en las que se apoya esa gestión eficiente del sistema (Hong & Fan, 2016).

ODS 12: Producción y consumo responsables

La **meta 12.8** persigue asegurar que las personas dispongan de la información y los conocimientos pertinentes para el desarrollo sostenible. El trabajo parte de una observación expuesta en la sección 1.1: la información sobre el sistema eléctrico existe, es pública y es gratuita, pero resulta inaccesible para el consumidor medio. La aportación de la aplicación consiste en cerrar esa distancia, transformando series técnicas publicadas por Red Eléctrica de España y AEMET en una recomendación en lenguaje natural. El empleo exclusivo de fuentes de datos abiertas y la publicación del código (Anexo A) refuerzan además la transparencia y la reproducibilidad del sistema.

ODS 13: Acción por el clima

La **meta 13.3** persigue mejorar la educación y la sensibilización respecto de la mitigación del cambio climático. La aplicación hace visible al usuario que el consumo eléctrico no es indiferente a la hora en que se produce, y promueve la **flexibilidad de la demanda**, reconocida como uno de los elementos necesarios para integrar una proporción creciente de generación renovable, cuya producción no puede programarse a voluntad.

Alcance y límites de la contribución

La vinculación anterior exige ser matizada, en coherencia con las limitaciones recogidas en la sección 6.4:

- **El sistema predice demanda, no emisiones ni precio.** Las horas de menor demanda suelen ser también las más económicas, pero no coinciden necesariamente con las de mayor proporción de generación renovable. Por ello, la contribución al ODS 13 se considera **indirecta**, circunstancia relacionada con la ausencia de información sobre generación recogida entre las limitaciones del trabajo.
- **El impacto depende de la adopción.** El trabajo proporciona la herramienta, pero no mide cambios reales de comportamiento ni ahorros efectivos en los hogares. Cuantificar ese impacto requeriría un estudio con usuarios que excede el alcance del trabajo.
- **El coste ambiental de la propia solución es reducido.** La elección de modelos de potenciación del gradiente frente a arquitecturas de aprendizaje profundo, justificada en el capítulo 3 por su rendimiento, implica también un consumo computacional moderado: el entrenamiento se completa en un equipo convencional y la aplicación se ejecuta en un ordenador personal sin aceleración por hardware. Se atiende así al principio de considerar el consumo energético de las soluciones de inteligencia artificial que se desarrollan.

En síntesis, el trabajo contribuye de forma **directa** al ODS 7 y al ODS 12, al poner a disposición del consumidor información útil para un uso más asequible y consciente de la energía, y de forma **indirecta** al ODS 13, en la medida en que dicha información favorezca la flexibilidad de la demanda.

1.4. Estructura del documento

El documento se organiza en seis capítulos.

El **capítulo 2** formula el objetivo general y los siete objetivos específicos, y delimita el alcance del trabajo.

El **capítulo 3** revisa el estado del arte: el panorama general de la predicción de demanda eléctrica, los modelos clásicos de series temporales, las técnicas de aprendizaje automático aplicadas a este dominio y el funcionamiento del mercado eléctrico español.

El **capítulo 4** expone la metodología. Describe la arquitectura del sistema, las fuentes de datos, el tratamiento aplicado —que constituye una de las aportaciones centrales—, la ingeniería de características derivada del análisis exploratorio, la estrategia de validación y los modelos evaluados.

El **capítulo 5** presenta y discute los resultados: la caracterización de la serie, la comparativa de rendimiento entre las diez formulaciones evaluadas, el análisis de importancia de variables, el estudio de errores y la aplicación desarrollada.

El **capítulo 6** revisa el grado de cumplimiento de los objetivos, sintetiza las aportaciones, reconoce las limitaciones y propone líneas de continuación.

Durante la elaboración del trabajo se han empleado herramientas de inteligencia artificial generativa como apoyo en tareas concretas, que se detallan en la sección 4.9. Su uso se ha documentado en un repositorio de transparencia público (Anexo B), conforme a las normas de la Universidad Internacional de Valencia.

Se incluyen finalmente las referencias bibliográficas y dos anexos con el repositorio de código y el repositorio de prompts utilizados.

2. Objetivos

2.1. Objetivo general

Desarrollar y evaluar un sistema de predicción de la demanda eléctrica peninsular española mediante técnicas de aprendizaje automático y fuentes de datos abiertos, abarcando desde la adquisición y tratamiento de los datos hasta el despliegue de una aplicación web orientada a la consulta e interpretación de las predicciones.

2.2. Objetivos específicos

- OE1.** Analizar el comportamiento histórico de la demanda eléctrica mediante técnicas de análisis exploratorio de datos, identificando tendencias, estacionalidad y ciclos característicos.
- OE2.** Incorporar variables exógenas relevantes al conjunto de datos: condiciones meteorológicas procedentes de AEMET, calendario laboral y variables de calendario derivadas.
- OE3.** Aplicar series de Fourier para la identificación de los patrones cíclicos dominantes con carácter previo a la fase de modelado.
- OE4.** Desarrollar y comparar modelos predictivos siguiendo una progresión de complejidad creciente: modelos estadísticos clásicos (ARIMA, SARIMA, Prophet) como línea base, y modelos de aprendizaje automático (Random Forest, XGBoost, LightGBM) como propuesta principal.
- OE5.** Evaluar el rendimiento de los modelos mediante métricas de entrenamiento y de validación (MAE, RMSE, MAPE), controlando explícitamente el sobreajuste.
- OE6.** Interpretar los resultados obtenidos e identificar los factores con mayor influencia sobre la demanda mediante análisis de importancia de variables.
- OE7.** Desarrollar una aplicación web interactiva que integre el modelo de mejor desempeño, ejecutable a partir del código publicado, con predicciones a 24–48 horas y recomendaciones orientadas a la tarifa PVPC.

2.3. Alcance y limitaciones

Tabla 2.1: Delimitación del alcance del trabajo

Dentro del alcance	Fuera del alcance
Demanda eléctrica peninsular española (REE)	Consumo individual del usuario en tiempo real
Histórico 2022–2024 (datos horarios)	Predicción de generación renovable
Variables meteorológicas de AEMET	Integración con API de distribuidoras
Calendario laboral	Aplicación móvil y despliegue público
Horizonte de predicción de 24–48 horas	Predicción por comunidad autónoma
Aplicación web funcional (ejecución local)	Modelos de precio del mercado mayorista

3. Estado del arte y Marco Teórico

3.1. Predicción de demanda eléctrica: panorama general

La predicción de la demanda eléctrica constituye una de las aplicaciones más antiguas y mejor documentadas del análisis de series temporales. Su relevancia deriva de una restricción física del sistema: la electricidad no puede almacenarse en cantidades significativas a escala de red, de modo que generación y consumo han de equilibrarse de forma instantánea y permanente.

Clasificación por horizonte temporal

La literatura distingue habitualmente cuatro horizontes, cada uno asociado a una finalidad operativa y a metodologías distintas (Hong & Fan, 2016):

- **Muy corto plazo** (de minutos a una hora). Orientado al control en tiempo real y a la regulación de frecuencia. Predomina la inercia de la serie: los métodos autorregresivos simples resultan difíciles de superar.
- **Corto plazo** (de una hora a una semana). Es el horizonte de la programación diaria y de la casación del mercado, y el que concentra el mayor volumen de investigación. **El presente trabajo se sitúa en este intervalo**, con un horizonte de veinticuatro a cuarenta y ocho horas.
- **Medio plazo** (de una semana a un año). Empleado en la planificación del mantenimiento y en la contratación de combustible.
- **Largo plazo** (más de un año). Orientado a la planificación de infraestructuras. Depende de variables macroeconómicas y demográficas más que de la propia serie histórica.

Factores determinantes

Existe consenso en la literatura sobre los tres grupos de factores que gobiernan la demanda a corto plazo:

1. **Calendario.** Hora del día, día de la semana y festividades. Su efecto es sistemático y predecible, y constituye la fuente principal de estructura de la serie.
2. **Meteorología.** Fundamentalmente la temperatura, cuya relación con la demanda no es lineal sino aproximadamente cuadrática, por la superposición de las demandas de calefacción y refrigeración.
3. **Actividad económica.** Relevante en horizontes medios y largos, con efecto reducido a escala de días.

Evolución metodológica

El campo ha atravesado tres etapas sucesivas. Hasta los años noventa predominaron los modelos estadísticos de la familia Box-Jenkins (Box et al., 2015) y la regresión con variables meteorológicas. La década siguiente vio la incorporación de las redes neuronales, con resultados desiguales. Desde mediados de la década de 2010 se han impuesto los métodos de conjunto basados en árboles de decisión.

Las competencias M han proporcionado la evidencia comparativa más sólida al respecto. La cuarta edición (Makridakis et al., 2020) estableció que las combinaciones de métodos superan sistemáticamente a los modelos individuales, y que el aprendizaje transversal entre series mejora los resultados frente al ajuste individualizado. La quinta (Makridakis et al., 2022) arrojó un hallazgo aún más rotundo: los métodos basados en árboles con potenciación del gradiente dominaron las primeras posiciones, por delante de las arquitecturas de aprendizaje profundo.

Esta evidencia justifica la progresión metodológica adoptada en el presente trabajo, que parte de modelos estadísticos clásicos y escala hacia técnicas de potenciación del gradiente, en lugar de recurrir directamente a formulaciones de mayor complejidad.

3.2. Modelos clásicos de series temporales

Los modelos estadísticos de series temporales constituyen la referencia frente a la que debe medirse cualquier propuesta alternativa. Su valor en este trabajo es doble: proporcionan una línea base rigurosa y aportan herramientas de diagnóstico —autocorrelación, descomposición estacional— que orientan la construcción de variables en los modelos posteriores.

3.2.1. Modelos ARIMA y SARIMA

La formulación ARIMA(p, d, q) (Box et al., 2015) modela una serie mediante tres componentes. El término **autorregresivo** de orden p expresa el valor actual como combinación lineal de p valores anteriores; la **integración** de orden d aplica diferenciaciones sucesivas hasta alcanzar la estacionariedad; y el término de **media móvil** de orden q incorpora los q errores de predicción precedentes.

Formalmente, empleando el operador de retardo B :

$$\phi_p(B) (1 - B)^d y_t = \theta_q(B) \varepsilon_t \quad (3.1)$$

donde ϕ_p y θ_q son los polinomios autorregresivo y de media móvil, y ε_t un proceso de ruido blanco.

La extensión estacional SARIMA(p, d, q)(P, D, Q) $_s$ añade componentes análogos sobre el periodo estacional s :

$$\Phi_P(B^s) \phi_p(B) (1 - B^s)^D (1 - B)^d y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t \quad (3.2)$$

Esta formulación presenta una limitación determinante para el problema que nos ocupa: **admite un único periodo estacional**. Una serie horaria de demanda eléctrica exhibe al menos dos —el ciclo diario de veinticuatro horas y el semanal de ciento sesenta y ocho—, y el coste computacional del ajuste crece con el valor de s , lo que hace inviable el tratamiento directo de la estacionalidad semanal.

La solución habitual consiste en representar la estacionalidad mediante términos de Fourier introducidos como regresores externos, reservando la parte ARIMA para la autocorrelación de corto plazo (Hyndman & Athanasopoulos, 2021). Este enfoque admite varios periodos simultáneos y reduce drásticamente el coste de estimación.

3.2.2. Prophet

Prophet (Taylor & Letham, 2018) adopta una aproximación distinta: descompone la serie de forma aditiva en tres componentes interpretables,

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (3.3)$$

donde $g(t)$ representa la tendencia —lineal por tramos con puntos de cambio detectados automáticamente—, $s(t)$ la estacionalidad modelada mediante series de Fourier, $h(t)$ el efecto de las festividades y ε_t el término de error.

Sus ventajas para este dominio son la admisión nativa de estacionalidades múltiples y la incorporación explícita de un calendario de festivos, con ventanas configurables para recoger el efecto de arrastre sobre vísperas y días posteriores. Como contrapartida, al no modelar la autocorrelación de los residuos, tiende a desaprovechar la fuerte inercia de corto plazo característica de las series de demanda.

3.2.3. Análisis espectral y series de Fourier

El análisis espectral permite identificar los periodos dominantes de una serie de manera objetiva, sin presuponerlos a partir del conocimiento del dominio. La transformada discreta de Fourier descompone la señal en componentes sinusoidales,

$$X_k = \sum_{n=0}^{N-1} x_n e^{-i2\pi kn/N} \quad (3.4)$$

y el periodograma $|X_k|^2$ revela la potencia asociada a cada frecuencia. Los máximos locales identifican los ciclos presentes en los datos.

Su utilidad en este trabajo es doble. Por una parte, fundamenta empíricamente la selección de los desfases temporales empleados como variables predictoras. Por otra, permite representar la estacionalidad mediante pares seno-coseno en los modelos que no la admiten de forma nativa.

3.3. Aprendizaje automático aplicado a series temporales

La aplicación de algoritmos de aprendizaje automático a series temporales exige una reformulación previa del problema. Mientras los modelos estadísticos operan directamente sobre la secuencia, los algoritmos de regresión requieren una matriz de observaciones independientes. La transformación consiste en construir, para cada instante, un vector de características que recoja la información disponible hasta ese momento.

Esta reformulación introduce dos ventajas y un riesgo. Permite incorporar variables exógenas sin restricciones y capturar relaciones no lineales e interacciones entre predictores. Pero expone el procedimiento a la **fuga de información**: si alguna variable incorpora datos posteriores al instante de predicción, las métricas obtenidas serán excelentes e irreproducibles en explotación. La sección 4.4.3 aborda esta cuestión de forma específica.

3.3.1. Modelos basados en árboles

Los métodos de conjunto basados en árboles de decisión dominan actualmente las aplicaciones sobre datos tabulares, y las competiciones M han confirmado su superioridad también en predicción de series temporales (Makridakis et al., 2022).

Random Forest (Breiman, 2001) construye múltiples árboles sobre remuestras del conjunto de entrenamiento, aleatorizando además las variables consideradas en cada división, y promedia sus predicciones. La reducción de varianza resultante lo hace robusto frente al sobreajuste, a costa de un sesgo algo mayor.

La **potenciación del gradiente** adopta una estrategia secuencial: cada árbol se ajusta sobre los residuos del conjunto acumulado hasta el momento. Las dos implementaciones de referencia son **XGBoost** (Chen & Guestrin, 2016), que incorpora regularización explícita sobre la complejidad del árbol y tratamiento nativo de valores ausentes, y **LightGBM** (Ke et al., 2017), que introduce el crecimiento por hojas y el agrupamiento de características mutuamente excluyentes, con una reducción sustancial del tiempo de entrenamiento.

La principal limitación de estos métodos en el contexto de series temporales es su incapacidad para extrapolar fuera del rango observado, consecuencia directa de que sus predicciones son promedios de valores del conjunto de entrenamiento. Esta restricción resulta poco problemática en demanda eléctrica, cuya magnitud se mantiene dentro de márgenes estables.

3.3.2. Ingeniería de características temporales

La calidad de las variables construidas determina el rendimiento de estos modelos en mayor medida que la elección del algoritmo. Se distinguen cuatro bloques:

- **Desfases** (lag_k). El valor de la serie k instantes antes. Su selección debe fundamentarse en la estructura de autocorrelación y, sobre todo, respetar la restricción

de disponibilidad: para un horizonte de h periodos únicamente son admisibles los desfases de orden $k \geq h$.

- **Estadísticos móviles.** Media y desviación típica sobre ventanas precedentes. Recogen el nivel y la volatilidad recientes. La ventana debe cerrarse antes del instante de predicción.
- **Codificación cíclica.** Las variables de calendario son circulares: la hora 23 es contigua a la hora 0. Su representación como enteros introduce una discontinuidad artificial que se evita mediante pares de funciones trigonométricas.
- **Variables de calendario.** Indicadores de festividad, día laborable y sus entornos. Su relevancia en demanda eléctrica es considerable, como se cuantifica en el capítulo de resultados.

3.4. El mercado eléctrico español y la tarifa PVPC

El mercado diario

La electricidad se negocia en España a través del Operador del Mercado Ibérico de Energía (Operador del Mercado Ibérico de Energía, 2025). El mercado diario casa oferta y demanda para cada una de las veinticuatro horas del día siguiente mediante un mecanismo marginalista: todas las ofertas aceptadas perciben el precio de la última unidad necesaria para cubrir la demanda prevista.

De este mecanismo se deriva una consecuencia directa para el presente trabajo: **el precio horario guarda una relación estrecha con la demanda prevista**. Las horas de mayor consumo exigen recurrir a tecnologías de coste marginal superior, lo que eleva el precio de casación. La demanda prevista aporta información contextual sobre el comportamiento esperado del sistema, pero no permite determinar por sí sola el perfil horario de precios, que depende además de la estructura de oferta, de la generación disponible y de otras condiciones del mercado eléctrico.

La tarifa PVPC

El Precio Voluntario para el Pequeño Consumidor es la tarifa regulada aplicable a suministros de baja tensión con potencia contratada inferior a diez kilovatios. Su característica distintiva es que el término de energía **varía cada hora** en función del resultado del mercado mayorista.

Los precios correspondientes a cada día se publican la víspera, en torno a las 20:15 horas, una vez cerrada la casación del mercado diario. El consumidor acogido a esta modalidad dispone así de información con la que planificar su consumo, si bien limitada al día siguiente.

Implicaciones para el sistema propuesto

De lo anterior se derivan las dos aportaciones que la aplicación desarrollada puede ofrecer sobre la información ya disponible:

1. **Anticipación.** La previsión de demanda está disponible en cualquier momento, mientras que el precio oficial solo se publica a las 20:15 horas de la víspera.
2. **Horizonte extendido.** El mercado publica únicamente el día siguiente; el sistema propuesto alcanza las cuarenta y ocho horas.

Debe precisarse que la aplicación no predice el precio, sino la demanda, y emplea esta última como indicador aproximado de aquel. La relación entre ambas magnitudes es estrecha pero no determinista: la composición del parque generador disponible —singularmente la aportación renovable— introduce una variabilidad que el modelo no contempla. Esta limitación se recoge de forma explícita en la aplicación.

3.5. Trabajos previos relacionados

3.5.1. Revisiones de referencia

La revisión de Hong y Fan (2016) constituye la síntesis más citada sobre predicción de carga eléctrica. Los autores clasifican las aproximaciones existentes, discuten las métricas habituales y señalan una carencia recurrente: la ausencia de comparación frente a líneas base ingenuas, que dificulta valorar la aportación real de cada propuesta. El presente trabajo atiende expresamente esa observación evaluando tres modelos ingenuos con anterioridad a cualquier formulación estadística.

3.5.2. Predicción de demanda eléctrica en el sistema español

Existen antecedentes directos sobre la serie que constituye el objeto de este trabajo.

Pegalajar et al. (2021) evalúan sobre datos de la red eléctrica española del periodo 2007–2019 un conjunto de seis formulaciones —regresión lineal, árboles de regresión, *gradient boosting*, *random forest*, perceptrón multicapa y tres variantes de red recurrente—, empleando infraestructura de procesamiento distribuido. Su resultado más destacable no es tanto la ordenación entre modelos como la comparación frente a la referencia externa: todas las formulaciones mejoran la previsión publicada por el propio operador del sistema, con incrementos de entre el 12 % y el 37 %. El trabajo evidencia que existe margen de mejora sobre las previsiones oficiales, si bien no incorpora variables meteorológicas ni de calendario.

Torres et al. (2022) abordan la misma serie con una red LSTM optimizada mediante búsqueda aleatoria y una metaheurística, sobre nueve años y medio de datos con frecuencia de diez minutos. Para un horizonte de cuatro horas comunican un MAPE del 1,45 %, que los autores presentan como el mejor resultado publicado hasta la fecha para la demanda eléctrica española. La cifra constituye una referencia útil para contextualizar

los resultados del presente trabajo, aunque la comparación directa no procede: el horizonte es sensiblemente inferior al de veinticuatro horas aquí considerado, y el protocolo de evaluación difiere.

Hernández et al. (2023) emplean datos horarios del mercado español para predecir simultáneamente consumo y precio, comparando regresión lineal, *random forest*, XGBoost, LSTM y GRU. El trabajo resulta de interés por abordar de forma conjunta ambas magnitudes, cuestión directamente relacionada con la distinción —relevante para la aplicación desarrollada— entre predecir demanda y predecir precio.

3.5.3. Métodos de potenciación del gradiente

Qinghe et al. (2022) optimizan un modelo XGBoost para la predicción de demanda a corto plazo sobre un sistema eléctrico regional, incorporando variables meteorológicas y de calendario. El trabajo ilustra la práctica habitual en este ámbito: construcción intensiva de variables derivadas seguida de un ajuste de hiperparámetros mediante búsqueda sistemática.

Wang et al. (2021) proponen una arquitectura que combina redes convolucionales temporales con LightGBM para consumidores industriales. Su aportación metodológica reside en la separación de responsabilidades: la componente neuronal extrae representaciones temporales y el modelo de potenciación efectúa la predicción final.

Semmelmann et al. (2022) evalúan modelos híbridos sobre datos de contadores inteligentes en comunidades energéticas. El trabajo resulta pertinente por situarse, como el presente, en el ámbito del consumidor final antes que en el de la operación del sistema.

3.5.4. Posicionamiento del presente trabajo

La Tabla 3.1 sintetiza los antecedentes revisados.

Del contraste se desprenden tres observaciones. En primer lugar, la mayoría de los trabajos revisados **no comunica comparación frente a líneas base ingenuas**, carencia que Hong y Fan (2016) ya señalaba y que impide valorar la magnitud real de la mejora aportada. En segundo lugar, el tratamiento del calendario suele limitarse a indicadores binarios de festividad, sin atender al alcance territorial de cada celebración. Y en tercer lugar, ninguno de ellos aborda el despliegue del modelo resultante en una herramienta accesible al usuario final.

Estos tres aspectos delimitan la aportación del presente trabajo: comparación sistemática frente a tres líneas base ingenuas, representación del calendario mediante una intensidad ponderada por población, y desarrollo de una aplicación web operativa.

Tabla 3.1: Síntesis de los antecedentes revisados

Trabajo	Datos	Horizonte	Variables	Modelos	Resultado principal
Pegalajar et al. (2021)	Red eléctrica española, 2007–2019	Multi-paso	Desfases de la serie	LR, árboles, GBR, RF, MLP, RNN	Mejora del 12–37 % sobre la previsión del operador
Torres et al. (2022)	Demanda española, 9,5 años, 10 min	4 h	Desfases de la serie	LSTM optimizada, DNN, TFT	MAPE del 1,45 %
Miller et al. (2023)	Mercado español, horario	Corto plazo	Consumo, precio, contexto	LR, RF, XGBoost, LSTM, GRU	Predicción conjunta de consumo y precio
Qinghe et al. (2022)	Sistema regional	Corto plazo	Meteorología, calendario	XGBoost optimizado	Mejora sobre modelos de referencia
Wang et al. (2021)	Consumidores industriales	Corto plazo	Desfases, variables derivadas	TCN + LightGBM	La combinación supera a los modelos individuales
Semmelmann et al. (2022)	Contadores inteligentes	Corto plazo	Consumo agregado	LSTM + XGBoost	Aplicación a comunidades energéticas
Este trabajo	Demanda peninsular (REE), 2022–2024	24–48 h	Desfases, calendario ponderado por población, temperatura	3 ingenuos, SARIMA, Prophet, Ridge, RF, XGBoost, LightGBM	Mejora sobre la línea base ingenua; validación temporal de origen rodante

3.6. Hipótesis de trabajo

La revisión anterior y las carencias identificadas en los antecedentes permiten formular las hipótesis que guían el trabajo. Todas ellas se contrastan con el mismo protocolo de validación temporal de origen rodante (sección 4.5) y se resuelven en el capítulo de conclusiones.

- H1.** Los modelos de potenciación del gradiente entrenados con desfases temporales, variables de calendario y variables meteorológicas superan a la mejor línea base ingenua en la predicción de la demanda a veinticuatro horas. Esta hipótesis responde a la evidencia de las competiciones M (Makridakis et al., 2022) y a la observación de Hong y Fan (2016) sobre la ausencia habitual de comparación con referencias ingenuas.
- H2.** Los modelos estadísticos clásicos (SARIMA, SARIMAX con términos de Fourier y Prophet), pese a representar explícitamente la estacionalidad, superan a la predicción ingenua semanal. La hipótesis se formula para comprobar si la línea base estadística aporta una mejora real sobre la alternativa trivial en una serie con una estructura semanal tan marcada.
- H3.** La incorporación de variables de calendario reduce de forma sustancial el error en los días festivos, que concentran la mayor parte de las desviaciones respecto al perfil habitual de consumo.
- H4.** Dado que el efecto del tipo de día sobre la demanda depende de la hora —un lunes de madrugada se asemeja a un domingo, pero no a media mañana—, los

modelos basados en árboles, capaces de representar esa interacción, superan a un modelo lineal regularizado que dispone exactamente de las mismas variables.

4. Metodología

4.1. Arquitectura del sistema

El sistema se organiza en tres capas desacopladas, según se recoge en la Figura 4.1. Esta separación permite desarrollar y validar cada una de forma independiente, y resulta especialmente conveniente en un trabajo con componente de despliegue: la capa de aplicación puede evolucionar sin afectar al procedimiento de entrenamiento, y viceversa.




Figura 4.1: Arquitectura general del sistema propuesto. El módulo `prediccion.py`, destacado en naranja, es compartido por el procedimiento de entrenamiento y por la aplicación, lo que garantiza que las variables se construyan de forma idéntica en ambos contextos

Capa de datos

Responsable de la obtención, el tratamiento y el almacenamiento de la información. Integra las tres fuentes descritas en la sección anterior mediante llamadas a sus respectivas interfaces de programación, aplica el procedimiento de limpieza e imputación y persiste el resultado en formato Parquet. Este almacenamiento intermedio evita la de-

pendencia de la red en ejecuciones sucesivas y garantiza la reproducibilidad del análisis.

Capa de modelos

Comprende la construcción de variables, el entrenamiento y la evaluación. Su componente central es el módulo `prediccion.py`, que implementa la generación de características y la función de predicción.

Conviene destacar una decisión de diseño con implicaciones prácticas considerables: **este módulo es compartido por el procedimiento de entrenamiento y por la aplicación**. La alternativa —implementar la construcción de variables por duplicado— expone el sistema al fenómeno conocido como *training/serving skew*: si ambas implementaciones divergen, aunque sea en un detalle menor, el modelo recibe en explotación entradas distintas de aquellas sobre las que fue entrenado, y su rendimiento se degrada sin que ningún procedimiento falle de manera visible.

Compartir el código reduce sustancialmente ese riesgo, si bien no lo suprime por completo: subsisten posibles discrepancias derivadas de las fuentes de datos, de la frecuencia de las variables o de la diferencia entre observaciones históricas y previsiones, aspectos que el código común no puede resolver por sí solo.

Capa de aplicación

Comprende la interfaz web, la obtención de datos en tiempo real y la generación de recomendaciones. Se apoya en el modelo serializado que produce la capa anterior y opera de forma autónoma respecto a ella.

Un principio rector de esta capa es la **degradación controlada**: el fallo de una fuente externa no debe interrumpir el servicio. Si la previsión meteorológica no está disponible, se recurre a una estimación climatológica y se advierte de ello al usuario; si falla la consulta de precios, la aplicación continúa operando sin esa información. Únicamente la serie de demanda resulta imprescindible, y su ausencia se comunica mediante un mensaje explícito.

4.2. Adquisición y descripción de los datos

El trabajo se apoya exclusivamente en fuentes de datos abiertas y de acceso gratuito, lo que garantiza la reproducibilidad del estudio. Se han integrado tres orígenes distintos, resumidos en la Tabla 4.1.

Tabla 4.1: Fuentes de datos empleadas

Fuente	Datos	Uso en el proyecto
REE (API REData)	Demanda eléctrica peninsular horaria	Variable objetivo. Serie principal 2022–2024
AEMET OpenData	Climatología diaria de Madrid-Retiro: temperatura media, máxima y mínima, humedad relativa, precipitación, presión y viento	Variables exógenas explicativas
Calendario laboral	Festivos de las 19 subdivisiones (librería holidays)	Intensidad de festivo ponderada por población y variables binarias

4.2.1. Demanda eléctrica

La variable objetivo procede del sistema de información público de Red Eléctrica de España (Red Eléctrica de España, 2025). El acceso se realiza mediante la API REData (apidatos.ree.es), que no requiere credenciales de autenticación.

Conviene señalar una particularidad relevante para la reproducibilidad. El *widget* *evolucion* de dicha API no admite agregación horaria y devuelve un error 400 Bad Request cuando se solicita el parámetro *time_trunc=hour*. La serie horaria debe obtenerse a través del *widget* *demanda-tiempo-real*, cuya resolución nativa es de diez minutos; los valores se reagregan posteriormente a frecuencia horaria mediante la media aritmética de los seis registros de cada hora.

La descarga se ejecuta de forma fraccionada en bloques de pocos días, con reintentos automáticos y un intervalo de espera entre peticiones. El fraccionamiento no obedece únicamente a la cortesía con el servicio: las peticiones que abarcan periodos extensos provocan errores 502 Bad Gateway, dado que el *widget* devuelve del orden de ciento cuarenta registros diarios. Los resultados se almacenan localmente en formato Parquet para evitar dependencias de red en ejecuciones posteriores.

4.2.2. Variables meteorológicas

Los datos climatológicos proceden del portal de datos abiertos de la Agencia Estatal de Meteorología (Agencia Estatal de Meteorología, 2025), para el que se solicitó una clave de acceso gratuita. Se emplea la estación de Madrid-Retiro como aproximación meteorológica simplificada, atendiendo a la continuidad y disponibilidad de su serie histórica. Esta elección no pretende representar la diversidad climática peninsular y constituye una limitación del estudio, recogida en la sección 6.4.

Además de la temperatura, la climatología diaria proporciona la humedad relativa media, la precipitación, la presión máxima y mínima, la velocidad media del viento y la racha máxima, que se incorporan también como variables explicativas en la fase de evaluación.

La API de AEMET presenta dos particularidades operativas. En primer lugar, responde mediante un mecanismo de dos peticiones encadenadas: la primera devuelve una URL temporal y la segunda recupera los datos propiamente dichos. En segundo lugar, impone un límite de peticiones por unidad de tiempo, por lo que la descarga se fracciona en tramos e incorpora esperas entre llamadas.

Debe destacarse una limitación de la fuente con implicaciones metodológicas: los valores climatológicos históricos de AEMET tienen **resolución diaria**, mientras que la variable objetivo es horaria. Se ha optado por propagar el valor diario a las veinticuatro horas del día correspondiente. Esta decisión implica renunciar al ciclo térmico intradiario, pero preserva la señal estacional, que es la componente con mayor efecto sobre la demanda agregada. La alternativa —emplear reanálisis ERA5 del programa Copernicus, con temperatura horaria— se descartó por su mayor complejidad de tratamiento y se recoge como línea de trabajo futuro.

4.2.3. Calendario laboral

Los días festivos se obtienen mediante la librería `holidays` de Python, configurada para España con la subdivisión correspondiente a la Comunidad de Madrid. Esta fuente cubre tanto festivos nacionales como autonómicos y no requiere acceso a red. Posteriormente, para recoger el alcance territorial de cada festividad, se consultó el calendario de las diecinueve subdivisiones y se construyó una intensidad ponderada por población (sección 5.5).

4.2.4. Delimitación temporal

El periodo de estudio abarca del 1 de enero de 2022 al 31 de diciembre de 2024, lo que supone tres años completos y **26.304 registros horarios** esperados. Esta ventana temporal se considera suficiente para capturar al menos tres ciclos estacionales completos, manteniendo un volumen de datos manejable para el entrenamiento iterativo de los modelos. Tras descartar la primera semana, necesaria para construir el desfase de 168 h, el conjunto de modelado comprende 26.136 registros

4.3. Tratamiento y preprocesado de los datos

El tratamiento de los datos constituye una fase central de este trabajo. Cada decisión adoptada se documenta gráficamente y, cuando procede, se verifica mediante contraste estadístico.

4.3.1. Análisis exploratorio inicial

La Figura 4.2 presenta la serie de demanda en tres escalas temporales. La visualización conjunta permite identificar de forma inmediata la superposición de tres patrones: un ciclo anual con máximos en invierno y verano, un ciclo semanal que diferencia días laborables de fines de semana, y un ciclo diario con doble pico.




Figura 4.2: Demanda eléctrica horaria en tres escalas temporales: serie completa 2022–2024 (superior), detalle mensual (centro) y detalle semanal (inferior)

En el detalle semanal se aprecia con nitidez la estructura del perfil diario: un mínimo en la madrugada, un ascenso pronunciado a partir de las seis de la mañana, un máximo de mediodía y un segundo máximo vespertino, con una reducción apreciable del nivel general durante el fin de semana.

4.3.2. Integridad de la serie y tratamiento de valores ausentes

La comprobación de integridad reveló una circunstancia que condiciona toda la estrategia de imputación. De los 26.304 registros horarios esperados se obtuvieron 26.214, resultando 90 ausencias (un 0,34 % del total). Ahora bien, el recuento de valores nulos sobre la serie descargada era **cero**: las ausencias no figuraban como valores perdidos, sino como **filas inexistentes en el índice temporal**.

Esta distinción no es menor. Los procedimientos habituales de interpolación operan sobre valores nulos dentro de registros existentes, de modo que aplicados directamente sobre esta serie no habrían producido efecto alguno: la verificación posterior habría comparado la serie consigo misma, arrojando un resultado trivialmente favorable y carente de valor. El procedimiento correcto exige **reindexar previamente** la serie sobre una malla horaria completa, materializando así los huecos como valores nulos explícitos, y solo entonces proceder a su imputación.

El inventario de huecos resultante muestra que las 90 ausencias corresponden a

cinco tramos idénticos de 18 horas consecutivas, todos entre las 03:00 y las 20:00 (6 de marzo, 29 de junio y 19 de diciembre de 2022; 12 de abril y 3 de octubre de 2023). La regularidad del patrón apunta a una incidencia sistemática del servicio de publicación. En consecuencia, todos los huecos se trataron mediante el segundo nivel de la estrategia —desplazamiento semanal—; los niveles primero y tercero se mantienen como salvaguarda, pero no llegaron a aplicarse.

Conviene distinguir entre el **preprocesamiento histórico** y el **operativo**. La interpolación descrita emplea los valores anterior y posterior al hueco, procedimiento admisible para reconstruir una serie histórica completa pero no aplicable en tiempo real, donde el valor posterior aún no existe. La aplicación desarrollada no realiza imputación: opera sobre los datos efectivamente publicados y advierte al usuario si la serie presenta huecos.

Estrategia de imputación

Se adopta un procedimiento escalonado en función de la longitud del hueco:

- 1. Huecos de hasta tres horas** — interpolación temporal lineal. En tramos tan breves la curva de demanda es aproximadamente lineal y el error introducido resulta despreciable.
- 2. Huecos superiores a tres horas** — sustitución por el valor registrado en la misma hora de la semana anterior (desplazamiento de 168 horas). Esta elección es deliberada: una interpolación lineal a lo largo de dieciocho horas trazaría una recta a través de un ciclo diario completo, destruyendo precisamente la estructura que el modelo debe aprender a reproducir. El desplazamiento semanal preserva tanto el perfil horario como el efecto del día de la semana.
- 3. Casos residuales** — mediana del perfil correspondiente a la combinación mes $\times$ día de la semana $\times$ hora.

La Figura 4.3 muestra la inspección visual del hueco de mayor longitud. El tramo imputado conserva la forma característica del ciclo diario y se integra con continuidad en los valores adyacentes, lo que confirma la idoneidad del procedimiento frente a la alternativa lineal.




Figura 4.3: Inspección del hueco de mayor longitud (18 horas, 6 de marzo de 2022). La franja sombreada corresponde al tramo imputado

Verificación de la distribución

Para comprobar que la imputación no altera la estructura estadística de la serie se comparan las distribuciones antes y después del tratamiento mediante histograma, función de densidad y diagrama de caja (Figura 4.4).




Figura 4.4: Comparativa de la distribución de la demanda antes y después del proceso de imputación

Dado que la imputación afecta únicamente a una pequeña proporción de la serie, la comparación descriptiva antes y después del tratamiento no muestra alteraciones apreciables en la distribución global. El contraste estadístico se emplea como comprobación complementaria y no como demostración de equivalencia. El contraste de Kolmogorov-Smirnov arroja un estadístico $D = 0,00036$ (p -valor $\approx 1,00$), sin evidencia de alteración de la distribución

4.3.3. Análisis de patrones cíclicos mediante series de Fourier

Con carácter previo al modelado se aplica la transformada rápida de Fourier sobre la serie centrada, con objeto de identificar los periodos dominantes de manera objetiva, sin presuponerlos a partir del conocimiento del dominio.




Figura 4.5: Periodograma de la serie de demanda. Escala logarítmica (superior) y detalle de los ciclos de corto plazo (inferior)

El periodograma (Figura 4.5) presenta picos nítidos y aislados en los periodos recogidos en la Tabla 4.2.

Tabla 4.2: Periodos dominantes identificados mediante análisis espectral

Periodo	Interpretación	Origen del patrón
24 h	Ciclo diario	Alternancia entre actividad diurna y descanso nocturno
12 h	Armónico del diario	Estructura de doble pico (mediodía y tarde)
168 h	Ciclo semanal	Diferencia entre días laborables y fin de semana
≈ 84 h	Semi-semanal	Armónico del ciclo semanal

Este resultado tiene consecuencias directas sobre la sección 4.4: los desfases temporales de 24 y 168 horas incorporados como variables predictoras no responden a una elección arbitraria ni a la costumbre, sino que se derivan de la estructura espectral observada en los propios datos.

4.3.4. Descomposición estacional múltiple

La descomposición STL (Cleveland et al., 1990) admite un único periodo estacional. Su extensión MSTL (Bandara et al., 2021) permite el tratamiento simultáneo de varias periodicidades, circunstancia que concurre en las series horarias de demanda.

La presencia simultánea de estacionalidad diaria y semanal impide emplear una descomposición STL convencional, que admite un único periodo. Aplicando STL con periodo 24 la componente semanal no puede ser capturada y se acumula íntegramente en el residuo, generando caídas sistemáticas coincidentes con los fines de semana.

Se recurre por tanto a la descomposición MSTL, que admite periodos múltiples y permite separar ambas componentes (Figura 4.6).




Figura 4.6: Descomposición MSTL de la serie con estacionalidad diaria (24 h) y semanal (168 h). El tramo ascendente inicial del panel de tendencia constituye un artefacto de borde del procedimiento, no un fenómeno real

La Figura 4.7 contrasta ambos residuos y evidencia la mejora: la estructura periódica visible en el residuo de STL desaparece al incorporar el periodo semanal.




Figura 4.7: Comparación del residuo obtenido mediante STL (periodo 24 h) y MSTL (periodos 24 h y 168 h)

La intensidad de cada componente se cuantifica mediante la métrica propuesta por Hyndman y Athanasopoulos (2021), definida como $1 - \text{Var}(R_t) / \text{Var}(S_t + R_t)$, donde S_t y R_t denotan respectivamente la componente estacional y el residuo. La fuerza de la estacionalidad diaria es de 0,947, la de la semanal de 0,876 y la de la tendencia de 0,782

4.3.5. Análisis de autocorrelación

Las funciones de autocorrelación simple y parcial (Figura 4.8) confirman por vía complementaria los hallazgos del análisis espectral, y proporcionan además los órdenes candidatos para la especificación de los modelos ARIMA estacionales (Box et al., 2015).




Figura 4.8: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie de demanda

La ACF muestra máximos locales pronunciados en los retardos múltiplos de 24 horas, con un valor próximo a 0,78 en el retardo 24 y una recurrencia de igual magnitud en el retardo 168, lo que refleja la persistencia conjunta de ambos ciclos.

4.3.6. Identificación de anomalías

La aplicación de la regla del rango intercuartílico sobre la serie completa resultó infructuosa: no identificó ningún valor atípico, con límites situados aproximadamente en 14.000 y 42.000 MW que la serie no alcanza en ningún momento. El motivo es que la propia variación estacional ensancha el rango intercuartílico hasta privarlo de capacidad discriminante. Un consumo de 22.000 MW resulta perfectamente ordinario en la madrugada de un domingo de agosto y marcadamente anómalo un martes de enero a las veinte horas, distinción que una regla global no puede establecer.

Se adopta en consecuencia un procedimiento condicionado al contexto temporal:

1. Se estima el **valor esperado** de cada hora como la mediana del conjunto de observaciones que comparten mes, día de la semana y hora. La mediana se prefiere a la media por su robustez frente a los propios valores extremos que se pretende detectar.
2. Se calcula el **residuo** como diferencia entre el valor observado y el esperado.
3. Se aplica un **z-score robusto** sobre dicho residuo, empleando la mediana y la desviación absoluta mediana (MAD) en lugar de la media y la desviación típica. Se consideran anómalas las observaciones cuyo valor absoluto supera un umbral de 4.

Este procedimiento identifica 555 horas anómalas, equivalentes al 2,11 % de la serie, frente a las cero detectadas por la regla del rango intercuartílico.

Clasificación de las anomalías

Dado que el perfil esperado se construye sobre la agrupación mes $\times$ día de la semana $\times$ hora, los días festivos no quedan recogidos en la línea base y se manifiestan como desviaciones de gran magnitud. Lejos de constituir una deficiencia del procedimiento, esta circunstancia proporciona una medida directa del efecto del calendario sobre la demanda.




Figura 4.9: Anomalías clasificadas según su origen (superior) y distribución del residuo asociado a cada categoría (inferior)

Tabla 4.3: Distribución de las anomalías detectadas según su origen

Origen	Horas	% del total
Festivo	347	62,5
Víspera de festivo	23	4,1
Día posterior a festivo	18	3,2
Sin explicación de calendario	136	24,5

Los resultados de la Tabla 4.3 son concluyentes: un 69,8 % de las anomalías se concentra en días festivos o en su entorno inmediato. El residuo mediano de la categoría *Festivo* se sitúa en torno a -7.000 MW, con casos que alcanzan los -15.500 MW. Sobre un nivel esperado próximo a 28.000 MW, ello representa una reducción cercana al 25 %.

Las 136 anomalías no atribuibles al calendario presentan, por el contrario, un residuo mediano *positivo* y se concentran en los meses estivales, lo que sugiere su asociación con episodios de temperatura extrema. Su análisis individualizado se aborda en el capítulo de resultados.

Criterio de conservación

Ninguna de las observaciones identificadas ha sido eliminada del conjunto de datos. Se trata de comportamiento real del sistema eléctrico —festivos, olas de calor, episodios meteorológicos adversos— y constituye precisamente el tipo de situación que el modelo debe aprender a anticipar. La detección se emplea con finalidad analítica y explicativa, no depurativa.

4.3.7. Relación entre demanda y temperatura

El análisis de la relación entre demanda diaria media y temperatura (Figura 4.10) arroja un resultado de especial relevancia para la especificación del modelo.




Figura 4.10: Relación entre demanda diaria media y temperatura media, con ajuste cuadrático superpuesto (izquierda) y matriz de correlaciones lineales (derecha)

El coeficiente de correlación lineal entre demanda y temperatura media es de **0,089**, valor prácticamente nulo que podría inducir erróneamente a descartar la temperatura como variable explicativa. La representación gráfica revela sin embargo una dependencia clara, de naturaleza **cuadrática**: la demanda aumenta tanto con temperaturas bajas, por efecto de la calefacción, como con temperaturas elevadas, por efecto de la refrigeración, alcanzando su mínimo en el entorno de los 16–17 °C.

Se trata de un caso paradigmático de relación no lineal para la que el coeficiente de correlación de Pearson carece de capacidad descriptiva. Este hallazgo motiva directamente la construcción de los términos cuadráticos y de grados-día descritos en la sección siguiente.

4.3.8. Perfiles de consumo

Los perfiles agregados (Figura 4.11) sintetizan la estructura temporal de la demanda y resultan coherentes con el comportamiento documentado para el sistema peninsular español.




Figura 4.11: Perfiles de consumo: perfil horario por día de la semana, distribución mensual, comparación entre días laborables y no laborables, y mapa de calor hora $\times$ mes

El mapa de calor resulta particularmente ilustrativo, al mostrar el carácter dual del consumo español: máximo vespertino en los meses invernales, asociado a iluminación y calefacción, y máximo de mediodía en julio y agosto, atribuible a la refrigeración.

4.4. Ingeniería de características

Las variables predictoras no se han seleccionado por convención, sino que se derivan de los hallazgos del análisis exploratorio expuestos en la sección anterior. La Tabla 4.4 recoge el conjunto construido junto con la justificación empírica de cada bloque.

Tabla 4.4: Variables predictoras empleadas en la evaluación (42). Con asterisco, las 30 que utiliza el modelo de la aplicación

Bloque	Variables	Justificación
Desfases temporales	lag_24h*, lag_25h*, lag_48h*, lag_168h*	Periodos dominantes del análisis de Fourier (Tabla 4.2). Los desfases de 1 a 3 horas se descartan por fuga de información (sección 4.4.3)
Estadísticos móviles	media24_h24*, std24_h24*, media168_h24*, std168_h24*	Nivel y variabilidad recientes, con la ventana desplazada el horizonte completo
Calendario numérico	hora*, dia_sem*, dia_mes*, mes*, anio	Posición en el calendario, aprovechable por los modelos de árboles
Codificación cíclica	hora_sin*, hora_cos*, dia_sem_sin*, dia_sem_cos*, mes_sin*, mes_cos*	Continuidad circular del tiempo entre las 23 y las 0 horas
Calendario binario	festivo, vispera_festivo, post_festivo, laborable, finde*	El 69,8 % de las anomalías se concentra en festivos y su entorno (Tabla 4.3). Referido a la Comunidad de Madrid
Calendario ponderado por población	intensidad_festivo*, intensidad_vispera*, intensidad_post*, festivo_nacional*, festivo_parcial, laborable_efectivo*	Recoge el alcance territorial de cada festividad (sección 5.5)
Temperatura	tmed*, tmax*, tmin*, tmed_sq*, grados_frio*, grados_calor*	Relación cuadrática con la demanda (Figura 4.10)
Otras variables meteorológicas	hrMedia, prec, presMax, presMin, racha, velmedia	Disponibles en la climatología diaria de AEMET

La evaluación comparativa del capítulo 5 emplea el conjunto completo de 42 variables. El modelo de la aplicación utiliza un subconjunto de 30, por dos motivos: en tiempo real, la predicción municipal de AEMET proporciona la temperatura pero no el resto de variables climatológicas, y las variables binarias referidas a la Comunidad de Madrid quedan sustituidas por la intensidad ponderada por población.

4.4.1. Codificación cíclica de las variables temporales

Las variables de calendario presentan naturaleza circular: la hora 23 es adyacente a la hora 0, y el mes de diciembre al de enero. Su codificación como enteros introduciría una discontinuidad artificial en dicha transición. Se recurre por ello a una representación mediante pares de funciones trigonométricas:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right) \quad (4.1)$$

donde t denota el valor de la variable y T su periodo (24 para la hora, 7 para el día de

la semana y 12 para el mes). De este modo, valores temporalmente próximos resultan también próximos en el espacio de características.

4.4.2. Términos de temperatura

Dado el carácter cuadrático de la relación entre demanda y temperatura, se incorporan tres transformaciones adicionales. La primera es el término cuadrático t_{med}^2 . Las dos restantes corresponden a los conceptos de grados-día de calefacción y refrigeración, de uso habitual en el análisis energético (Hong & Fan, 2016):

$$GD_{frío} = \max(0, 18 - t_{med}), \quad GD_{calor} = \max(0, t_{med} - 22) \quad (4.2)$$

Estas variables permiten a los modelos lineales capturar la forma en U de la relación, que de otro modo quedaría fuera de su alcance.

4.4.3. Prevención de fuga de información

La construcción de variables a partir de la propia serie objetivo expone el procedimiento a la fuga de información, que constituye el riesgo metodológico principal en la aplicación de aprendizaje automático a series temporales.

Formulación del problema

Para un horizonte de veinticuatro horas, la predicción del instante $t + 24$ debe elaborarse desde el instante t . En ese momento, la disponibilidad efectiva de cada variable es la que recoge la Tabla 4.5.

Tabla 4.5: Disponibilidad de las variables en el instante de predicción

Variable en $t + 24$	Equivale a	¿Conocida en t ?
lag_1h	y_{t+23}	No
lag_2h	y_{t+22}	No
lag_3h	y_{t+21}	No
lag_24h	y_t	Sí
lag_168h	y_{t-144}	Sí
media_24h	media de $t \dots t + 23$	No
media_168h	ventana que alcanza $t + 23$	No
Calendario	conocido con antelación	Sí
Meteorología	solo como previsión	Parcialmente

La meteorología merece una precisión. Las variables de calendario se conocen con certeza en el instante de predicción, pero la temperatura del horizonte futuro únicamente está disponible como **previsión**, afectada por su propio error. La evaluación retrospectiva de este trabajo emplea las observaciones registradas.

Merece atención el caso de los estadísticos móviles. Su construcción en el análisis exploratorio empleó un desplazamiento de una posición, adecuado para predicción a un

paso. Para un horizonte de veinticuatro horas, sin embargo, la ventana de `media_24h` en el instante $t + 24$ abarca de t a $t + 23$, tramo en su mayor parte desconocido. **La contaminación no se limita por tanto a los desfases de orden reducido**, extremo que no resulta evidente a simple vista.

Criterio adoptado

Se establece la regla siguiente: para un horizonte de h periodos únicamente son admisibles los desfases de orden $k \geq h$ y los estadísticos móviles cuya ventana se cierre antes del instante de predicción. En consecuencia:

- Se descartan `lag_1h`, `lag_2h` y `lag_3h`.
- Se descartan los estadísticos móviles del análisis exploratorio y se recalculan desplazando la serie el horizonte completo.
- Se conservan los desfases de 24, 25, 48 y 168 horas, así como las variables de calendario y meteorológicas.

Cuantificación del efecto

El efecto de la fuga no se ha asumido, sino medido. Entrenando el mismo modelo con ambos conjuntos de variables sobre idénticos orígenes de validación se obtiene que, **en el experimento realizado**, la incorporación de variables temporalmente no disponibles reduce artificialmente el error observado en torno a un 55%. La cifra no constituye una cuantificación general del fenómeno, sino una ilustración de la magnitud que puede alcanzar la fuga de información temporal en este problema concreto.

Dicho de otro modo: un modelo que incorporase los desfases de orden reducido aparentaría un rendimiento sustancialmente superior al que alcanzaría en explotación, donde esas variables sencillamente no están disponibles. La magnitud del efecto justifica el tratamiento explícito que recibe esta cuestión.

4.5. Estrategia de validación

Improcedencia de la validación cruzada aleatoria

La validación cruzada por particiones aleatorias, procedimiento estándar en aprendizaje supervisado, resulta **metodológicamente inadmisibile** en series temporales. Al asignar observaciones a los conjuntos de entrenamiento y prueba sin atender a su orden, el modelo se entrena con datos posteriores a aquellos que debe predecir. Las métricas resultantes son optimistas y carecen de correspondencia con el comportamiento en explotación.

Validación de origen rodante

Se adopta en su lugar la validación de origen rodante (*rolling origin* o *walk-forward*). El procedimiento fija un instante de corte, entrena con la totalidad de las observaciones anteriores, predice las veinticuatro horas siguientes y repite la operación desplazando el corte:

```
Origen 1: [----- entrenamiento -----] [test]
Origen 2: [----- entrenamiento -----] [test]
Origen 3: [----- entrenamiento -----] [test]
```

Este esquema reproduce las condiciones de explotación: en cada origen el modelo dispone exclusivamente de información anterior al instante de predicción.

Elección del paso entre orígenes

La separación entre orígenes exige una precaución que no siempre se explicita en la literatura. Una primera configuración empleó un paso de ciento sesenta y ocho horas —exactamente una semana— con el propósito de cubrir un periodo amplio. El resultado fue que **los catorce orígenes recayeron sobre el mismo día de la semana**, de modo que la evaluación excluía por completo sábados y domingos.

El sesgo introducido no era neutral. Beneficiaba específicamente a los modelos que predicen a partir del día anterior, pues todos los días evaluados eran laborables precedidos de laborables. Detectada la anomalía, se sustituyó el paso por ciento veinte horas —cinco días—, valor que no es múltiplo de la semana y que con catorce orígenes proporciona exactamente dos observaciones de cada día. Al repetir la evaluación, el error del modelo ingenuo diario se elevó de forma apreciable, lo que confirmó el diagnóstico.

La configuración definitiva es por tanto:

- Horizonte de predicción: 24 horas
- Número de orígenes: 14
- Separación entre orígenes: 120 horas (5 días)
- Periodo cubierto: aproximadamente 70 días

Las catorce ventanas descritas constituyen un protocolo de **validación temporal del desarrollo**. Dado que se sitúan dentro del periodo analizado en la fase exploratoria, sus resultados deben interpretarse en consecuencia como una estimación condicionada al proceso de desarrollo, circunstancia recogida entre las limitaciones del trabajo.

Evaluación complementaria en días festivos

El esquema anterior distribuye los orígenes de forma regular, por lo que la coincidencia con un día festivo queda librada al azar. En la evaluación realizada ningún origen

recayó sobre una festividad, circunstancia que habría dejado sin contrastar el hallazgo principal del análisis exploratorio.

Se construyó en consecuencia un conjunto de evaluación **dirigido**, seleccionando ocho orígenes de modo que el día completo a predecir fuese festivo. Este conjunto está deliberadamente sesgado hacia casos difíciles y no representa el rendimiento medio del sistema; se reporta como análisis complementario en la sección 5.5.

4.6. Modelos desarrollados

Se han evaluado diez formulaciones, organizadas en tres niveles de complejidad creciente. Todas comparten el mismo esquema de validación, los mismos orígenes y las mismas métricas, de modo que la comparación resulta homogénea.

4.6.1. Línea base

Modelos ingenuos

Antes de cualquier formulación estadística se establece el error que se obtiene sin modelo alguno. Se consideran tres alternativas:

1. **Ingenuo diario**: la demanda de cada hora del día siguiente coincide con la observada a esa misma hora del día actual.
2. **Ingenuo semanal**: coincide con la del mismo día de la semana anterior. A diferencia del anterior, recoge el efecto laborable/festivo.
3. **Perfil semanal**: media por hora del día sobre las cuatro últimas semanas.

La inclusión de estas referencias responde a una observación recurrente en la literatura (Hong & Fan, 2016): un número considerable de trabajos publicados presenta mejoras que en realidad no superan la predicción ingenua estacional.

Modelos estadísticos clásicos

SARIMA. Se ajusta un modelo $SARIMA(2, 0, 1)(1, 1, 1)_{24}$, con órdenes orientados por las funciones de autocorrelación. El elevado coste computacional del ajuste con periodo estacional 24 obliga a restringir el entrenamiento a una ventana de sesenta días.

SARIMAX con términos de Fourier. Alternativa que representa las estacionalidades diaria, semanal y anual mediante pares seno-coseno introducidos como regresores externos, reservando la parte ARIMA para la autocorrelación de corto plazo. La comparación de tiempos de ajuste justifica empíricamente esta elección: mientras el SARIMA clásico requiere del orden de 15 segundos sobre una ventana reducida, la formulación con Fourier procesa el último año de datos (8.760 horas) en 3,6 segundos.

Una primera especificación de este modelo empleó $d = 0$ sin término constante. La inspección de los resultados reveló un sesgo sistemático —subestimación en los periodos de demanda elevada y sobrestimación en los de demanda reducida— característico

de la reversión a la media del conjunto de entrenamiento. La corrección consistió en aplicar una diferenciación de primer orden, con lo que el modelo opera sobre incrementos y se adapta al nivel local.

Prophet. Se configura con estacionalidad diaria, semanal y anual, e incorpora el calendario de festivos con ventanas de un día a cada lado para recoger el efecto de arrastre.

4.6.2. Modelos de aprendizaje automático

Se evalúan cuatro formulaciones sobre el conjunto de variables descrito en la sección 4.4:

- **Ridge.** Regresión lineal con regularización L_2 , precedida de estandarización. Actúa como referencia lineal y permite aislar la aportación de la no linealidad.
- **Random Forest** (Breiman, 2001). Cien árboles, profundidad máxima doce y diez observaciones mínimas por hoja. La configuración es deliberadamente contenida: el procedimiento de validación exige catorce reentrenamientos sobre más de veinte mil observaciones, y una parametrización más ambiciosa resultaba impracticable.
- **XGBoost** (Chen & Guestrin, 2016). Cuatrocientos árboles, tasa de aprendizaje 0,05, profundidad máxima siete, submuestreo de observaciones y variables al 80 %.
- **LightGBM** (Ke et al., 2017). Parámetros equivalentes, con cuarenta y ocho hojas por árbol.

4.6.3. Sobre la optimización de hiperparámetros

No se ha realizado una búsqueda sistemática de hiperparámetros. La decisión es deliberada y se fundamenta en dos consideraciones.

En primer lugar, los resultados obtenidos con configuraciones convencionales superan holgadamente los umbrales fijados en los objetivos del trabajo, por lo que el margen de mejora esperable no justifica el coste computacional de una búsqueda exhaustiva.

En segundo lugar, y con mayor peso, la evidencia acumulada en las competiciones M (Makridakis et al., 2022) indica que la calidad de las variables construidas determina el rendimiento en mayor medida que el ajuste fino de los hiperparámetros. El esfuerzo se ha concentrado en consecuencia sobre la ingeniería de características, guiada por el análisis exploratorio.

La optimización mediante Optuna se recoge como línea de trabajo futuro.

4.7. Métricas de evaluación

Se emplean cuatro métricas complementarias, ninguna de las cuales resulta suficiente por sí sola.

El **error absoluto medio** expresa la desviación en megavatios y resulta directamente interpretable, si bien depende de la escala:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.3)$$

La **raíz del error cuadrático medio** penaliza en mayor medida las desviaciones grandes, lo que la hace sensible a los valores extremos:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.4)$$

El **error porcentual absoluto medio** es adimensional y constituye la referencia habitual en la literatura sobre predicción de carga, lo que permite contrastar los resultados con los trabajos publicados:

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (4.5)$$

El **error porcentual absoluto medio simétrico** corrige la asimetría del anterior frente a sobrestimaciones e infraestimaciones:

$$\text{sMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{2 |y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \quad (4.6)$$

Media y mediana

Las métricas se calculan sobre cada uno de los catorce orígenes y se resumen mediante media y mediana. La distinción no es accesorio: un único día atípico —una festividad, un episodio meteorológico extremo— puede duplicar la media sin que ello refleje el comportamiento habitual del modelo.

Se reportan por tanto ambos estadísticos, junto con la desviación típica entre orígenes y el peor caso observado. La mediana constituye el criterio principal de ordenación, por su robustez frente a valores extremos.

Métricas de entrenamiento y de producción

Siguiendo la indicación expresa de la dirección del trabajo, se registran conjuntamente el error dentro de muestra —sobre las observaciones de entrenamiento— y fuera de muestra —sobre las predicciones efectivas—. Una diferencia sustancial entre ambos indica que el modelo memoriza en lugar de generalizar.

Debe precisarse un matiz relativo a los modelos estadísticos: en ellos el ajuste dentro de muestra corresponde a una predicción de un paso adelante, mientras que la evaluación se realiza a veinticuatro pasos. La comparación resulta en consecuencia poco

informativa. En los modelos de aprendizaje automático, en cambio, ambos errores se calculan sobre el mismo horizonte y la diferencia sí es interpretable.

4.8. Desarrollo de la aplicación web

Diseño funcional

La aplicación se dirige a un usuario sin formación técnica en el ámbito energético. Su función es traducir la predicción numérica en una recomendación comprensible. Se estructura en cinco bloques:

1. **Indicadores de situación:** demanda actual, máximo y mínimo previstos, y franja horaria más favorable.
2. **Recomendación en lenguaje natural**, generada automáticamente a partir de la predicción.
3. **Representación gráfica** de la serie histórica y la previsión, con las franjas recomendadas destacadas.
4. **Tabla de horas** ordenada por demanda prevista, con el precio de mercado cuando está disponible.
5. **Contexto meteorológico** y nota metodológica sobre el modelo y sus limitaciones.

Tecnologías empleadas

La interfaz se ha desarrollado con Streamlit (Streamlit Inc., [2025](#)), entorno que permite construir aplicaciones de datos en Python sin requerir desarrollo específico de interfaz. Las representaciones gráficas emplean Plotly, y el modelo se serializa mediante joblib.

Obtención de datos en tiempo real

La aplicación consulta tres fuentes en cada ejecución. La demanda reciente se obtiene de la interfaz REData, en bloques de siete días: las peticiones de mayor amplitud provocan errores de servidor, dado que el servicio publica con resolución de diez minutos. La previsión meteorológica procede del servicio de predicción horaria municipal de AEMET, con horizonte de cuarenta y ocho horas. Dado que el modelo se entrenó con valores diarios —media, máxima y mínima de cada jornada—, la previsión horaria se **agrega a esa misma resolución** antes de construir las variables. De este modo, la magnitud que recibe el modelo en explotación es conceptualmente idéntica a la empleada durante el entrenamiento. El precio de mercado se recupera igualmente de REData, con carácter complementario.

Predicción más allá del horizonte nativo

El modelo se ha entrenado para un horizonte de veinticuatro horas, límite impuesto por la disponibilidad de los desfases: predecir el instante $t + 25$ requeriría conocer $t + 1$, aún no observado.

Para alcanzar las cuarenta y ocho horas se aplica un **esquema recursivo**: las predicciones del primer tramo se incorporan a la serie y se emplean para calcular los desfases del segundo. El procedimiento acumula error, circunstancia que se cuantifica en el capítulo de resultados y de la que se advierte al usuario en la propia interfaz.

Ejecución de la aplicación

La aplicación se ejecuta en local a partir del repositorio del trabajo (Anexo A), siguiendo las instrucciones de su fichero README. El modelo serializado se genera mediante el notebook de entrenamiento final, y las credenciales de AEMET se gestionan mediante variables de entorno, excluidas del control de versiones. En ausencia de dichas credenciales, la aplicación recurre a una estimación climatológica de la temperatura y lo advierte en pantalla.

4.9. Uso de herramientas de inteligencia artificial generativa

En la elaboración de este trabajo se han empleado ChatGPT (OpenAI, 2026) y Claude (Anthropic, 2026). Su uso se ha limitado a las tareas de apoyo que se describen a continuación.

- **Búsqueda bibliográfica.** Localización preliminar de trabajos sobre predicción de demanda eléctrica. Cada referencia sugerida se comprobó en la fuente original antes de incorporarse.
- **Apoyo en el código.** Consultas sobre bibliotecas y diagnóstico de errores en la descarga de datos. Todo el código se ejecutó, probó y validó por el autor.
- **Revisión formal.** Corrección ortográfica y de estilo sobre texto redactado previamente por el autor.

Integración en el trabajo. Las aportaciones de estas herramientas se han tratado como colaboraciones y no como obra original.

Límite ético. No se ha delegado en estas herramientas el planteamiento del problema, el diseño metodológico, el análisis crítico de los resultados ni la formulación de las conclusiones, de cuya exactitud y originalidad el autor asume la plena responsabilidad.

Trazabilidad. Los prompts, las respuestas relevantes, la fecha y la herramienta de cada interacción se recogen en el repositorio de transparencia referenciado en el Anexo B.

5. Evaluación y resultados

5.1. Resultados del análisis exploratorio

El análisis exploratorio ha permitido caracterizar la serie de demanda y, sobre todo, fundamentar empíricamente las decisiones de modelado. Se sintetizan a continuación los hallazgos de mayor relevancia.

5.1.1. Calidad de la fuente de datos

La serie descargada presenta una completitud del 99,66 %, con 90 registros ausentes sobre 26.304 esperados. Dichas ausencias se concentran en unos pocos tramos, lo que apunta a incidencias puntuales del sistema de publicación y no a un problema sistemático de la fuente. No se ha detectado ningún valor físicamente inconsistente.

5.1.2. Estructura temporal

El análisis espectral confirma la existencia de tres escalas de periodicidad —diaria, semanal y anual— y de un armónico de doce horas correspondiente a la estructura de doble pico. La descomposición MSTL cuantifica la intensidad de cada componente y muestra que la estacionalidad diaria es la dominante.

Este resultado tiene implicaciones prácticas: cualquier modelo que aspire a un rendimiento competitivo deberá incorporar explícitamente ambas periodicidades, bien mediante términos estacionales en el caso de las formulaciones ARIMA, bien mediante desfases temporales en los modelos de aprendizaje automático.

5.1.3. Efecto del calendario

El resultado de mayor valor para la fase de modelado procede de la clasificación de anomalías. Casi el 70 % de las desviaciones significativas respecto al perfil esperado se explica por el calendario, con un efecto mediano en los días festivos próximo a los -7.000 MW.

La magnitud del efecto convierte la inclusión de variables de calendario en un requisito y no en una opción: se trata de la mayor fuente identificada de variación no capturada por la estructura cíclica ordinaria.

5.1.4. Relación con la temperatura

El coeficiente de correlación lineal entre demanda y temperatura, de 0,089, resulta engañoso si se interpreta aisladamente. La inspección gráfica revela una dependencia cuadrática nítida con mínimo en torno a los $16\text{--}17$ °C, coherente con la superposición de las demandas de calefacción y refrigeración.

Este hallazgo condiciona la selección de modelos. Las formulaciones lineales requieren la incorporación explícita de términos cuadráticos o de grados-día para aprovechar la información térmica, mientras que los modelos basados en árboles de decisión pueden capturar la no linealidad de forma automática, si bien, como se verá en la sección 6.4, la aportación efectiva de la temperatura diaria resulta limitada.

5.2. Comparativa de rendimiento de los modelos

La Tabla 5.1 recoge el rendimiento de las diez formulaciones evaluadas, ordenadas por error mediano. Todas comparten los mismos catorce orígenes de validación, el mismo horizonte y las mismas métricas.

Tabla 5.1: Comparativa de rendimiento de los modelos evaluados

Modelo	MAPE medio	MAPE mediana	Desv. típica	Peor caso	MAE (MW)	Frente al ingenuo
<i>Aprendizaje automático</i>						
XGBoost	1,65	1,34	0,70	3,10	470	+56,3 %
Random Forest	1,86	1,47	0,98	3,98	520	+52,1 %
LightGBM	1,67	1,53	0,75	3,71	473	+49,9 %
Ridge	2,55	1,94	1,56	6,22	717	+36,6 %
<i>Línea base estadística</i>						
SARIMA clásico	3,95	2,42	2,98	10,29	1.120	+20,9 %
Prophet	4,86	4,78	1,28	7,34	1.370	−56,4 %
SARIMAX + Fourier	5,66	4,90	3,18	13,02	1.565	−60,3 %
<i>Modelos ingenuos</i>						
Ingenuo semanal	3,92	3,06	2,64	10,35	1.108	referencia
Ingenuo diario	4,98	3,21	4,57	15,36	1.387	−5,0 %
Perfil semanal	8,54	8,30	3,33	13,60	2.434	−171,2 %

Resultado principal

El modelo XGBoost alcanza un error mediano del **1,34 %**, lo que supone una mejora del **56,3 %** sobre la mejor línea base ingenua. En términos absolutos, el error absoluto medio de 470 MW representa un 1,7 % sobre una demanda media de 28.263 MW.

Ambas cifras superan holgadamente los umbrales establecidos en los objetivos del trabajo —MAPE inferior al 8 % y MAE por debajo del 5 % de la demanda media— y se sitúan en el orden de magnitud que maneja el propio operador del sistema en sus previsiones a día vista.

Los modelos estadísticos no superan la línea base

Un resultado que merece reportarse con la misma claridad es que **Prophet y SARIMAX con términos de Fourier obtienen peores resultados que la predicción ingenua semanal**. Únicamente el SARIMA clásico logra superarla, con una mejora del 20,9 %.

Este hallazgo no constituye una anomalía. La predicción ingenua estacional es una referencia exigente en demanda eléctrica, precisamente porque la serie presenta una estructura semanal muy marcada. La observación de Hong y Fan (2016) sobre la ausencia habitual de comparación con líneas base cobra aquí pleno sentido: un trabajo que hubiese omitido estos modelos ingenuos habría presentado a Prophet como una aportación valiosa cuando en realidad no mejora la alternativa trivial.

En el caso de SARIMAX, el análisis por origen revela que sus dos peores resultados corresponden a domingos. La causa es identificable: con dos armónicos para el periodo de ciento sesenta y ocho horas, la forma semanal representable es una senoide suave, incapaz de reproducir la transición abrupta entre días laborables y fin de semana.

Estabilidad frente a precisión

La columna de desviación típica introduce un matiz relevante. El modelo ingenuo diario presenta una mediana aceptable (3,21 %) pero la mayor dispersión de todo el conjunto (4,57), con un peor caso del 15,36 %. El análisis por origen muestra que sus fallos se concentran en los lunes, con errores del 15,36 % y el 13,94 %, frente a valores próximos al 2 % en el resto. La explicación es inmediata: predice el lunes a partir del domingo.

Se trata de un modelo que funciona razonablemente bien la mayor parte del tiempo y falla de forma severa en circunstancias identificables. En un contexto de explotación, esa característica resulta más problemática que un error medio ligeramente superior pero estable.

El contraste con Prophet ilustra el compromiso. Prophet obtiene el peor error mediano de las formulaciones estadísticas (4,78 %), pero la menor desviación típica con diferencia (1,28): nunca destaca y nunca falla estrepitosamente.

Control del sobreajuste

La Tabla 5.2 recoge la comparación entre el error de entrenamiento y el de producción para los modelos de aprendizaje automático, donde ambos se calculan sobre el mismo horizonte y la comparación resulta por tanto interpretable.

Tabla 5.2: Error de entrenamiento frente a error de validación temporal

Modelo	Entrenamiento	Producción	Diferencia
XGBoost	0,67 %	1,65 %	+146 %
LightGBM	0,83 %	1,67 %	+101 %
Random Forest	1,38 %	1,86 %	+34 %
Ridge	2,99 %	2,55 %	−14 %

XGBoost presenta la mayor diferencia relativa, consecuencia esperable de su configuración con cuatrocientos árboles de profundidad siete. Random Forest exhibe la menor, coherente con su parametrización más restrictiva —profundidad doce y diez obser-

vaciones mínimas por hoja—, que penaliza la precisión a cambio de una mayor capacidad de generalización.

El dato de Ridge requiere interpretación específica: su error de validación temporal es **inferior** al de entrenamiento. Ello no responde a ninguna singularidad del modelo, sino a que **el periodo de evaluación resulta más benigno que la media del histórico de entrenamiento**. Las catorce ventanas se sitúan entre octubre y diciembre de 2024, tramo relativamente estable, mientras que el entrenamiento abarca tres años que incluyen la volatilidad de 2022.

La implicación afecta a la lectura del resto de la tabla: si el conjunto de evaluación es más favorable que la media, las diferencias de los modelos de árboles están **infravaloradas**. En un periodo de mayor variabilidad cabría esperar una separación superior. Esta circunstancia se recoge entre las limitaciones del trabajo.

Selección del modelo

XGBoost obtiene el mejor resultado en error mediano y en error absoluto medio, por lo que se selecciona como modelo definitivo. En la evaluación dirigida sobre festivos, sin embargo, LightGBM obtiene un error inferior (3,01 % frente a 3,32 %), lo que refuerza su condición de alternativa defendible.

Además su rendimiento en producción es prácticamente equivalente (1,67 % frente a 1,65 % de error medio), presenta la mitad de diferencia entre entrenamiento y producción, y su tiempo de ajuste es sensiblemente menor. En un escenario que exigiese reentrenamiento frecuente, esas propiedades podrían inclinar la elección.

5.3. Análisis de la importancia de variables




Figura 5.1: Importancia de las variables en el modelo seleccionado

El análisis de importancia responde al objetivo específico OE6, relativo a la identificación de las variables con mayor contribución predictiva.

Valores SHAP

La importancia nativa de los modelos de árboles indica con qué frecuencia se emplea cada variable, pero no en qué dirección ni bajo qué condiciones. Los valores SHAP (Lundberg & Lee, 2017) descomponen cada predicción individual en la contribución aditiva de cada predictor, lo que permite un análisis más matizado.




Figura 5.2: Valores SHAP del modelo seleccionado

El análisis de importancia sitúa en las primeras posiciones los desfases de **168 y 24 horas**, seguidos de la variable `laborable_efectivo`. El orden resulta consistente con los hallazgos del análisis exploratorio: el periodograma identificó los ciclos de 24 y 168 horas como los dominantes (Tabla 4.2), y la clasificación de anomalías situó en los días festivos y su entorno cerca del 70 % de las desviaciones significativas (Tabla 4.3).

Que las tres variables de mayor contribución se correspondan con los dos patrones identificados por vías independientes —análisis espectral y detección de anomalías— aporta consistencia interna al procedimiento seguido.

Los valores SHAP permiten precisar el sentido de cada contribución. Los desfases de 168 y 24 horas presentan una relación **creciente**: los valores elevados de la demanda registrada una semana y un día antes, representados en tono rojizo, se asocian a contribuciones positivas, mientras que los valores reducidos desplazan la predicción a la baja. Es el comportamiento esperable de una serie con fuerte persistencia, y ambos desfases presentan además la mayor dispersión de contribuciones, del orden de varios miles de megavatios.

La variable `laborable_efectivo` ocupa la tercera posición con un patrón nítido: los valores próximos a cero —días no laborables— concentran contribuciones negativas, y

los próximos a la unidad, positivas. Su dispersión es sensiblemente menor que la de los desfases, lo que sugiere que actúa como un ajuste de nivel sobre la predicción base antes que como determinante principal.

La variable `intensidad_festivo` contribuye en sentido **negativo**: las intensidades próximas a la unidad, correspondientes a festividades de alcance nacional, desplazan la predicción a la baja, mientras que los valores nulos apenas alteran la contribución. La dirección coincide con lo observado en el análisis exploratorio.

Conviene precisar un aspecto de la atribución. El descenso asociado a `intensidad_festivo` es de menor magnitud que el efecto mediano de -7.000 MW estimado en el análisis de anomalías. La discrepancia no indica inconsistencia, sino que la atribución se reparte entre variables correlacionadas: `laborable_efectivo` se define como el producto del indicador de día entre semana por el complemento de la intensidad de festivo, de modo que ya incorpora esa información. Los valores SHAP distribuyen el efecto del calendario entre ambas variables en lugar de concentrarlo en una sola. Lo mismo ocurre con la variable binaria `laborable`, referida a la Comunidad de Madrid, que el modelo de evaluación conserva junto a `laborable_efectivo` y que aparece en séptima posición.

Las variables de temperatura ocupan posiciones **intermedias**: `tmin` y `tmax` se sitúan en la mitad de la clasificación, y los términos derivados `—grados_frio` y los estadísticos móviles— en las últimas posiciones representadas. Sus contribuciones presentan además una dispersión reducida frente a la de los desfases.

Resulta compatible con lo observado respecto al efecto de la meteorología: su aportación es moderada frente a la de los desfases de la propia serie. Ambas vías convergen en que, para un horizonte de veinticuatro horas, la información contenida en la propia serie prevalece sobre la meteorológica.

*Debe subrayarse que los valores SHAP describen **el comportamiento del modelo**, no relaciones causales del sistema eléctrico. Que una variable presente una contribución predictiva elevada indica que el modelo se apoya en ella para elaborar sus predicciones, no que determine físicamente la demanda. La interpretación anterior debe entenderse, por tanto, en términos de asociación con las predicciones y no de causalidad.*

5.4. Análisis de errores

Las métricas agregadas ocultan la distribución del error. Esta sección examina dónde falla el modelo, con especial atención a si corrige las deficiencias detectadas en la línea base.

Error según el tipo de día

La Tabla 5.3 recoge el error desagregado entre días laborables y fines de semana.

Tabla 5.3: Error según el tipo de día (modelos de aprendizaje automático)

Modelo	Laborable	Fin de semana	Diferencia
XGBoost	1,59 %	1,82 %	0,23
LightGBM	1,61 %	1,83 %	0,22
Random Forest	1,67 %	2,34 %	0,67
Ridge	2,42 %	2,88 %	0,46

La diferencia entre ambos tipos de día resulta reducida en los modelos de potencia-ción del gradiente, lo que indica que las variables de calendario cumplen su función.

Corrección de las deficiencias de la línea base

El análisis por origen de la fase anterior había identificado dos patrones de fallo: el modelo ingenuo diario se degradaba los lunes y SARIMAX los domingos. La Tabla 5.4 compara el comportamiento en esos mismos orígenes.

Tabla 5.4: Error en los orígenes problemáticos de la línea base

Origen	Modelo deficiente	Línea base	XGBoost
Lunes 28-oct	Ingenuo diario	15,36 %	3,10 %
Lunes 2-dic	Ingenuo diario	13,94 %	1,85 %
Domingo 17-nov	SARIMAX	11,18 %	1,03 %
Domingo 22-dic	SARIMAX	13,02 %	1,30 %
Viernes 27-dic	Ingenuo semanal	10,35 %	1,37 %

La corrección es sistemática y de magnitud considerable. Confirma la hipótesis formulada al analizar la línea base: los fallos identificados obedecían a la ausencia de información de calendario, y los modelos que la incorporan los resuelven.

Comportamiento lineal frente a no lineal

Un resultado con valor explicativo se obtiene al comparar Ridge con los modelos de árboles en esos mismos orígenes. Ridge mantiene errores del 6,30 % y el 5,10 % en los lunes problemáticos, y del 4,06 % en uno de los domingos, mientras las tres formulaciones basadas en árboles se sitúan por debajo del 3 %.

La circunstancia resulta ilustrativa porque **Ridge dispone exactamente de las mismas variables**, incluida la indicadora de día laborable. Su limitación es estructural: al ser lineal, únicamente puede sumar un efecto constante asociado al tipo de día, sin capturar que **dicho efecto depende de la hora**. Un lunes a las cuatro de la madrugada se asemeja considerablemente a un domingo, mientras que a las nueve de la mañana la diferencia es máxima. Esa interacción entre hora y día de la semana solo la reproducen los modelos capaces de representar relaciones no lineales.

Distribución del error a lo largo del día

El error presenta un mínimo en torno a las cinco de la madrugada (0,96 %) y un máximo a las diecisiete horas (2,63 %). El patrón es coherente con la estructura del problema: las horas de rampa —el ascenso matinal y el pico vespertino— concentran la mayor incertidumbre, mientras que el valle nocturno resulta altamente predecible.

Calidad global del ajuste

El coeficiente de correlación entre valores observados y predichos alcanza 0,9931, con un error máximo de 1.948 MW sobre una demanda media de 28.263 MW. El sesgo medio es de -204 MW, lo que indica una ligera tendencia a la infraestimación (aproximadamente un 0,72 % de la demanda media), magnitud relativa reducida.

5.5. Evaluación en días festivos

El análisis exploratorio estableció que cerca del 70 % de las anomalías se concentraba en días festivos, y sobre esa base se incorporaron las variables de calendario. Procede verificar de forma explícita que dichas variables cumplen su cometido, para lo cual se emplea el conjunto de evaluación dirigido descrito en la sección 4.5.

Tabla 5.5: Rendimiento en los ocho días festivos evaluados

Modelo	MAPE en festivos	Peor festivo	MAPE ordinario	Penalización
LightGBM	3,01 %	5,81 %	1,67 %	1,80
XGBoost	3,32 %	7,02 %	1,65 %	2,01
Random Forest	4,10 %	8,31 %	1,86 %	2,21
Ingenuo diario	14,12 %	19,52 %	4,98 %	2,84
Ingenuo semanal	16,63 %	40,68 %	3,92 %	4,24

La columna de penalización expresa el cociente entre el error en festivo y el error en día ordinario. Un valor próximo a la unidad indicaría que el modelo aprovecha íntegramente la información de calendario.

El caso más ilustrativo corresponde al 25 de diciembre: el modelo ingenuo semanal alcanza un error del **40,68 %**, frente al **4,74 %** de XGBoost. La diferencia es de casi un orden de magnitud y responde a una causa evidente: el modelo ingenuo compara la Navidad con el miércoles precedente, mientras que el modelo de aprendizaje automático dispone de la indicación de festividad.

Festivos nacionales y autonómicos

Una primera versión de este análisis reveló un patrón inesperado. Los modelos de aprendizaje automático superaban ampliamente a la línea base en los festivos nacionales, pero no en los autonómicos, donde el error resultaba comparable e incluso superior.

La causa admite una explicación precisa. La serie de demanda es **peninsular**, mientras que el calendario empleado correspondía a la **Comunidad de Madrid**. El 2 de mayo, festividad exclusivamente madrileña, el modelo recibía la indicación de festivo y anticipaba una caída pronunciada del consumo; sin embargo, el resto del país mantenía su actividad ordinaria y la demanda apenas descendía.

La solución adoptada sustituye la variable binaria por una **intensidad ponderada por población**: la fracción de habitantes del territorio nacional para los que cada fecha constituye día festivo. Se consulta a tal efecto el calendario de las diecinueve subdivisiones y se pondera por población.

Tabla 5.6: Intensidad de festivo según el alcance territorial

Fecha	Festividad	Comunidades	Intensidad
25 de diciembre	Natividad del Señor	19	1,000
28 de marzo	Jueves Santo	17	0,725
25 de julio	Santiago Apóstol	5	0,271
2 de mayo	Fiesta de la Comunidad de Madrid	1	0,143

Resulta pertinente señalar que una simple distinción binaria entre festivos nacionales y autonómicos tampoco habría resuelto el problema. El Jueves Santo figura como autonómico en las fuentes de calendario, pero afecta en realidad al 72,5 % de la población. La representación mediante una magnitud continua es la única que recoge adecuadamente este matiz.

Efecto de la corrección

El resultado sobre los dos casos problemáticos fue sustancial. El error del 2 de mayo descendió del **10,62 % al 2,14 %**, y el de Santiago Apóstol del 4,28 % al 2,89 %. En términos agregados, el error medio en festivos pasó del 4,81 % al 3,32 %, con una reducción de la penalización de 2,95 a 2,01.

El rendimiento global permaneció prácticamente inalterado, como cabía esperar: las festividades representan alrededor de veinte días al año y su peso sobre la métrica media es reducido. Una corrección que mejora los casos difíciles sin degradar el caso general constituye el resultado deseable.

5.6. Aplicación desarrollada



Figura 5.3: Interfaz de la aplicación web desarrollada parte 1




Figura 5.4: Interfaz de la aplicación web desarrollada parte 2

La aplicación materializa el objetivo específico OE7. Su elemento central es la traducción de la predicción numérica a una recomendación en lenguaje natural, generada automáticamente a partir de las franjas horarias de menor demanda prevista.

Rendimiento del modelo de la aplicación

Evaluable sobre los mismos catorce orígenes, el modelo de 30 variables obtiene un MAPE mediano del 1,34 % y medio del 1,49 %, frente al 1,34 % y el 1,65 % del modelo

de evaluación. La reducción del conjunto de variables no penaliza, por tanto, el rendimiento.

Como comprobación adicional, el modelo se entrenó una sola vez y se aplicó sobre un bloque continuo de 30 días (diciembre de 2024). El error medio asciende en ese caso al 3,05 % (mediana del 2,01 %), concentrado en cinco días —entre ellos Nochebuena, Navidad y el puente de la Inmaculada—, sin los cuales se sitúa en el 2,12 %. El error crece además con la distancia al último entrenamiento, por lo que se recomienda reentrenar el modelo periódicamente.

Extensión del horizonte a 48 horas

El modelo se entrena para un horizonte nativo de veinticuatro horas, límite impuesto por la disponibilidad de los desfases: predecir el instante $t + 25$ requeriría conocer $t + 1$, aún no observado. La extensión a cuarenta y ocho horas se obtiene mediante un **esquema recursivo**, realimentando las predicciones del primer tramo para calcular los desfases del segundo.

La degradación resultante se estimó sobre **un único origen**, situado al final de la serie, obteniéndose un error de 0,45 % en las horas 1 a 24 y de 0,74 % en las horas 25 a 48. Procede subrayar que estas cifras **no son comparables** con las de la sección 5.2: proceden de una sola predicción y no del protocolo de catorce orígenes, por lo que su valor es meramente ilustrativo de la degradación relativa entre ambos tramos.

Las variables meteorológicas empleadas en esta comprobación son observaciones registradas, con la misma salvedad señalada respecto al protocolo de evaluación retrospectiva.

Comportamiento ante fallos de las fuentes

Durante el desarrollo se constató que la interfaz REData devuelve errores de servidor ante peticiones que abarcan periodos extensos, dado que publica con resolución de diez minutos. La descarga se fragmentó en consecuencia en bloques de siete días, con tolerancia a fallos parciales: si un bloque concreto no responde, los restantes se procesan y la aplicación advierte de la posible existencia de huecos.

Esta consideración excede el ámbito estrictamente académico, pero resulta determinante para un sistema destinado a funcionar de forma continuada.

6. Conclusiones

6.1. Cumplimiento de los objetivos

Se revisa a continuación el grado de consecución de cada objetivo específico.

OE1 — Análisis del comportamiento histórico. Alcanzado. El análisis exploratorio caracterizó la serie e identificó las tres escalas de periodicidad presentes. El tratamiento de valores ausentes reveló además una circunstancia metodológicamente relevante: las ausencias no figuraban como valores nulos sino como registros inexistentes en el índice temporal, de modo que los procedimientos habituales de interpolación no habrían producido efecto alguno.

OE2 — Incorporación de variables exógenas. Alcanzado. Se integraron las variables meteorológicas de AEMET y el calendario laboral. El calendario evolucionó durante el trabajo desde una variable binaria hasta una intensidad ponderada por población, tras detectarse la discordancia entre el ámbito territorial de la demanda y el del calendario, y su aportación queda confirmada por la evaluación en festivos. La aportación de la temperatura, en cambio, resultó nula en el periodo evaluado: el análisis de sensibilidad (sección 6.4) muestra que el modelo sin variables térmicas obtiene un error ligeramente inferior. El objetivo se cumple en cuanto a la incorporación de las variables, pero la utilidad predictiva de la meteorología queda condicionada a disponer de información horaria y representativa del conjunto peninsular.

OE3 — Aplicación de series de Fourier. Alcanzado. El análisis espectral identificó los periodos de 24, 12 y 168 horas, resultado que fundamenta empíricamente la selección de los desfases temporales empleados como predictores.

OE4 — Desarrollo y comparación de modelos. Alcanzado. Se evaluaron diez formulaciones frente a las seis inicialmente previstas, incorporando tres modelos ingenuos como línea base adicional.

OE5 — Evaluación con control del sobreajuste. Alcanzado. Se registraron las métricas dentro y fuera de muestra para todos los modelos, con la precisión relativa a su distinta interpretabilidad en formulaciones estadísticas y de aprendizaje automático.

OE6 — Identificación de los factores determinantes. Alcanzado. Mediante importancia nativa y valores SHAP. El resultado converge con el del análisis exploratorio, lo que refuerza ambas vías.

OE7 — Despliegue de la aplicación. Alcanzado. La aplicación es funcional y puede ejecutarse a partir del código publicado en el repositorio (Anexo A), con predicción a 24 y 48 horas, identificación de franjas favorables y recomendaciones en lenguaje natural.

Cumplimiento de las métricas objetivo

Tabla 6.1: Grado de consecución de las métricas establecidas

Métrica	Objetivo	Obtenido	Estado
MAPE	< 8 %	1,34 %	Superado
MAE sobre demanda media	< 5 %	1,7 %	Superado
Mejora sobre línea base	Superarla	+56,3 %	Superado
Aplicación funcional	Ejecutable desde el repositorio	Sí	Cumplido

6.2. Contraste de las hipótesis

La Tabla 6.2 resume la resolución de las hipótesis planteadas en la sección 3.6.

Tabla 6.2: Resolución de las hipótesis de trabajo

Hipótesis	Evidencia principal	Resolución
H1	XGBoost: MAPE mediano del 1,34 % frente al 3,06 % del ingenuo semanal (mejora del 56,3 %). Random Forest y LightGBM también la superan	Confirmada
H2	Solo SARIMA supera al ingenuo semanal (+20,9 %). Prophet (−56,4 %) y SARIMAX con Fourier (−60,3 %) quedan por debajo	Rechazada parcialmente
H3	MAPE en festivos del 3,32 % (XGBoost) frente al 16,63 % (ingenuo semanal). La intensidad ponderada por población reduce el error del 2 de mayo del 10,62 % al 2,14 %	Confirmada
H4	Ridge, con las mismas variables, obtiene un MAPE mediano del 1,94 % y errores del 5–6 % en los lunes, frente a menos del 3 % en los modelos de árboles	Confirmada

H1 — Confirmada. Los tres modelos basados en árboles superan con claridad a la mejor línea base ingenua, y XGBoost lo hace en un 56,3 %. La mejora se mantiene en los orígenes que resultaban problemáticos para la línea base (Tabla 5.4), lo que indica que no depende de unos pocos días favorables.

H2 — Rechazada parcialmente. Únicamente el SARIMA clásico mejora la predicción ingenua semanal. Prophet y SARIMAX con términos de Fourier obtienen peores resultados, porque su representación suave de la estacionalidad semanal no reproduce la transición abrupta entre días laborables y fin de semana. Este resultado negativo es una aportación del trabajo en sí mismo: sin las referencias ingenuas, ambos modelos se habrían presentado como una mejora cuando no lo son.

H3 — Confirmada. El error en festivos se reduce a la quinta parte del de la línea base, y el caso del 25 de diciembre (4,74 % frente a 40,68 %) ilustra la magnitud del efecto. El contraste permitió además detectar una limitación de la formulación inicial —el calendario de una sola comunidad aplicado a una demanda peninsular—, corregida mediante la intensidad ponderada por población.

H4 — Confirmada. Ridge dispone exactamente de las mismas variables que los modelos de árboles, pero su carácter lineal le impide representar que el efecto del tipo de día depende de la hora. Ello explica sus errores en los lunes y confirma que la ventaja de los modelos de árboles se debe a su capacidad para capturar relaciones no lineales, y no a disponer de más información.

6.3. Principales aportaciones

Desarrollo de un sistema integral desde la adquisición de datos hasta el despliegue

La aportación principal no reside en el valor concreto del error alcanzado, sino en haber recorrido el ciclo íntegro desde el dato abierto hasta una aplicación utilizable. Ese recorrido obligó a resolver cuestiones que un estudio puramente comparativo no llega a plantearse: la disponibilidad efectiva de cada variable en el instante de predicción, la coherencia entre el código de entrenamiento y el de explotación, o el comportamiento del sistema ante el fallo de una fuente externa.

Tratamiento riguroso y documentado de los datos

Tres decisiones metodológicas merecen destacarse por su carácter no evidente:

1. **El reindexado previo a la imputación.** Las ausencias se manifestaban como registros inexistentes, no como valores nulos. Sin reindexar, la interpolación no habría producido efecto y la verificación posterior habría comparado la serie consigo misma.
2. **La estrategia escalonada de imputación.** El desplazamiento semanal para huecos extensos preserva el perfil diario, que una interpolación lineal destruiría.
3. **La detección de anomalías condicionada al contexto.** La regla del rango intercuartílico no identificaba ningún valor atípico; el procedimiento sobre el residuo respecto al perfil temporal detectó 555.

Cuantificación de la fuga de información

El trabajo no se limita a evitar la fuga de información, sino que mide su efecto: la inclusión de variables no disponibles en el instante de predicción reduce el error aparente en un 55 %. Esta cuantificación documenta una decisión metodológica que la mayoría de los trabajos publicados no llega a explicitar.

Verificación del efecto del calendario

Los resultados son consistentes con las hipótesis planteadas a partir del análisis exploratorio. El análisis exploratorio identificó que cerca del 70 % de las anomalías se concentraba en festivos; ese hallazgo motivó la incorporación de las variables de calendario; y la evaluación dirigida verificó que dichas variables cumplen su cometido, con diferencias de hasta un orden de magnitud frente a los modelos que carecen de ellas.

Detección y corrección de una limitación propia

La discordancia entre el ámbito territorial de la demanda —peninsular— y el del calendario —autonómico— se detectó al analizar los resultados, no se conocía de antemano. La solución adoptada, una intensidad ponderada por población, corrigió el error del 2 de mayo del 10,62 % al 2,14 % sin degradar el rendimiento general.

6.4. Limitaciones del trabajo

Resolución de las variables meteorológicas. Los valores climatológicos de AEMET tienen periodicidad diaria, mientras que la variable objetivo es horaria. La propagación del valor diario a las veinticuatro horas del día renuncia al ciclo térmico intradiario.

Representatividad de la estación meteorológica. Se emplea una única estación —Madrid-Retiro— como aproximación de las condiciones peninsulares. La heterogeneidad climática del territorio nacional no queda recogida.

Meteorología en la evaluación retrospectiva. Las variables meteorológicas correspondientes al horizonte de predicción proceden de observaciones registradas, empleadas como aproximación de la información que proporcionaría un pronóstico operativo. Al no existir un archivo histórico accesible de previsiones de AEMET, esta simplificación resulta inevitable, y produce una estimación optimista del rendimiento en la medida en que las observaciones no incorporan la incertidumbre propia de una previsión.

Para acotar su alcance se ha realizado un análisis de sensibilidad, perturbando las temperaturas observadas con un error diario aleatorio de magnitud creciente. Con errores de 1 a 1,5 °C, característicos de un pronóstico a veinticuatro horas, el MAPE medio pasa del 1,65 % al 1,66–1,69 %, una degradación relativa de entre el 0,4 % y el 2,0 %. El optimismo introducido por emplear observaciones resulta, por tanto, reducido.

El mismo análisis revela, sin embargo, un resultado que debe reportarse: prescindiendo por completo de las variables de temperatura, el MAPE medio desciende al 1,53 %. En el periodo evaluado —otoño e inicio del invierno, con temperaturas moderadas— la temperatura diaria de una única estación no aporta capacidad predictiva adicional a la contenida en los desfases de la propia serie. El resultado es coherente con la posición intermedia de estas variables en el análisis SHAP y refuerza la conveniencia de emplear temperatura horaria y representativa del conjunto peninsular.

Periodo de evaluación acotado. Los catorce orígenes cubren aproximadamente setenta días, entre octubre y diciembre de 2024. El signo negativo de la diferencia entre entrenamiento y producción en el modelo Ridge sugiere que dicho periodo resulta más estable que la media del histórico, por lo que las cifras de sobreajuste podrían estar infravaloradas.

Ausencia de información sobre generación. El sistema no incorpora datos de generación renovable, factor que influye sensiblemente sobre el precio y que podría mejorar la calidad de las recomendaciones económicas.

Extensión recursiva del horizonte. La predicción más allá de veinticuatro horas se obtiene realimentando las predicciones anteriores, procedimiento que acumula error. Un modelo entrenado específicamente para cuarenta y ocho horas obtendría mejores resultados.

Relación entre demanda y precio. La aplicación emplea la demanda prevista como indicador aproximado del precio. La relación entre ambas magnitudes es estrecha pero no determinista: la composición del parque generador disponible introduce una variabilidad no contemplada.

6.5. Líneas de trabajo futuro

Predicción directa del precio. Incorporar el precio del mercado diario como variable objetivo adicional permitiría ofrecer recomendaciones económicas directas en lugar de aproximadas.

Meteorología de resolución horaria. El reanálisis ERA5 del programa Copernicus proporciona temperatura horaria histórica, lo que eliminaría la limitación principal de las variables meteorológicas actuales.

Modelos fundacionales para series temporales. Han surgido recientemente modelos preentrenados de propósito general para predicción de series temporales, capaces de operar sin entrenamiento específico sobre el conjunto de destino. Su evaluación comparativa frente al enfoque adoptado constituye una línea de continuación natural.

Combinación de modelos. La evidencia de las competiciones M (Makridakis et al., 2020) indica que la combinación de predicciones mejora sistemáticamente la robustez. Un promedio ponderado de XGBoost y LightGBM resultaría inmediato de implementar.

Desagregación territorial. La disponibilidad de demanda por comunidad autónoma permitiría emplear el calendario correspondiente a cada territorio, resolviendo de raíz la limitación que motivó la variable de intensidad ponderada.

Integración del consumo individual. La incorporación de los datos de consumo del propio usuario, accesibles a través de las distribuidoras, permitiría pasar de una recomendación general a una estimación personalizada del ahorro.

Despliegue público de la aplicación. La publicación de la aplicación en un servicio en la nube, como Streamlit Community Cloud, permitiría el acceso sin instalación previa. Requiere únicamente versionar el modelo serializado y configurar las credenciales como secretos del servicio.

7. Referencias

- Agencia Estatal de Meteorología. (2025). *AEMET OpenData*. Consultado el 22 de julio de 2026, desde <https://opendata.aemet.es/>
- Anthropic. (2026). *Claude* (Ver. Claude Sonnet 5) [Modelo de lenguaje de gran tamaño]. <https://claude.ai/>
- Bandara, K., Hyndman, R. J., & Bergmeir, C. (2021). MSTL: A Seasonal-Trend Decomposition Algorithm for Time Series with Multiple Seasonal Patterns. *arXiv preprint arXiv:2107.13462*. <https://doi.org/10.48550/arXiv.2107.13462>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5.^a ed.). John Wiley & Sons.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A Seasonal-Trend Decomposition Procedure Based on Loess. *Journal of Official Statistics*, 6(1), 3-73.
- Hernández, M., Baca, L. G., Criado, D., & Pegalajar, M. C. (2023). Artificial Intelligence-Based Prediction of Spanish Energy Pricing and Its Impact on Electric Consumption. *Machine Learning and Knowledge Extraction*, 5(2). <https://doi.org/10.3390/make5020026>
- Hong, T., & Fan, S. (2016). Probabilistic Electric Load Forecasting: A Tutorial Review. *International Journal of Forecasting*, 32(3), 914-938. <https://doi.org/10.1016/j.ijforecast.2015.11.011>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54-74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). The M5 competition: Background, organization, and implementation. *International Journal of Forecasting*, 38(4), 1325-1336. <https://doi.org/10.1016/j.ijforecast.2021.07.007>

- Naciones Unidas. (2015). *Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible* [Resolución A/RES/70/1 de la Asamblea General]. Consultado el 30 de septiembre de 2026, desde <https://www.un.org/sustainabledevelopment/es/>
- OpenAI. (2026). *ChatGPT* (Ver. GPT-5) [Modelo de lenguaje de gran tamaño]. <https://chatgpt.com/>
- Operador del Mercado Ibérico de Energía. (2025). *Resultados del mercado diario*. Consultado el 22 de julio de 2026, desde <https://www.omie.es/>
- Pegalajar, M. C., Ruiz, L. G. B., Cuéllar, M. P., & Rueda, R. (2021). Analysis and enhanced prediction of the Spanish Electricity Network through Big Data and Machine Learning techniques. *International Journal of Approximate Reasoning*, 133, 48-59. <https://doi.org/10.1016/j.ijar.2021.03.002>
- Qinghe, Z., Wen, X., Boyan, H., Jong, W., & Junlong, F. (2022). Optimised extreme gradient boosting model for short term electric load demand forecasting of regional grid system. *Scientific Reports*, 12, 19282. <https://doi.org/10.1038/s41598-022-22024-3>
- Red Eléctrica de España. (2025). *Sistema de Información del Operador del Sistema (e-sios)*. Consultado el 22 de julio de 2026, desde <https://www.esios.ree.es/>
- Semmelmann, L., Henni, S., & Weinhardt, C. (2022). Load forecasting for energy communities: a novel LSTM-XGBoost hybrid model based on smart meter data. *Energy Informatics*, 5(1), 24. <https://doi.org/10.1186/s42162-022-00212-9>
- Streamlit Inc. (2025). *Streamlit: A Faster Way to Build and Share Data Apps*. Consultado el 22 de julio de 2026, desde <https://streamlit.io/>
- Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37-45. <https://doi.org/10.1080/00031305.2017.1380080>
- Torres, J. F., Martínez-Álvarez, F., & Troncoso, A. (2022). A deep LSTM network for the Spanish electricity consumption forecasting. *Neural Computing and Applications*, 34, 10533-10545. <https://doi.org/10.1007/s00521-021-06773-2>
- Wang, Y., Chen, J., Chen, X., Zeng, X., Kong, Y., Sun, S., Guo, Y., & Liu, Y. (2021). Short-term load forecasting for industrial customers based on TCN-LightGBM. *IEEE Transactions on Power Systems*, 36(3), 1984-1997. <https://doi.org/10.1109/TPWRS.2020.3028133>

Anexos

Anexo A. Repositorio de código

Enlace al repositorio público de GitHub con el código fuente del proyecto. <https://github.com/Rober-GP/tfm-prediccion-demanda-energetica>

Anexo B. Repositorio de prompts utilizados

Conforme a las normas de la Universidad Internacional de Valencia sobre el uso ético de la inteligencia artificial generativa, el siguiente repositorio recoge los prompts utilizados, las respuestas relevantes, la fecha y herramienta de cada interacción y un comentario sobre su propósito: <https://github.com/Rober-GP/repositorio-ia-TFM>